

Университет ИТМО

Факультет технологий искусственного интеллекта

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

по направлению подготовки

27.04.03 Системный анализ и управление

Тема: «Алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания»

Выполнил: Горбунов Роман Леонидович

Научный руководитель: к.ф.-м.н., Бабушкин М.В.

Санкт-Петербург, 2026

Аннотация

Краткое описание работы.

Ключевые слова: ключ1, ключ2, ключ3.

Содержание

Введение	4
1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов	5
1.1. Алгоритмы измерения частотных характеристик	5
1.2. Алгоритмы идентификации параметров	5
2. Разработка алгоритмов внутрисхемного измерения частотных характеристик	6
2.1. Общие сведения	6
2.2. Алгоритм 1	8
2.3. Алгоритм 2	10
2.4. Алгоритм 3	13
2.5. Оптимальный алгоритм	15
3. Разработка алгоритмов идентификации параметров макромоделей . .	17
3.1. Архитектура модели	17
3.1.1. Энкодер	18
3.1.2. Bottleneck	19
3.1.3. Декодер	21
3.2. Обучение модели	22
3.2.1. Набор данных	22
3.2.2. Функция потерь	23
3.2.3. Метрики	23
3.3. Результаты	24
Заключение	25
Список использованных источников	26
Приложение А. Лабораторный стенд	27
Приложение Б. Внедрение результатов работы	28

Введение

Актуальность темы работы Работа связана с системами управления вторичными источниками электропитания, их настройкой, отладкой и контролем состояния.

Цели и задачи работы

Цель работы - разработать алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания.

Задачи работы:

1. Разработать алгоритмы внутрисхемного измерения частотных характеристик.
2. Разработать алгоритмы идентификации параметров на основе измеренных частотных характеристик.
3. Выполнить экспериментальную оценку показателей качества измерений и идентификации параметров.

Основные результаты работы

Практическая значимость результатов работы

Апробация результатов работы

Объем и структура работы

1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов

1.1. Алгоритмы измерения частотных характеристик

1.2. Алгоритмы идентификации параметров

2. Разработка алгоритмов внутрисхемного измерения частотных характеристик

2.1. Общие сведения

Рассматриваемая система аналого-цифрового преобразования и цифровой обработки сигналов с воздействием на объект управления посредством широтно-импульсной модуляции (рис. (2.1)).




Рисунок 2.1. Рассматриваемая система

Операции выполняются циклически с постоянным периодом T_d , соответствующим базовой частоте дискретного регулирования $f_d = 1/T_d$.

В канал управления системы аддитивно инжектируется сигнал в виде дискретной последовательности $z[n]$.

Откликом системы являются два непрерывных сигнала: $x_c(t)$, $y_c(t)$.

Система преобразует непрерывные сигналы $x_c(t)$, $y_c(t)$ в дискретные последовательности $x[n]$, $y[n]$.

Преобразование осуществляется посредством дискретизации:

$$\begin{aligned} x[n] &= x_c(nT_s), \\ y[n] &= y_c(nT_s), \end{aligned} \tag{2.1}$$

где T_s – период дискретизации, $T_s \geq T_d$.

Коэффициенты разложения дискретных последовательностей

$$x[n] = \frac{1}{N} \sum_{l=0}^{N-1} X[l] e^{j \frac{2\pi}{N} ln},$$

$$y[n] = \frac{1}{N} \sum_{l=0}^{N-1} Y[l] e^{j \frac{2\pi}{N} ln}$$

определяются по N -последовательным отсчетам дискретных последовательностей $x[n]$, $y[n]$:

$$X[l] = \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} nl},$$

$$Y[l] = \sum_{n=0}^{N-1} y[n] e^{-j \frac{2\pi}{N} nl}.$$
(2.2)

Коэффициенты $X[l]$, $Y[l] \in \mathbb{C}$, представляют собой дискретные периодические последовательности с периодом N .

При условии, что измерительное окно длительностью T_h вмещает целое количество N периодов дискретизации T_s ($T_h = N \cdot T_s$) дискретные последовательности $X[l]$, $Y[l]$ на отрезке $l \in [0; N-1]$ длины N содержат коэффициенты разложения $x[n]$, $y[n]$ в диапазоне частот $f \in [0, f_s/2]$ с шагом по частоте $\Delta f = 1/T_h$.

Составляющим с частотой f_h соответствуют $X[l]$, $Y[l]$ при $l = 1$, а с частотой $f_s/2$ – при $l = \lfloor (N-1)/2 \rfloor$.

В данном разделе рассматриваются алгоритмы измерения частотных характеристик, основанные на воздействии на систему дискретной последовательностью $z[n]$ моногармонического типа, определяемой косинусоидальной функцией

$$z[n] = Z \cos(\underbrace{2\pi f_z T_d n}_{\omega_z})$$

с частотой f_z .

Минимальное количество отсчетов N на измерительном окне T_h принято равным 3, поэтому частота f_z ограничена сверху значением $f_d/3$.

Модель сигналов-откликов системы принята следующей:

$$\begin{aligned}x_c(t) &= X_0 + X_z \cos(\omega_z t + \phi_x) + X_g \cos(\omega_g t), \\y_c(t) &= Y_0 + Y_z \cos(\omega_z t + \phi_y) + Y_g \cos(\omega_g t),\end{aligned}$$

где $\omega_z = 2\pi f_z$.

Алгоритм измерения частотной характеристики звена системы основан на последовательной смене периода инжектируемого сигнала $T_z = 1/f_z$ в серии из K -измерений.

Каждому k -му измерению, $k \in [1, K]$, соответствует пара параметров $Z^{(k)}$, $T_z^{(k)}$, следовательно, и набор дискретных последовательностей $x^{(k)}[n]$, $y^{(k)}[n]$, $z^{(k)}[n]$, а также коэффициентов $X^{(k)}[l]$, $Y^{(k)}[l]$.

Под частотной характеристикой понимается набор пар значений $f_z^{(k)}$, $W^{(k)}$, где в каждом k -ом измерении

$$W^{(k)} = \frac{Y^{(k)}[L^{(k)}]}{X^{(k)}[L^{(k)}]} = |W^{(k)}| e^{j\angle W^{(k)}}, \quad (2.3)$$

$$L^{(k)} = T_h^{(k)} / T_z^{(k)}.$$

Пары значений $f_z^{(k)}$, $|W^{(k)}|$ и $f_z^{(k)}$, $\angle W^{(k)}$ образуют амплитудно-частотную и фазо-частотную характеристики, соответственно.

$$\begin{aligned}|W^{(k)}| &= \frac{|Y^{(k)}[L^{(k)}]|}{|X^{(k)}[L^{(k)}]|}, \\ \angle W^{(k)} &= \angle Y^{(k)}[L^{(k)}] - \angle X^{(k)}[L^{(k)}].\end{aligned} \quad (2.4)$$

2.2. Алгоритм 1

$$T_h - var, N - var$$

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}$, $k \in [1; K]$):

- Длительность T_h измерительного окна равна периоду T_z инжектируемого сигнала ($T_h^{(k)} = T_z^{(k)}$, $T_h^{(k)} - var$).
- Период дискретизации T_s одинаков для всех значений T_z и равен периоду T_d выполнения операций в системе ($T_s^{(k)} = T_d$, $T_s^{(k)} = const$).

- Количество точек N дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), изменяется пропорционально $T_z (N^{(k)} - var)$.

Период инжектируемого сигнала

$$T_z^{(k)} = N^{(k)} \cdot T_s^{(k)} = N^{(k)} \cdot T_d$$

кратен периоду T_d выполнения операций в системе (рис. 2.2).




Рисунок 2.2. Размер $N^{(k)}$ дискретной последовательности при изменении периода $T_z^{(k)}$ инжектируемого сигнала

В связи с тем, что $T_h^{(k)} = T_z^{(k)}$ составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (2.3) при $L^{(k)} = 1$.

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты f_z инжектируемого сигнала в серии из K измерений **характерны следующие особенности:**

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , которое ограничено сверху

- только объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.
2. Максимально возможная частота f_z в пределе составляет $f_d/3$.
 3. В памяти достаточно хранить $N^{(k)} = f_d/f_z^{(k)}$ -значений каждого массива-отклика $x^{(k)}[n]$, $y^{(k)}[n]$, причем величина N не является постоянной и уменьшается с ростом частоты f_z вплоть до $N = 3$ при $f_z \rightarrow f_d/3$.
 4. Шаг приращения периода T_z инжектируемого сигнала (разрешающая способность): $\Delta T_z = T_d$.
 5. Потенциальные значения частот f_z инжектируемого сигнала неравномерно распределены на интервале $f \in (0; f_d/2)$ возможных значений:
 - На полуинтервале $f \in [f_d/10; f_d/2)$ частота f_z может принимать значения всего из 8-ми возможных:
 $f_z = (f_d/10, f_d/9, \dots, f_d/3)$.
 - На полуинтервале $f \in [f_d/100; f_d/10)$ – одно из 90 возможных:
 $f_z = (f_d/100, f_d/99, \dots, f_d/11)$.
 - На интервале $f \in (0; f_d/100)$ – сколь угодно много значений, ограниченное исключительно объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.

2.3. Алгоритм 2

$$T_h - var, N = const$$

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}$, $k \in [1; K]$):

- Длительность T_h измерительного окна равна периоду T_z инжектируемого сигнала ($T_h^{(k)} = T_z^{(k)}$, $T_h^{(k)} - var$).
- Количество точек N дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменно для всех значений периода T_z ($N^{(k)} = const$).
- Период дискретизации T_s изменяется в целях обеспечить $N^{(k)} = const$ при изменении периода T_z инжектируемого сигнала ($T_s^{(k)} - var$).

Постоянство N при изменении периода T_z инжектируемого сигнала обеспечивается децимацией (прореживанием) дискретных последовательностей $x'[n]$, $y'[n]$.

Выражениями $x'[n]$, $y'[n]$ обозначены дискретные последовательности,

формируемые в результате дискретизации откликов системы $x_c(t)$, $y_c(t)$ непосредственно с периодом T_d выполнения операций в системе.

Дискретные последовательности $x^{(k)}[n]$, $y^{(k)}[n]$ формируются в результате децимации $x'^{(k)}[n]$, $y'^{(k)}[n]$ с коэффициентом децимации $M^{(k)} \in \mathbb{N}$

$$\begin{aligned} x^{(k)}[n] &= x'^{(k)}[n \cdot M^{(k)}] = x_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}) \\ y^{(k)}[n] &= y'^{(k)}[n \cdot M^{(k)}] = y_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}), \end{aligned}$$

так, что период инжектируемого сигнала всегда кратен периоду T_d выполнения операций в системе:

$$T_z^{(k)} = N^{(k)} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}.$$

Дискретные последовательности $x^{(k)}[n]$, $y^{(k)}[n]$ формируются по правилу (2.1) фактически с эквивалентным периодом дискретизации $T_s^{(k)} = M^{(k)} \cdot T_d$ (рис. (2.3)). Под эквивалентным понимается такой период дискретизации, при котором формировалась бы точно такая же дискретная последовательность.




Рисунок 2.3. Период дискретизации $T_s^{(k)}$ при изменении периода $T_s^{(z)}$ инжестируемого сигнала

Измерительное окно $T_h^{(k)} = T_z^{(k)}$ при всех k , поэтому, также как и в алгоритме 2.2, составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)}[l]$, $Y^{(k)}[l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (2.3) при $L^{(k)} = 1$.

Принципиальное отличие от алгоритма 2.2 связано с потенциально меньшим размером N массивов-откликов $x[n]$, $y[n]$ ($N \in \mathbb{N}$ – независимая переменная, $N > 2$).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты f_z инжестируемого сигнала в серии из K измерений **характерны следующие особенности**:

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , причем требуемый объем памяти для хранения массивов-откликов $x^{(k)}[n]$, $y^{(k)}[n]$ одинаков для всех длительностей $T_h^{(k)}$ и частот $f_z^{(k)}$.
2. Максимально возможная частота f_z составляет f_d/N .

3. Шаг приращения периода T_z инжектируемого сигнала (разрешающая способность) в N -раз больше, в сравнении с алгоритмом 2.2 ($\Delta T_z = N \cdot T_d$).
4. Грубый шаг приращения периода обуславливает еще более неравномерное распределение частот. Например, в диапазоне частот $f \in [f_d/100; f_d/10]$ при $N = 10$ частота f_z инжектируемого сигнала может принимать значения всего из 10-ти возможных:
 $f_z = (f_d/100, f_d/90, \dots, f_d/10)$.

2.4. Алгоритм 3

$$T_h = \text{const}, N = \text{const}$$

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}, k \in [1; K]$):

- Длительность T_h измерительного окна неизменна и равна наибольшему периоду инжектируемого сигнала ($T_h^{(k)} = T_z^{max}, T_h^{(k)} = \text{const}$).
- Период дискретизации T_s одинаков для всех значений T_z ($T_s^{(k)} = \text{const}$) и кратен периоду T_d выполнения операций в системе ($T_s^{(k)} = M \cdot T_d$); коэффициент децимации $M = \text{const}, M \in \mathbb{N}$.
- Количество точек $N \in \mathbb{N}$ дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменно для всех значений $T_z^{(k)}$ ($N^{(k)} = \text{const}$),

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

Математическая обработка в соответствии с (2.2) накладывает ограничение на период T_z инжектируемого сигнала – требуется, чтобы измерительное окно T_h вмещало целое число периодов T_z (рис. 2.4), т.е. для каждого значения $T_z^{(k)}$ должно выполняться

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)}, \quad (2.5)$$

где $L^{(k)} \in \mathbb{N}$.




Рисунок 2.4. Период инжектируемого сигнала при $T_h^{(k)} = \text{const}$

В соответствии с (2.5), частота $f_z^{(k)}$ инжектируемого сигнала потенциально принимает значения

$$f_z^{(k)} = L^{(k)} \frac{1}{T_h} = L^{(k)} \Delta f_z,$$

где Δf_z – шаг приращения частоты инжектируемого сигнала

В связи с $\Delta f_z = \text{const}$ потенциальные значения частот $f_z^{(k)}$ равномерно распределены на интервале возможных значений, что **является главной отличительной особенностью алгоритма** в сравнении с алгоритмами 2.2, 2.3.

Составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ при разных значениях $L^{(k)}$, определяемых выражением (2.3).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты $f_z^{(k)}$ инжектируемого сигнала в серии из K измерений **характерны следующие особенности:**

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , которое ограничено сверху только объемом памяти для хранения массивов-откликов $x [n]$, $y [n]$.

2. Максимально возможная частота f_z в пределе составляет $f_s/3$.
3. Требуемый объем памяти для хранения массивов-откликов $x^{(k)}[n]$, $y^{(k)}[n]$ одинаков для всех частот $f_z^{(k)}$ инжектируемого сигнала.
4. Период T_z инжектируемого сигнала потенциально принимает значения от $T_z^{min} = 3T_s$ до $T_z^{max} = T_h$, но при условии $T_h/T_s \in \mathbb{N}$.
5. Шаг приращения частоты f_z инжектируемого сигнала (разрешающая способность): $\Delta f_z = 1/T_h$.

2.5. Оптимальный алгоритм

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала $(T_z^{(k)}, k \in [1; K])$:

- Длительность T_h измерительного окна кратна периоду инжектируемого сигнала ($T_h^{(k)} = L^{(k)}T_z^{(k)}$, $T_h^{(k)} = \text{var}$).
- Период дискретизации T_s кратен периоду T_d выполнения операций в системе ($T_s^{(k)} = M^{(k)}T_d$); коэффициент децимации $M^{(k)} = \text{var}$, $M \in \mathbb{N}_{>0}$.
- Количество точек $N \in \mathbb{N}_{>0}$ дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), соответствует каждому отдельному значению $T_z^{(k)}$ ($N^{(k)} = \text{var}$).

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

Длительность измерительного окна

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)} = L^{(k)} \cdot R^{(k)} \cdot T_s^{(k)} = \underbrace{L^{(k)} \cdot R^{(k)}}_{N^{(k)}} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}},$$

где $(R^{(k)} \in \mathbb{R})$ – соотношение между периодом инжектируемого сигнала и периодом дискретизации

$$R^{(k)} = \frac{T_z^{(k)}}{T_s^{(k)}}.$$

В связи с тем, что частота инжектируемого сигнала

$$f_z^{(k)} = L^{(k)} \cdot f_h^{(k)} = \frac{L^{(k)}}{T_h^{(k)}}$$

кратна частоте первой гармоники в спектре, множитель $L^{(k)}$ ограничен диапазоном

$$1 \leq L^{(k)} < \frac{N^{(k)}}{2}.$$

Главной отличительной особенностью алгоритма является то, что соотношение между периодом инжектируемого сигнала и периодом дискретизации может принимать дробные значения. Это означает, что на интервале $f \in (0; f_d/2)$ потенциальные значения частот f_z инжектируемого сигнала принимают сколь угодно много значений, ограниченное исключительно объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$. Главной задачей становится для каждой k -й частоты f_z найти оптимальный набор целых чисел $\mathbf{p}^{(k)} = (N^{(k)}, M^{(k)}, L^{(k)}) \in \mathbb{N}_{>0}^3$, при которых обеспечивается частота f_z^* с заданной степенью приближения ϵ_f к f_z :

$$\frac{|f_z^* - f_z|}{f_z} < \epsilon_f,$$

при ограничениях

$$N_{\min} \leq N^{(k)} \leq N_{\max},$$

$$M^{(k)} < \frac{R}{2}.$$

Если несколько наборов параметров удовлетворяют заданной точности, то из них выбирается с наименьшим N .

Если ни один набор параметров не удовлетворяет заданной точности, то выбирается набор с наименьшим отклонением f_z от заданной f_z .

Последовательность в алгоритме:

1. Вычисляется коэффициент
2. Перебираются значения N из диапазона $N_{\min}, N_{\max}$.

3. Разработка алгоритмов идентификации параметров макромоделей

Фактически решаемая задача по идентификации параметров сведена к задаче instance-сегментации. Разработанная архитектура модели реализует детектирование целевых объектов по частотным характеристикам звеньев системы – определяются количество объектов и области частот, где они расположены.

3.1. Архитектура модели

Модель основана на автокодировщике, выполняющем преобразование C_{in} -канального тензора длиной L в C_{out} -канальный тензор той же длины:

$$\Gamma : \mathbb{R}^{C_{in} \times L} \mapsto \mathbb{R}^{C_{out} \times L}.$$

Выход представляет собой бинарную маску, каждый канал которой соответствует типу детектируемых объектов.

Преобразование Γ выполняется в 3 основных этапа:

- Кодирование в скрытое (латентное) пространство (CNN-энкодер):

$$\mathbf{F} : \mathbb{R}^{F_0 \times L} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Выделение наиболее информативных признаков в скрытом пространстве (bottleneck):

$$\mathbf{H} : \mathbb{R}^{F_3 \times L_3} \mapsto \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Декодирование из скрытого пространства (CNN-декодер):

$$\mathbf{Y} : \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_1 \times L_1}.$$

На входе и выходе архитектуры имеются дополнительные сверточные слои (без нормализации и активации). В декодер проброшены attention gated-skip-

СВЯЗИ.




Рисунок 3.1. Блок-схема архитектуры модели

3.1.1. Энкодер

Энкодер преобразует входные данные в латентное (скрытое) пространство уменьшенной размерности. В созданной реализации энкодер состоит из каскада N сверточных базовых блоков. Заложена residual-архитектура базового блока по типу «pre-activation».




Рисунок 3.2. Блок-схема базового блока энкодера

Каждый n -й базовый блок, $n \in \{1, \dots, N\}$, выполняет последовательно две свертки с ядрами $\mathbf{W}_n^1$, $\mathbf{W}_n^2$, соответственно.

$$\begin{aligned}
\mathbf{z}_n^1 &= \mathbf{W}_n^1 * \sigma(\mathcal{N}(\mathbf{e}_{n-1})), \\
\mathbf{z}_n^2 &= \mathbf{W}_n^2 * \sigma(\mathcal{N}(\mathbf{z}_n^1)), \\
\mathbf{x}_n &= \mathbf{z}_n^2 \oplus \mathbf{s}_n,
\end{aligned}$$

где $*$ – операция свертки, $\oplus$ – поэлементная сумма.

Сквозная связь «вход-выход» $\mathbf{s}_n$ (skip-connection) базового слоя приводится к числу каналов (фичей) на выходе (при необходимости):

$$\mathbf{s}_n = \begin{cases} \mathbf{W}_n^s * \mathbf{e}_{n-1}, & \text{если } F_{n-1} \neq F_n \\ \mathbf{e}_{n-1}, & \text{иначе,} \end{cases}$$

где $\mathbf{W}_n^s \in \mathbb{R}^{F_n \times F_{n-1}}$ – ядро проекции.

Между слоями энкодера выполняется уменьшение размерности тензор в 2 раза алгоритмом «nn.MaxPool1d»:

$$\mathbf{e}_n \rightarrow \mathbf{e}_n \downarrow_2.$$

Таким образом, в энкодере выполняется последовательное увеличение числа каналов (фичей) с одновременным уменьшением размерности тензора. Residual-архитектура с pre-activation обеспечивают лучший градиентный поток для быстрой сходимости при обучении [1]. Регуляризация выполняется алгоритмом «nn.Dropout1d» на выходе второй свертки.

3.1.2. Bottleneck

Bottleneck реализован на основе трансформера.




Рисунок 3.3. Блок-схема bottleneck-алгоритма

С выхода энкодера поступает тензор $\mathbf{e}_3 \in \mathbb{R}^{F_3 \times L_3}$. На входе Bottleneck длина тензора уменьшается до L_4 , а количество каналов увеличивается до F_4 :

$$\mathbf{b}_{\text{in}} = \sigma \left(\mathcal{N} \left(\mathbf{W}^P * \mathbf{e}_3 \downarrow \right) \right),$$

где $\mathbf{W}^P \in \mathbb{R}^{F_4 \times F_3}$, $\mathbf{b}_{\text{in}} \in \mathbb{R}^{F_4 \times L_4}$.

На входе данные нормализуются (pre-normalization, [2]), затем тензор преобразуется (permute) к формату $L \times F$

$$\mathbf{b}_{\text{in}} \rightarrow \mathcal{N}(\mathbf{b}_{\text{in}}) \rightarrow \mathbf{b}_{\text{in.perm}},$$

$\mathbf{b}_{\text{in.perm}} \in \mathbb{R}^{L_4 \times F_4}$, для совместимости с популярной реализацией алгоритма Multi-Head Self-Attention (MHSA, [3]):

$$\begin{aligned} \mathbf{Q}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^Q, \\ \mathbf{K}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^K, \\ \mathbf{V}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^V, \\ \mathbf{H}_m &= \text{Softmax} \left(\frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_k}} \right) \mathbf{V}_m, \end{aligned}$$

где $d_k = F_4/h$,

$$\begin{aligned} \mathbf{W}_m^Q, \mathbf{W}_m^K, \mathbf{W}_m^V &\in \mathbb{R}^{F_4 \times d_k}, \\ \mathbf{Q}_m, \mathbf{K}_m, \mathbf{V}_m, \mathbf{H}_m &\in \mathbb{R}^{L_4 \times d_k}, \end{aligned}$$

$m \in \{1, \dots, h\}$.

Результаты вычисления h -«голов» алгоритма MHSA конкатенируются

$$\mathbf{MH}_{\text{perm}} = \text{Concat}(\mathbf{H}_1, \dots, \mathbf{H}_h) \mathbf{W}^O,$$

где $\mathbf{W}^O \in \mathbb{R}^{L_4 \times d_k}$, т.е. $\mathbf{MH}_{\text{perm}} \in \mathbb{R}^{L_4 \times F_4}$ – той же размерности, что и $\mathbf{b}_{\text{in.perm}}$.

Выход формируется в виде суммы со входным тензором, для чего размерности преобразуются обратно ($\mathbf{MH}_{\text{perm}} \rightarrow \mathbf{MH}$).

$$\mathbf{b}_{\text{attn}} = \mathbf{b}_{\text{in}} \oplus \mathbf{MH}.$$

После алгоритма MHSA выполняется нормализация данных для их последующей обработки полносвязными слоями (Multi-Layer Perceptron, MLP). Реализованы два Feed-Forward-слоя с промежуточным увеличением скрытого пространства в r -раз:

$$\mathbf{MLP} = \text{Dropout} \left(\mathbf{W}^{\text{MLP2}} \cdot \sigma \left(\mathbf{W}^{\text{MLP1}} \mathcal{N}(\mathbf{b}_{\text{attn}}) \right) \right),$$

$$\mathbf{b}_{\text{out}} = \mathbf{b}_{\text{attn}} \oplus \mathbf{MLP},$$

$$\mathbf{W}^{\text{MLP1}} \in \mathbb{R}^{(r \cdot F_4) \times F_4},$$

$$\mathbf{W}^{\text{MLP2}} \in \mathbb{R}^{F_4 \times (r \cdot F_4)},$$

где r – кратность масштабирования скрытого пространства в MLP-алгоритме.

Регуляризация выполняется алгоритмом «nn.Dropout» после каждого Feed-Forward-слоя.

3.1.3. Декодер

Каждый слой декодера увеличивает разрешение массива, последовательно приближая данные к маскам длины L .

$$\mathbf{x}_{\uparrow} = \text{Upsample}(\mathbf{x}),$$

$$\mathbf{z} = \mathbf{W} * \mathbf{x}_{\uparrow},$$

$$\mathbf{y} = \sigma(\mathcal{N}(\mathbf{z}))$$

Слои декодера связаны с соответствующими выходами энкодера посредством Attention-gated-связей, по аналогии с [4].

3.2. Обучение модели

3.2.1. Набор данных

Обучение модели выполнено на синтетическом наборе данных, сгенерированном под обучение разработанной архитектуры модели. Набор данных включает ‘Train’, ‘Val’ и ‘Test’-коллекций csv-таблиц частотных характеристик и json-файлов с координатами полюсов/нулей.

Тренировочный набор данных состоит из 72 случайных комбинаций полюсов/нулей обобщенной модели линейного динамического звена:

$$H(s) = G \frac{\prod_{m=1}^M \left(1 + \frac{s}{\omega_{z(m)}}\right)}{s^K \prod_{n=1}^N \left(1 + \frac{s}{\omega_{p(n)}}\right)} e^{-st_{\text{delay}}},$$

где

- G – пропорциональный коэффициент, $G \in \mathbb{R}$;
- t_{delay} – задержка времени, $t_{\text{delay}} > 0$;
- K – количество интеграторов, $K \in \mathbb{N}$;
- $\omega_{z(m)}$ – частоты нулей передаточной функции $H(s)$ в количестве M , $\omega_{z(m)} \in \mathbb{R}$;
- $\omega_{p(n)}$ – частоты полюсов передаточной функции $H(s)$ в количестве N , $\omega_{p(n)} \in \mathbb{R}$.

Каждой комбинации соответствует 500 значений, отличающихся диапазонами частот и частотами полюсов/нулей. Параметры G , t_{delay} заданы константами для последующего изменения в ходе обучения. Общий размер тренировочного набора данных – $72 \times 500 = 36\,000$ примеров. Размеры валидационного и тестового наборов – 14 400 и 7 200 примеров, соответственно.

В тестовом наборе данных параметры G , t_{delay} сгенерированы случайным образом; частотные характеристики приближены к реальным данным путем введения шума с нормальным распределением.

Полное описание генератора набора данных приведено в репозитории [5].

3.2.2. Функция потерь

Обучение производилось путем минимизации комбинированной функции потерь

$$w^{\text{BCE}} \mathcal{L}^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}^{\text{Dice}},$$

где

- $\mathcal{L}^{\text{BCE}}$ – перекрестная энтропия,
- $\mathcal{L}^{\text{Dice}}$ – функция потерь Дайса,
- w^{BCE} , w^{Dice} – весовые коэффициенты.

Перекрестная энтропия:

$$\mathcal{L}^{\text{BCE}} = -\frac{1}{L} \sum_{i=1}^L \left[t_i \log(\sigma(d_i)) + (1 - t_i) \log(1 - \sigma(d_i)) \right],$$

где t_i – ожидаемое значение (0 или 1), d_i – логиты с выхода декодера (логит). Логиты преобразуются в непрерывный диапазон $[0; 1]$ функцией

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Функция потерь Дайса:

$$\mathcal{L}^{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^L d_i t_i}{\sum_{i=1}^L d_i + \sum_{i=1}^L t_i + \varepsilon}. \quad (3.1)$$

С целью более глубокого обучения полная функция ошибки формируется по каждому выходу n декодера:

$$\mathcal{L} = \frac{1}{w} \sum_{n=1}^N \left[w_n \left(w^{\text{BCE}} \mathcal{L}_n^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}_n^{\text{Dice}} \right) \right],$$

w – сумма всех коэффициентов w_n .

3.2.3. Метрики

Оценка качества работы модели производилась по коэффициенту Дайса:

$$\text{Dice} = \frac{2 \sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i + \varepsilon}, \quad (3.2)$$

где p_i – значения бинарной маски на выходе модели,

$$p_i = \mathbb{I}(\sigma(d_i) > 0,5). \quad (3.3)$$

где $\mathbb{I}(\cdot)$ – индикаторная функция, принимающая значения «0» или «1».

В качестве вспомогательной метрики использовался коэффициент Жаккара:

$$\text{IoU} = \frac{\sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i - \sum_{i=1}^L p_i t_i + \varepsilon}. \quad (3.4)$$

3.3. Результаты

Обучение модели выполнялось по лучшему коэффициенту Дайса на валидации (см. раздел 3.1). Весовые коэффициенты функции ошибки: $w^{\text{BCE}} = 0.25$, $w^{\text{Dice}} = 0.75$.

Таблица 3.1. Метрики результирующие

		Dice	IoU	Комментарий
1	Train	0.9092	0.8580	Случайные аугментации: G , t_{delay} , шумы.
2	Val	0.9393	0.9030	Нет аугментаций.*
3	Test	0.9221	0.8774	Нет аугментаций.**

* Набор данных изначально сформирован с разными G , t_{delay} .

** Набор данных изначально сформирован с шумами и разными G , t_{delay} .

Результаты инференса случайных примеров из тестового набора данных

Проведен эксперимент на лабораторном стенде (приложение А). Внутрисхемно измерена частотная характеристика цифрового звена

$$H(z) = \frac{\alpha}{1 - (1 - \alpha)z^{-1}},$$

где $\alpha = 0.12566$, частота тактирования 100 кГц, и выполнена детекция его полюсов и нулей

Заключение

Выводы по работе, ключевые результаты, перспективы дальнейших исследований.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Identity Mappings in Deep Residual Networks / К. He [и др.] // European Conference on Computer Vision (ECCV). — Springer, 2016. — С. 630—645. — DOI: [10.1007/978-3-319-46493-0_38](https://doi.org/10.1007/978-3-319-46493-0_38). — arXiv: [1603.05027 \[cs.CV\]](https://arxiv.org/abs/1603.05027). — URL: <https://arxiv.org/abs/1603.05027>.
2. On Layer Normalization in the Transformer Architecture / R. Xiong [и др.] // Proceedings of the 37th International Conference on Machine Learning (ICML). — PMLR, 2020. — С. 10524—10533. — URL: <https://arxiv.org/abs/2002.04745>.
3. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. Т. 30. — Curran Associates, Inc., 2017. — С. 5998—6008. — URL: <https://arxiv.org/abs/1706.03762>.
4. Attention U-Net: Learning Where to Look for the Pancreas / O. Oktay [и др.] // 1st Conference on Medical Imaging with Deep Learning (MIDL). — 2018. — URL: <https://arxiv.org/abs/1804.03999>.
5. *Gorbunov R.* zeros-poles-masks. — 2026. — GitHub repository; last accessed: 2026-05-04. <https://github.com/romangorbunov91/zeros-poles-masks>.

Приложение А. Лабораторный стенд

1. Макет источника питания 180 Вт – 1 шт.
2. Источник питания GW INSTEK GPC-3060D (2x30 В, 2x6 А) – 1 шт.
3. Нагрузка электронная АКИП 1380/1 (150 В, 30 А, 300 Вт) – 1 шт.
4. Измеритель частотных характеристик AP300 – 1 шт.
5. Осциллограф АКИП-4126/4А-Х – 1 шт.
6. Мультиметр FLUKE 17B+ – 1 шт.




Рисунок А.1. Лабораторный стенд

Приложение Б. Внедрение результатов работы