

Университет ИТМО

Факультет технологий искусственного интеллекта

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

по направлению подготовки

27.04.03 – Системный анализ и управление

**Алгоритмы внутрисхемного измерения частотных
характеристик и идентификации параметров вторичных
источников электропитания**

Выполнил:

Горбунов Роман Леонидович, к.т.н.

Научный руководитель:

Бабушкин Максим Владимирович, к.ф.-м.н.

Санкт-Петербург – 2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 ОБЗОР АЛГОРИТМОВ ИЗМЕРЕНИЯ ЧАСТОТНЫХ ХАРАКТЕРИСТИК И ИДЕНТИФИКАЦИИ ПАРАМЕТРОВ МАКРОМОДЕЛЕЙ ФИЗИЧЕСКИХ ОБЪЕКТОВ	7
1.1 Алгоритмы измерения частотных характеристик	7
1.2 Алгоритмы идентификации параметров	16
2 РАЗРАБОТКА АЛГОРИТМОВ ВНУТРИСХЕМНОГО ИЗМЕРЕНИЯ ЧАСТОТНЫХ ХАРАКТЕРИСТИК	25
2.1 Алгоритм с изменяемой длительностью измерительного окна, равной периоду инжектируемого сигнала	28
2.2 Алгоритм с изменяемой длительностью измерительного окна, равной периоду инжектируемого сигнала, и децимацией	30
2.3 Алгоритм с неизменной длительностью измерительного окна, кратной периоду инжектируемого сигнала.	32
2.4 Алгоритм с изменяемой длительностью измерительного окна, кратной периоду инжектируемого сигнала.	34
2.5 Процедура поиска оптимального набора параметров	37
2.6 Результаты измерений	42
3 РАЗРАБОТКА АЛГОРИТМОВ ИДЕНТИФИКАЦИИ ПАРАМЕТРОВ МАКРОМОДЕЛЕЙ	46
3.1 Архитектура модели сегментации	46
3.2 Предварительная обработка данных	54
3.3 Обучение модели сегментации.	57
3.4 Результаты детекции объектов и идентификации параметров	60
ЗАКЛЮЧЕНИЕ	76
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	77
ПРИЛОЖЕНИЕ А. Внедрение результатов работы	79
ПРИЛОЖЕНИЕ Б. Лабораторный стенд	81

ВВЕДЕНИЕ

Актуальность темы работы

Во вторичных источниках электропитания, регулируемых электроприводах и других технических устройствах с автоматическим регулированием процедуры отладки, настройки и контроля качества сопровождаются измерением частотных характеристик разомкнутого и замкнутого контура регулирования, объекта управления, канала обратной связи, регулятора встроенной системы управления. Измерения проводятся специализированным лабораторным оборудованием, подключаемым в разрыв штатных измерительных цепей системы управления.

В то же время современные источники электропитания все чаще оснащаются программным управлением (real-time embedded control), что создает предпосылки для внутрисхемного измерения характеристик. Результаты измерений могут использоваться для автоматизированного тестирования, настройки и контроля качества изделий в производственном цикле.

Цель работы

Разработать алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания.

Задачи работы

1. Разработать алгоритмы внутрисхемного измерения частотных характеристик.
2. Разработать алгоритмы идентификации параметров на основе измеренных частотных характеристик.
3. Выполнить экспериментальную оценку показателей качества измерений и идентификации параметров.

Положения, выносимые на защиту

1. Разработан **алгоритм внутрисхемного измерения частотных характеристик**, основанный на инъекции в систему синусоидальных сигналов с последовательной сменой частоты и амплитуды, обеспечивающий оптимальный размер измеряемых сигналов-откликов системы с целью уменьшения продолжительности измерений.

2. Разработан **алгоритм идентификации параметров линейного динамического звена по его частотной характеристике**, основанный на архитектуре энкодера-декодера, обеспечивающей однократную генерацию узких бинарных масок, соответствующих координатам частот вещественных полюсов и нулей передаточной функции звена.

Достоверность и обоснованность полученных результатов

Работоспособность разработанных алгоритма внутрисхемного измерения частотных характеристик и алгоритма идентификации параметров подтверждены в серии экспериментов по измерению частотных характеристик источника питания. Достигаемые качественные показатели оценены путем сравнения эталонных результатов с результатами измерения характеристик и идентификации по ним параметров.

Физическая реализуемость внутрисхемного измерения частотных характеристик обусловлена специфическими особенностями рассматриваемых в данной работе систем силовой электроники. В этих системах возможно задействовать канал управляющих воздействий как точку ввода программно генерируемого возмущения. При этом физические переменные уже измеряются в реальном времени встроенной системой управления для штатных задач регулирования и мониторинга и доступны к считыванию.

Практическая значимость и реализация результатов работы

Результаты работы предназначены к применению в электронной промышленности на этапах автоматизированного тестирования, контроля и отладки систем управления вторичных источников электропитания, источников бесперебойного питания, регулируемых электроприводов, автономных систем генерирования электроэнергии и многих других комплексов силовой электроники.

Алгоритм внутрисхемного измерения частотных характеристик, основанный на инъекции в систему синусоидальных сигналов с последовательной сменой частоты и амплитуды, обеспечивающий оптимальный размер измеряемых сигналов-откликов системы с целью уменьшения продолжительности измерений, успешно прошел аппаратные испытания и внедрен в коммерческую версию программного обеспечения «Digital Points» (протокол № 001 от 14.05.2026, Приложение А).

Результаты интеллектуальной деятельности

1. Свидетельство о гос. регистрации программы для ЭВМ: Программный модуль измерения частотных характеристик / **Р.Л. Горбунов**, Н.А. Севостьянов, А.Б. Дамдинов, И.В. Александров. – № 2021665973 от 06.10.2021 (Российская Федерация).
2. Свидетельство о гос. регистрации программы для ЭВМ: Модуль определения частоты при внутрисхемном измерении частотных характеристик / Н.А. Севостьянов, **Р.Л. Горбунов**. – № 2024613044 от 08.02.2024 (Российская Федерация).
3. Свидетельство о гос. регистрации программы для ЭВМ: Модуль построения графиков частотных характеристик / **Р.Л. Горбунов**. – № 2024613165 от 08.02.2024 (Российская Федерация).
4. Свидетельство о гос. регистрации программы для ЭВМ: Модуль инициализации параметров измерения частотных характеристик / **Р.Л. Горбунов**. – № 2023687756 от 18.12.2023 (Российская Федерация).
5. Свидетельство о гос. регистрации программы для ЭВМ: Модуль преобразования временных рядов в частотные характеристики / **Р.Л. Горбунов**. – № 2023688842 от 25.12.2023 (Российская Федерация).
6. Свидетельство о гос. регистрации программы для ЭВМ: Модуль преобразования комплексных переменных в частотные характеристики / **Р.Л. Горбунов**. – № 2023685884 от 30.11.2023 (Российская Федерация).
7. Свидетельство о гос. регистрации программы для ЭВМ: Классификатор с конфигурируемой архитектурой / **Р.Л. Горбунов**. – № 2026612481 от 28.01.2026 (Российская Федерация).
8. Свидетельство о гос. регистрации программы для ЭВМ: Функция настройки оптимизатора автоэнкодера / **Р.Л. Горбунов**. – № 2026615254 от 04.02.2026 (Российская Федерация).

Апробация результатов работы

Основные результаты работы представлены на следующих конференциях:

1. XIII Конгресс молодых ученых. 08-11 апреля 2024 г., ИТМО, г. Санкт-Петербург.
2. LIII научная и учебно-методическая конференция ИТМО. 29 января-02 февраля 2024 г., г. Санкт-Петербург.

3. Всероссийская научно-практическая конференция с международным участием «Искусственный интеллект: научные достижения и прикладные задачи». 04-05 декабря 2025 г., Югорский государственный университет, г. Ханты-Мансийск.

Личный вклад автора

Автором лично разработаны алгоритм внутрисхемного измерения частотных характеристик и алгоритм идентификации параметров линейного динамического звена по его частотной характеристике. Автором спроектирована архитектура модели, сгенерирован синтетический набор данных для обучения модели и выполнено обучение, проведены эксперименты по оценке качественных показателей разработанных алгоритмов.

Соответствие направлению подготовки

Работа соответствует направлению подготовки «27.04.03 – Системный анализ и управление» по следующим общепрофессиональным и профессиональным компетенциям ФГОС ВО и образовательного стандарта университета ИТМО:

1. ОПК-4. Способен осуществлять оценку эффективности технических систем методами системного анализа и управления.
2. ОПК-6. Способен применять методы математического, функционального и системного анализа для решения задач моделирования, исследования и синтеза автоматического управления техническими объектами.
3. ОПК-8. Способен формулировать содержательные и математические задачи исследований, выбирать методы исследований, системно анализировать, интерпретировать и представлять результаты исследований.
4. ПК-4. Способен формировать технические задания и участвовать в разработке аппаратных и (или) программных средств, экспертно-аналитических систем поддержки принятия оптимальных решений.

Объем и структура работы

Текст работы состоит из введения, 3 глав, заключения, списка из 16 использованных источников и 2 приложений. Основная часть работы изложена на 78 страницах машинописного текста, иллюстрируется 45 рисунками и содержит 4 таблицы.

1 ОБЗОР АЛГОРИТМОВ ИЗМЕРЕНИЯ ЧАСТОТНЫХ ХАРАКТЕРИСТИК И ИДЕНТИФИКАЦИИ ПАРАМЕТРОВ МАКРОМОДЕЛЕЙ ФИЗИЧЕСКИХ ОБЪЕКТОВ

1.1 Алгоритмы измерения частотных характеристик

1.1.1 Алгоритмы с моногармоническим возмущающим сигналом

Метод sine-sweep основан на последовательном возбуждении системы синусоидальными сигналами разной частоты и измерении установившегося отклика [1]. В отличие от широкополосных методов (PRBS, multisine), sine-sweep обеспечивает высокое отношение сигнал/шум на каждой частоте за счёт узкополосного анализа.

На вход системы (канал управления $d[n]$) подаётся синусоидальная последовательность:

$$p[n] = A \cdot \sin(2\pi f_k n T_s + \phi_0), \quad n = 0, 1, \dots, N_k - 1, \quad (1.1)$$

где:

- A – амплитуда возмущения (обычно 0.5%–5% от номинального D);
- f_k – текущая тестовая частота, $f_k \in [f_{\min}, f_{\max}]$;
- T_s – период дискретизации ($T_s = T_{sw}$ для синхронизации с ШИМ);
- N_k – число периодов усреднения на частоте f_k .

После переходного процесса (~ 3 – 5 постоянных времени системы) регистрируется выходной сигнал $y[n]$ (напряжение/ток). Для подавления шума и гармоник применяется когерентное усреднение по M периодам:

$$\bar{y}[m] = \frac{1}{M} \sum_{\ell=0}^{M-1} y[m + \ell \cdot N_{\text{per}}], \quad m = 0, 1, \dots, N_{\text{per}} - 1, \quad (1.2)$$

где $N_{\text{per}} = f_s / f_k$ – число отсчётов на период.

Амплитуда и фаза отклика извлекаются через корреляцию с опорными синусом и косинусом (метод квадратурной демодуляции):

$$Y_{\cos}(f_k) = \frac{2}{N} \sum_{n=0}^{N-1} \bar{y}[n] \cdot \cos(2\pi f_k n T_s), \quad (1.3)$$

$$Y_{\sin}(f_k) = \frac{2}{N} \sum_{n=0}^{N-1} \bar{y}[n] \cdot \sin(2\pi f_k n T_s), \quad (1.4)$$

$$G_{vd}(e^{j\omega_k T_s}) = \frac{Y_{\cos}(f_k) - jY_{\sin}(f_k)}{A}, \quad (1.5)$$

где $\omega_k = 2\pi f_k$. Формула (1.5) даёт оценку передаточной функции на частоте f_k .

Для минимизации нелинейных искажений и максимизации ОСШ амплитуда A может подбираться автоматически:

$$A_{\text{opt}} = \arg \min_A \left\{ \sigma_{\text{noise}}(A) \mid \frac{\|Y(f_k)\|}{\sigma_{\text{noise}}} \geq \text{SNR}_{\min} \right\}, \quad (1.6)$$

где σ_{noise} оценивается по «хвосту» импульсной характеристики или в полосе выше f_k .

1. Задать диапазон $[f_{\min}, f_{\max}]$ и закон развёртки:
 - **Линейный**: $f_{k+1} = f_k + \Delta f$;
 - **Логарифмический**: $f_{k+1} = f_k \cdot r$, $r = (f_{\max}/f_{\min})^{1/(K-1)}$.
2. Для каждой f_k :
 - 2.1. Сгенерировать $p[n]$ по (1.1);
 - 2.2. Дождаться установления ($\sim 3\tau_{\text{sys}}$);
 - 2.3. Собрать $y[n]$, применить (1.2);
 - 2.4. Вычислить $G_{vd}(e^{j\omega_k T_s})$ по (1.3)–(1.5);
 - 2.5. Проверить критерии сходимости (ОСШ, стабильность амплитуды).
3. Построить АЧХ/ФЧХ: $|G_{vd}|_{\text{dB}} = 20 \log_{10} |G_{vd}|$, $\angle G_{vd} = \arg(G_{vd})$.

Практические рекомендации для реализации

- **Синхронизация**: f_k должна быть кратной f_s/N_{per} для исключения утечки спектра.
- **Длительность измерения**: $T_{\text{meas}}(f_k) \geq \max\left(\frac{5}{f_k}, \frac{3}{\zeta \omega_n}\right)$, где ζ , ω_n – параметры доминирующей моды.

- **Подавление гармоник:** использовать оконные функции (Hann, Blackman) при вычислении (1.3)–(1.4), если N_{per} нецелое.
- **Адаптивная развёртка:** увеличивать время усреднения M на частотах с низким ОСШ или вблизи резонансов.

1.1.2 Алгоритмы с полигармоническим возмущающим сигналом

В качестве возбуждения используется псевдослучайная бинарная последовательность (PRBS) (рис. 1.1), близкая по спектру к белому шуму [2]. Сигнал вводится в управляющий контур преобразователя:

- В цикл управления скважностью (duty cycle);
- В опорные сигналы тока и напряжения.

Такое распределение гарантирует, что тестовый сигнал не будет подавлен регуляторами в широком частотном диапазоне, обеспечивая возбуждение системы на частотах выше и ниже полосы пропускания контуров управления [3].




Рисунок 1.1 – Алгоритм PRBS

В процессе возмущения измеряются мгновенные значения напряжения $v(t)$ и тока $i(t)$. С помощью быстрого преобразования Фурье (БПФ) получают

частотные спектры:

$$V(j\omega) = \mathcal{F}\{v(t)\}, \quad I(j\omega) = \mathcal{F}\{i(t)\}. \quad (1.7)$$

Импеданс подсистемы вычисляется как:

$$Z(j\omega) = \frac{V(j\omega)}{I(j\omega)}. \quad (1.8)$$

Для получения параметрической модели (передаточной функции) к непараметрической оценке применяется алгоритм наименьших квадратов, позволяющий аппроксимировать импеданс моделью заданного порядка (число полюсов/нулей).

Измеренные импедансы и передаточные функции используются для автоматической перенастройки локальных контроллеров преобразователей. Алгоритм адаптации работает в цикле:

1. **Возмущение:** Ввод PRBS-сигнала в контур управления.
2. **Сбор данных:** Запись откликов $v(t), i(t)$ в течение времени T_{IDENT} .
3. **Анализ:** БПФ-обработка и вычисление частотной характеристики $G(j\omega)$.
4. **Аппроксимация:** Подбор параметрической модели с заданным числом полюсов и нулей.
5. **Синтез:** Расчёт новых коэффициентов регулятора (например, методом Internal Model Control) с учётом пользовательских ограничений по устойчивости и быстродействию.
6. **Обновление:** Загрузка новых коэффициентов в цифровой контроллер (FPGA/DSP).

Полный цикл адаптации занимает время $T_{\text{TOTAL}} \propto T_{\text{IDENT}}$.

В методе минимизации крест-фактора полигармонических (multisine) сигналов на основе аппроксимации нормы Чебышёва [4], [5] полигармонический возбуждающий сигнал с заданным спектром мощности определяется в дискретной временной области как:

$$e(n, \phi) = \sum_{m=1}^M Z_m \sin(2\pi f_m T n + \phi_m), \quad n = 0, 1, \dots, N-1, \quad (1.9)$$

где Z_m , f_m и ϕ_m – амплитуда, частота и фаза m -й гармоники соответственно; M – число гармоник, T – период дискретизации, $\phi = [\phi_1, \dots, \phi_M]^\top \in \mathbb{R}^M$ – вектор оптимизируемых фаз.

Крест-фактор (Crest Factor, CF) характеризует отношение пикового значения сигнала к его среднеквадратичному (RMS) уровню:

$$CF(e) = \frac{\max_n |e(n, \phi)|}{\text{rms}(e(n, \phi))} = \frac{\|e(n, \phi)\|_\infty}{\text{rms}(e(n, \phi))}. \quad (1.10)$$

Поскольку амплитуды Z_m фиксируются на этапе проектирования, значение $\text{rms}(e)$ остаётся постоянным. Следовательно, задача минимизации CF эквивалентна минимизации нормы Чебышёва (L_∞ -нормы) сигнала:

$$\min_{\phi} \|e(n, \phi)\|_\infty. \quad (1.11)$$

Прямая градиентная оптимизация L_∞ -нормы затруднена из-за её негладкости (производная не существует в точках глобального максимума). В работе предлагается аппроксимировать L_∞ -норму пределом обобщённой L_p -нормы при $p \rightarrow \infty$:

$$L_p(e(n, \phi)) = \left(\frac{1}{N} \sum_{n=1}^N |e(n, \phi)|^p \right)^{1/p}. \quad (1.12)$$

Оптимизация выполняется итеративно по возрастающей последовательности чётных значений $p \in \{4, 8, 16, 32, \dots, p_{\max}\}$. Оптимальный вектор фаз $\phi^{(p)}$, полученный при текущем p , используется в качестве начального приближения для минимизации при следующем p , что обеспечивает плавную и устойчивую сходимость к решению.

Для каждого фиксированного p задача сводится к задаче нелинейного метода наименьших квадратов. Вводится вектор невязок $\mathbf{E} \in \mathbb{R}^N$:

$$\mathbf{E} = [e(1, \phi)^h, e(2, \phi)^h, \dots, e(N, \phi)^h]^\top, \quad h = \frac{p}{2}. \quad (1.13)$$

Целевая функция принимает вид $\Lambda_p(\phi) = \|\mathbf{E}\|^2$.

На s -й итерации алгоритма вычисляется матрица Якоби $\hat{\mathbf{J}}_s \in \mathbb{R}^{N \times M}$. Её элементы определяются аналитически:

$$[\hat{\mathbf{J}}_s]_{n,u} = \frac{\partial \hat{e}(n, \hat{\phi}_s)^h}{\partial \hat{\phi}_{u,s}} = h \hat{e}(n, \hat{\phi}_s)^{h-1} Z_u \cos(2\pi f_u T n + \hat{\phi}_{u,s}), \quad u = 1, \dots, M. \quad (1.14)$$

Шаг обновления вектора фаз вычисляется по классической формуле Левенберга-Марквардта:

$$\mathbf{d}_s = - \left(\hat{\mathbf{J}}_s^\top \hat{\mathbf{J}}_s + \lambda_s \mathbf{I} \right)^{-1} \hat{\mathbf{J}}_s^\top \hat{\mathbf{E}}_s, \quad (1.15)$$

где $\lambda_s > 0$ – адаптивный параметр регуляризации, предотвращающий вырожденность матрицы $\hat{\mathbf{J}}_s^\top \hat{\mathbf{J}}_s$ и обеспечивающий глобальную сходимость, а $\mathbf{I}$ – единичная матрица. Обновление фаз: $\hat{\phi}_{s+1} = \hat{\phi}_s + \mathbf{d}_s$.

Метод демонстрирует превосходство над аналитическими фазами Шрёдера и эвристическими подходами (напр., алгоритм ABC) по следующим показателям:

- **Эффективность:** Значительное снижение минимального, среднего и максимального CF при увеличении числа гармоник M .
- **Вычислительная скорость:** Численная сходимость L-алгоритма в десятки раз быстрее эволюционных методов при сопоставимом или лучшем качестве решения.
- **Идентификация FRF:** Сигналы с оптимизированным CF повышают отношение сигнал/шум (SNR) при измерении частотных характеристик.

1.1.3 Алгоритм с построением виртуальной модели объекта

Алгоритм измерения предполагает создание на основе данных динамических моделей объекта (цифровых двойников, Digital Twin, DT) [6]. Модель должна удовлетворять строгим требованиям: работа в реальном времени без переполнений процессора, учет крупных сигналов (large-signal), усреднение по периоду коммутации (switch-averaged) и возможность встраивания (embeddable) в стандартный цифровой контроллер без использования специализированных решателей. Предложено использовать архитектуру динамической нейронной сети NARX (Nonlinear AutoRegressive eXogenous, рис. 1.2).




Fig. 5. The boost converter topology with inductor ESR and a current source load.




Fig. 6. The boost converter digital twin model I/O.




Fig. 7. A detailed depiction of NARX-ANN used for boost converter modeling, with only one delay in each tapped delay line and three hidden neural layers having ten neurons each.

Рисунок 1.2 – Архитектура цифрового двойника из [6]

Статические полносвязные сети не подходят для моделирования систем дифференциальных уравнений, так как не имеют памяти. Архитектура NARX решает эту проблему за счет линий задержки на входах и выходах.

Поведение сети в замкнутом контуре (closed-loop) описывается уравнением:

$$\tilde{y}_k = F(\tilde{y}_{k-1}, \tilde{y}_{k-2}, \dots, \tilde{y}_{k-n}, u_k, u_{k-1}, \dots, u_{k-m}), \quad (1.16)$$

где u_k – вектор входов системы, $\tilde{y}_k$ – вектор прогнозируемых выходов модели, n и m – количество задержек для выходов и входов соответственно, $F(\cdot)$ – нелинейная функция, реализуемая статической ANN.

Для обучения используется разомкнутый контур (open-loop), где на входы задержки подаются истинные измеренные значения:

$$\tilde{y}_k = F(y_{k-1}, y_{k-2}, \dots, y_{k-n}, u_k, u_{k-1}, \dots, u_{k-m}). \quad (1.17)$$

Такой режим значительно повышает вычислительную эффективность и стабильность процесса оптимизации.

Внутренние нейроны используют нелинейную функцию активации. В работе применяется гиперболический тангенс:

$$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1. \quad (1.18)$$

Для обеспечения физической интерпретируемости и универсальности модели входы выбираются как управляющие и внешние возмущения, а выходы – как состояния системы. На примере повышающего (boost) преобразователя:

– **Вектор входов** u_k :

$$u_k = \begin{bmatrix} d[k] \\ v_g[k] \\ i_{\text{load}}[k] \end{bmatrix}, \quad (1.19)$$

где $d[k]$ – коэффициент заполнения, $v_g[k]$ – входное напряжение, $i_{\text{load}}[k]$ – ток нагрузки.

– **Вектор выходов** y_k :

$$y_k = \begin{bmatrix} i_L[k] \\ v_o[k] \end{bmatrix}, \quad (1.20)$$

где $i_L[k]$ — ток индуктивности, $v_o[k]$ — напряжение на выходном конденсаторе.

Обучающая выборка генерируется исключительно в среде компьютерного моделирования, что гарантирует отсутствие шумов измерений и исключает риски повреждения оборудования. Для корректного обучения крупной нелинейной модели данные должны покрывать:

- широкий частотный спектр (chirp-сигналы, белый шум) для идентификации динамических характеристик;
- медленные синусоиды и ступенчатые функции для охвата различных постоянных рабочих точек (DC operating points);
- большие амплитуды возмущений для выявления нелинейных эффектов (например, правого нуля в boost-преобразователе).

Сбор данных осуществляется на частоте коммутации (в примере $f_{sw} = 20$ кГц).

Структура сети и параметры обучения задаются до запуска алгоритма. В работе установлено:

- Глубина: 3 скрытых слоя по 10 нейронов в каждом (глубокая архитектура показала лучшую сходимость, чем мелкая);
- Задержки: $n = m = 1$ (соответствует дискретизации интегральных уравнений состояния первого порядка; увеличение задержек ухудшало аппроксимацию);
- Метрика качества – среднеквадратичная ошибка (MSE):

$$\text{MSE} = \frac{1}{N} \sum_{k=1}^N \epsilon_k^2 = \frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_k)^2. \quad (1.21)$$

- Алгоритм оптимизации: Levenberg-Marquardt (гибрид градиентного спуска и метода Ньютона);
- Обновление весов (в базовой формулировке градиентного спуска):

$$w_{ij}^{\text{new}} = w_{ij}^{\text{old}} - \eta \left. \frac{\partial}{\partial w_{ij}} (\text{MSE}) \right|_{w_{ij}=w_{ij}^{\text{old}}}, \quad (1.22)$$

где η – скорость обучения. Максимальное число эпох – 1000.

Для гарантии надежности цифрового двойника применяется двухэтапная проверка:

1. **Валидация во временной области:** тестирование на независимом наборе данных с экстремальными переходными процессами и широкополосным шумом. Модель точно отслеживает как стационарные режимы, так и быстрые динамические изменения.
2. **Валидация в частотной области:** обученная NARX-сеть линеаризуется вокруг заданной рабочей точки, и снимается малосигнальная частотная характеристика (АЧХ/ФЧХ). Результаты сравниваются с аналитическими передаточными функциями преобразователя. Например, для boost-топологии передаточная функция «управление-выходное напряжение» имеет вид:

$$\frac{\hat{v}_o(s)}{\hat{d}(s)} = \frac{D'}{s^2 LC + s R_s C + D'^2}, \quad (1.23)$$

где $D' = 1 - D$, R_s – эквивалентное последовательное сопротивление (ESR) индуктивности. Совпадение частотных характеристик подтверждает, что

сеть выучила физические законы системы, а не переобучилась на временные ряды.

Представленный метод позволяет создавать высокоточные, быстродействующие и легко встраиваемые цифровые двойники силовых преобразователей. Использование динамической NARX-архитектуры с обучением в разомкнутом контуре на синтетических данных обеспечивает корректную аппроксимацию нелинейной динамики без итерационных решателей. Двойная валидация гарантирует надежность модели для задач мониторинга, диагностики, прогнозирования остаточного ресурса (PHM) и программно-аппаратного моделирования (HIL).

1.2 Алгоритмы идентификации параметров

1.2.1 Vector Fitting

Метод *Vector Fitting* (VF) [7] предназначен для построения редуцированных моделей линейных стационарных систем по дискретным выборкам их частотной характеристики. Пусть заданы $\bar{k}$ измерений передаточной функции:

$$H_k = H(j\omega_k), \quad k = 1, \dots, \bar{k}. \quad (1.24)$$

Требуется найти рациональную аппроксимацию $\tilde{H}(s)$, минимизирующую среднеквадратичную ошибку:

$$e^2 = \frac{1}{\bar{k}} \sum_{k=1}^{\bar{k}} |H_k - \tilde{H}(j\omega_k)|^2. \quad (1.25)$$

Прямое решение этой нелинейной задачи наименьших квадратов (НКМ) затруднено из-за неизвестных коэффициентов в знаменателе, что приводит к плохой обусловленности (матрицы Вандермонда) и риску попадания в локальные минимумы.

VF заменяет полиномиальный базис s^n на базис частичных дробей с фиксированными на текущей итерации полюсами $p_n^{(i-1)}$. Аппроксимант и весовая

функция записываются в виде:

$$\tilde{H}^{(i)}(s) = r_0^{(i)} + \sum_{n=1}^{\bar{n}} \frac{r_n^{(i)}}{s - p_n^{(i-1)}}, \quad (1.26)$$

$$w^{(i)}(s) = 1 + \sum_{n=1}^{\bar{n}} \frac{w_n^{(i)}}{s - p_n^{(i-1)}}, \quad (1.27)$$

где $\bar{n}$ – порядок модели. Вводится линеаризованный функционал ошибки:

$$(e_{SK}^{(i)})^2 = \frac{1}{\bar{k}} \sum_{k=1}^{\bar{k}} \left| H_k w^{(i)}(j\omega_k) - \tilde{H}^{(i)}(j\omega_k) \right|^2. \quad (1.28)$$

В отличие от классического метода Санатханана-Кёрнера, весовая функция $w^{(i)}(s)$ применяется неявно через перенос полюсов на каждой итерации, что радикально улучшает обусловленность системы уравнений.

Алгоритм выполняется циклически ($i = 1, 2, \dots$):

1. **Инициализация полюсов.** Выбираются начальные полюса $p_n^{(0)}$ с малой отрицательной вещественной частью, равномерно распределённые по диапазону частот $[\omega_1, \omega_{\bar{k}}]$:

$$p_n^{(0)} = \begin{cases} (-\alpha + j) \frac{\omega_{\bar{k}}}{\bar{n}/2} n, & n = 1, \dots, \bar{n}/2, \\ (p_{n-\bar{n}/2}^{(0)})^*, & n = \bar{n}/2 + 1, \dots, \bar{n}, \end{cases} \quad (1.29)$$

где обычно $\alpha = 0.01$.

2. **Решение линейной системы НКМ.** Минимизация $(e_{SK}^{(i)})^2$ сводится к решению:

$$\begin{bmatrix} \Phi_0^{(i)} & -\mathbf{D}_H \Phi_1^{(i)} \end{bmatrix} \begin{bmatrix} \mathbf{c}_H^{(i)} \\ \mathbf{c}_w^{(i)} \end{bmatrix} = \mathbf{V}_H, \quad (1.30)$$

где $\Phi_0^{(i)}, \Phi_1^{(i)}$ содержат значения базисных функций $\frac{1}{j\omega_k - p_n^{(i-1)}}$, $\mathbf{D}_H = \text{diag}(H_1, \dots, H_{\bar{k}})$, $\mathbf{V}_H = [H_1, \dots, H_{\bar{k}}]^T$, а $\mathbf{c}_H^{(i)}, \mathbf{c}_w^{(i)}$ – векторы неизвестных вычетов и весовых коэффициентов. Система решается через QR-разложение.

3. **Обновление полюсов.** Новые полюса $p_n^{(i)}$ вычисляются как нули функции $w^{(i)}(s)$, что эквивалентно задаче на собственные значения:

$$\{p_n^{(i)}\} = \text{eig} \left(\mathbf{A}^{(i-1)} - \mathbf{b}_w (\mathbf{c}_w^{(i)})^T \right), \quad (1.31)$$

где $\mathbf{A}^{(i-1)} = \text{diag}(p_1^{(i-1)}, \dots, p_{\bar{n}}^{(i-1)})$, $\mathbf{b}_w = [1, \dots, 1]^T$.

4. **Проверка сходимости.** Итерации останавливаются, когда:

$$\max_k \left| w^{(i)}(j\omega_k) - 1 \right| \leq \epsilon_w. \quad (1.32)$$

После выполнения условия фиксируются полюса $p_n^{(i)}$ и решается окончательная задача НКМ только для вычетов:

$$\Phi_0^{(i+1)} \mathbf{c}_H^{(i+1)} = \mathbf{V}_H, \quad (1.33)$$

что гарантирует минимизацию исходной ошибки e^2 .

Для систем с $\bar{m}$ входами и $\bar{q}$ выходами измеряемые данные представляют собой матрицы $\mathbf{H}_k \in \mathbb{C}^{\bar{q} \times \bar{m}}$. Модель строится с *общими полюсами* для всех элементов передаточной матрицы:

$$\tilde{\mathbf{H}}(s) = \mathbf{R}_0 + \sum_{n=1}^{\bar{n}} \frac{\mathbf{R}_n}{s - p_n}, \quad (1.34)$$

где $\mathbf{R}_n \in \mathbb{C}^{\bar{q} \times \bar{m}}$. Минимизируется норма Фробениуса ошибки. Для снижения вычислительной сложности применяется *Fast VF*, использующий блочные QR-разложения и распараллеливание по каналам.

Для реальных систем полюса и вычеты должны быть вещественными или образовывать комплексно-сопряжённые пары. Это обеспечивается явным разделением базиса на вещественную и комплексную части.

Чтобы гарантировать устойчивость и причинность модели, на шаге обновления полюсов применяется принудительная стабилизация:

$$p_n^{(i)} \leftarrow \begin{cases} p_n^{(i)}, & \text{Re}\{p_n^{(i)}\} < 0, \\ -\text{Re}\{p_n^{(i)}\} + j \text{Im}\{p_n^{(i)}\}, & \text{Re}\{p_n^{(i)}\} > 0. \end{cases} \quad (1.35)$$

При отсутствии шума в данных это не снижает точность, но делает модель пригодной для моделирования в области времени.

Полученная модель в форме «полюса/нули» преобразуется к пространству состояний:

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t), \\ \mathbf{y}(t) = \mathbf{C}\mathbf{x}(t) + \mathbf{D}\mathbf{u}(t), \end{cases} \quad (1.36)$$

где $\mathbf{D} = \mathbf{R}_0$, а блочно-диагональная матрица $\mathbf{A}$ и блочные $\mathbf{B}, \mathbf{C}$ формируются из SVD-разложений матриц вычетов $\mathbf{R}_n = \mathbf{U}_n \boldsymbol{\Sigma}_n \mathbf{V}_n^H$. Такая реализация гарантирует минимальный порядок системы и исключает неуправляемые/ненаблюдаемые состояния.

Таким образом, метод Vector Fitting преобразует нелинейную задачу рациональной аппроксимации в последовательность линейных задач НКМ за счёт неявного весового перевзвешивания и переноса полюсов. Метод обладает высокой скоростью сходимости (обычно 4-6 итераций), численной устойчивостью и легко масштабируется на многоканальные системы. Существуют расширения алгоритма для работы во временной области (z -VF), учёта шумов (Relaxed VF), параметрического моделирования и распределённых систем с задержками.

1.2.2 Алгоритмы на основе CNN-архитектур

В моделировании эквивалентными электрическими схемами через измерение комплексного импеданса Z в диапазоне частот $f = [f_1, f_2, \dots, f_M]$, импеданс описывается функцией от параметров компонентов:

$$Z = F(f; p_1, p_2, \dots, p_N), \quad (1.37)$$

где $\mathbf{p} = [p_1, \dots, p_N]$ – вектор параметров (сопротивления, ёмкости, индуктивности, элементы постоянной фазы и т.д.).

Традиционный метод комплексных нелинейных наименьших квадратов (CNLS), реализуемый через алгоритм Левенберга-Марквардта, требует задания начального приближения $\mathbf{p}^{(0)}$. Сильная нелинейность модели и наличие шума часто приводят к сходимости в локальные минимумы или расходимости. Для решения проблемы авторы предлагают использовать сверточную

нейронную сеть (CNN) для автоматической генерации качественного начального приближения (рисунок 1.3) [8].




Рисунок 1.3 – Алгоритм идентификации параметров с предсказанием начальных приближений нейросетевой моделью

Для обучения регрессионной модели генерируется синтетический набор данных. Параметры $\mathbf{p}$ выбираются случайно в физически обоснованном диапазоне, после чего с помощью симулятора рассчитываются соответствующие спектры импеданса. Входные данные нормализуются и представляются в виде 4 каналов: действительная часть (Z'), мнимая часть (Z''), модуль ($|Z|$) и фаза ($\angle Z$).

Архитектура сети включает:

- Три слоя Conv1D с количеством фильтров 128, 256, 128 и длинами ядер 4, 5, 4 соответственно.
- Слой Flatten.
- Слой Gaussian Noise со стандартным отклонением $\sigma = 0.05$ для повышения обобщающей способности.
- Три полносвязных (Dense) слоя размерности 256, 64 и p (число параметров схемы).

Во всех слоях используется функция активации ReLU:

$$\text{ReLU}(x) = \max(0, x). \quad (1.38)$$

Обучение проводится с помощью оптимизатора Adam (learning rate = 0.001). Функция потерь определяется как среднеквадратичная ошибка (MSE) между предсказанными сетью параметрами p'_n и истинными параметрами p_n :

$$\mathcal{L}_{\text{CNN}} = \frac{1}{N} \sum_{n=1}^N (p'_n - p_n)^2. \quad (1.39)$$

Обученная модель выступает в роли этапа предфиттинга. Процедура состоит из следующих шагов:

1. Измеренный спектр импеданса нормализуется и подаётся на вход CNN.
2. Сеть генерирует начальное приближение параметров $\mathbf{p}_{\text{init}}$.
3. $\mathbf{p}_{\text{init}}$ передаётся в алгоритм CNLS (Левенберг-Марквардт) для точной оптимизации.

CNLS минимизирует ошибку между измеренными значениями z_m и модельными Z_m на каждой частоте:

$$\text{MSE}_{\text{CNLS}} = \frac{1}{M} \sum_{m=1}^M (z_m - Z_m)^2. \quad (1.40)$$

Благодаря качественному начальному приближению, алгоритм быстро сходится к глобальному минимуму без ручного вмешательства.

Для валидации метода используется средняя абсолютная процентная ошибка (MAPE), вычисляемая по всем частотным точкам:

$$\text{MAPE} = \frac{1}{M} \sum_{m=1}^M \frac{|z_m - Z_m|}{|z_m|}. \quad (1.41)$$

Фиттинг считается успешным, если $\text{MAPE} < 0.01$. Эксперименты на открытом наборе данных показали, что предложенный метод повышает успешность фиттинга до 87.5% (на 25% выше по сравнению с CNLS со случайными начальными значениями и стохастическими методами), при этом сокращая общее время вычислений и обеспечивая стабильную сходимость.

1.2.3 Архитектуры для задач сегментации

Метод [9] основан на архитектуре «энкодер-декодер» (encoder-decoder), адаптированной для работы с высокоразрешающими изображениями (до 4608×3456 пикселей). Сеть выполняет бинарную посимвольную классификацию: каждому пикселю присваивается значение 0 (фон) или 1 (трещина).

В качестве экстрактора признаков используется архитектура **ConvNeXt** (версия Tiny), предобученная на наборе данных ImageNet (рисунок 1.4). ConvNeXt состоит из 4 стадий, каждая из которых включает свёрточные блоки с увеличением глубины каналов и уменьшением пространственного разрешения. Использование предобученных весов реализует стратегию трансферного обучения, позволяя сети эффективно извлекать низкоуровневые и семантические признаки даже на ограниченном доменном наборе данных.




Рисунок 1.4 – Архитектура автоэнкодера для сегментации «узких» объектов

Декодировщик состоит из 6 уровней и модифицирует архитектуру [10]. Основные компоненты:

- **Модули внимания:** На каждом уровне применяются пространственные и каналные слои squeeze-and-excitation, которые адаптивно взвешивают карты признаков, усиливая релевантные области.

- **Skip-connections:** Карты признаков декодировщика конкатенируются с соответствующими картами кодировщика для восстановления пространственной информации, потерянной при даунсэмплинге.
- **Остаточные блоки:** После конкатенации и свёртки 3×3 применяются residual-блоки с batch normalization и функцией активации ReLU.
- **Финальный слой:** Поточечная свёртка с сигмоидальной активацией формирует итоговую карту сегментации со значениями в диапазоне $[0, 1]$.

Прямая подача полного изображения в сеть требует ~ 189 ГБ ОЗУ, что превышает возможности стандартных GPU (40 ГБ). Для решения проблемы применяется патч-ориентированный подход:

- Изображение разбивается на непересекающиеся патчи размером 512×512 пикселей.
- Каждый патч обрабатывается сетью независимо.
- Полученные карты сегментации склеиваются (stitching) для формирования глобальной карты всего изображения.

Эксперименты показали, что уменьшение размера патча (например, до 128×128) снижает точность, так как сеть теряет глобальный контекст, необходимый для отличия трещин от *crack-like features* (стыки, тени, коррозия).

Стандартной функцией потерь для сегментации трещин является сумма бинарной кросс-энтропии (BCE) и Dice-потери, которая компенсирует сильный класс-имбаланс (трещины занимают малую площадь):

$$L_{\text{BCE}}(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)], \quad (1.42)$$

$$L_{\text{Dice}}(y, \hat{y}) = 1 - \frac{\sum_{i=1}^N y_i \cdot \hat{y}_i + \epsilon}{\sum_{i=1}^N y_i + \sum_{i=1}^N \hat{y}_i + \epsilon}, \quad (1.43)$$

$$L(y, \hat{y}) = L_{\text{BCE}}(y, \hat{y}) + L_{\text{Dice}}(y, \hat{y}), \quad (1.44)$$

где N – число пикселей, $y_i \in [0, 1]$ и $\hat{y}_i \in \{0, 1\}$ – значения i -го пикселя в эталонной и предсказанной картах соответственно, $\epsilon = 1$.

Проблема фона: Для патчей без трещин $\sum_{i=1}^N y_i = 0$. В этом случае $L_{\text{Dice}} \approx 1$ при любом $\sum \hat{y}_i \gg \epsilon$, что делает функцию нечувствительной к ложноположительным срабатываниям на фоне.

«Loss Inversion»: Для фоновых патчей вводится операция инверсии меток:

$$L_{\text{inversion}}(y, \hat{y}) = \begin{cases} L(\text{inv}(y), \text{inv}(\hat{y})), & \text{если } \sum_{i=1}^N y_i = 0, \\ L(y, \hat{y}), & \text{иначе,} \end{cases} \quad (1.45)$$

где $\text{inv}(z) = -z + 1$. При обучении на фоне сеть оптимизируется как «сегментатор фона», что позволяет корректно штрафовать ошибки и использовать в обучающей выборке до 90% фоновых патчей без попадания в локальный минимум «all-white segmentation maps».

Для стабилизации градиентов и ускорения сходимости на промежуточных уровнях декодировщика (уровни 2-5) формируются дополнительные карты сегментации. Итоговая функция потерь вычисляется как взвешенная сумма:

$$L_{\text{total}}(y, \hat{y}) = L_{\text{target}}(y, \hat{y}) + \sum_{i=0}^n w_i L_{\text{companion}}^i(y, \hat{y}_i), \quad (1.46)$$

где n – число вспомогательных карт, $w_i = 1$, а $\hat{y}_i$ масштабируются до размера входного изображения методом ближайших соседей и проходят через сигмоиду.

- **Оптимизатор:** ADAMW с $\lambda_{\text{initial}} = 0.001$ и weight decay $1 \cdot 10^{-5}$.
- **Экспоненциальное затухание LR:** $\lambda = \lambda_{\text{initial}} \cdot \gamma^e$, где $\gamma = 0.99$, e – номер эпохи.
- **Поэтапное затухание LR (ConvNeXt):** $\lambda_{\text{stage}} = \lambda \cdot k^{N+1-n}$, где $k = 0.7$, $N = 4$ (число стадий), n — номер стадии.
- **Аугментация:** Флипы, повороты $\{0^\circ, 90^\circ, 180^\circ, 270^\circ\}$, изменение яркости/контраста/насыщения (75–125%), сдвиг оттенка ($\pm 10\%$), аддитивный шум, случайное масштабирование и зум.
- **Баланс патчей:** Оптимальное соотношение трещина/фон для стандартной потери $\approx 70/30$. При использовании $L_{\text{inversion}}$ возможно обучение на полном наборе ($\sim 6.5/93.5$).

2 РАЗРАБОТКА АЛГОРИТМОВ ВНУТРИСХЕМНОГО ИЗМЕРЕНИЯ ЧАСТОТНЫХ ХАРАКТЕРИСТИК

Система управления вторичного источника электропитания представлена в виде обобщенной системы аналого-цифрового преобразования и цифровой обработки сигналов с воздействием на объект управления посредством импульсной модуляции с постоянным периодом T_d (рисунок 2.1). Период T_d выполнения операций в системе соответствует базовой частоте дискретного регулирования $f_d = 1/T_d$.




Рисунок 2.1 – Рассматриваемая система

В канал управления системы аддитивно инжектируется сигнал в виде дискретной последовательности $z[n]$. Откликом системы являются два континуальных сигнала: $x_c(t)$, $y_c(t)$. Система преобразует континуальные сигналы $x_c(t)$, $y_c(t)$ в дискретные последовательности $x[n]$, $y[n]$. Преобразование осуществляется посредством дискретизации:

$$\begin{aligned} x[n] &= x_c(nT_s), \\ y[n] &= y_c(nT_s), \end{aligned} \tag{2.1}$$

где T_s – период дискретизации, $T_s \geq T_d$.

Коэффициенты разложения дискретных последовательностей

$$x[n] = \frac{1}{N} \sum_{l=0}^{N-1} X[l] e^{j \frac{2\pi}{N} l \cdot n},$$

$$y[n] = \frac{1}{N} \sum_{l=0}^{N-1} Y[l] e^{j \frac{2\pi}{N} l \cdot n}$$

определяются по N последовательным отсчетам дискретных последовательностей $x[n]$, $y[n]$:

$$X[l] = \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} n \cdot l},$$

$$Y[l] = \sum_{n=0}^{N-1} y[n] e^{-j \frac{2\pi}{N} n \cdot l}.$$
(2.2)

Коэффициенты $X[l]$, $Y[l] \in \mathbb{C}$ представляют собой дискретные периодические последовательности с периодом N , где $N \in \mathbb{N}$ – длина массивов-откликов (независимая переменная, $N \geq N_{\min}$). Во время измерения отклики $x[n]$, $y[n]$ хранятся в буфере, выделенном под внутрисхемное измерение в памяти встроенной системы управления. Размер буфера ограничен $2N_{\max}$ значениями. Таким образом, $N_{\min} \leq N \leq N_{\max}$.

При условии, что измерительное окно длительностью T_h вмещает целое количество N периодов дискретизации T_s ($T_h = N \cdot T_s$), дискретные последовательности $X[l]$, $Y[l]$ на отрезке $l \in [0; N-1]$ длины N содержат коэффициенты разложения $x[n]$, $y[n]$ в диапазоне частот $f \in [0, f_s/2]$ с шагом по частоте $\Delta f = 1/T_h$. Составляющим с частотой f_h соответствуют $X[l]$, $Y[l]$ при $l = 1$, а с частотой $f_s/2$ – при $l = \lfloor (N-1)/2 \rfloor$.

В работе рассматриваются алгоритмы измерения частотных характеристик, основанные на воздействии на систему дискретной последовательностью $z[n]$ моногармонического типа с амплитудой Z и частотой $\omega_z = 2\pi f_z$:

$$z[n] = Z \cdot \cos(n \cdot \omega_z \cdot T_d).$$

В ходе измерения период инжектируемого сигнала $T_z = 1/f_z$, а в общем случае и амплитуда Z , последовательно изменяются. В серии из K -измерений каждому k -му измерению, $k \in \{1, \dots, K\}$, соответствует пара параметров $T_z^{(k)}$, $Z^{(k)}$, следовательно, и набор дискретных последовательностей $x^{(k)}[n]$, $y^{(k)}[n]$, а также соответствующих им коэффициентов $X^{(k)}[l]$, $Y^{(k)}[l]$.

Под частотной характеристикой понимается набор из K пар значений $f_z^{(k)}$, $H^{(k)}$, где в каждом k -ом измерении

$$H^{(k)} = \frac{Y^{(k)}[L^{(k)}]}{X^{(k)}[L^{(k)}]} = |H^{(k)}| e^{j\angle H^{(k)}}, \quad (2.3)$$

где $L^{(k)} \in \mathbb{N}_{>0}$ – номер гармоники, равный количеству целых периодов инжектируемого сигнала $T_z^{(k)}$ на измерительном окне $T_h^{(k)}$:

$$L^{(k)} = \left\lfloor \frac{T_h^{(k)}}{T_z^{(k)}} \right\rfloor.$$

Пары значений $f_z^{(k)}$, $|H^{(k)}|$ и $f_z^{(k)}$, $\angle H^{(k)}$ образуют амплитудно-частотную и фазо-частотную характеристики, соответственно.

$$\begin{aligned} |H^{(k)}| &= \frac{|Y^{(k)}[L^{(k)}]|}{|X^{(k)}[L^{(k)}]|}, \\ \angle H^{(k)} &= \angle Y^{(k)}[L^{(k)}] - \angle X^{(k)}[L^{(k)}]. \end{aligned} \quad (2.4)$$

Продолжительность измерения частотной характеристики:

$$t_{\text{meas}} = K \cdot t_{\text{trans}} + \sum_{k=1}^K T_h^{(k)} + 2K \frac{N \cdot B}{S}, \quad (2.5)$$

где t_{trans} – длительность установления переходных процессов, B – размер данных на одно значение передаваемой дискретной последовательности, S – скорость передачи данных по интерфейсу связи.

Например, при измерении частотной характеристики в диапазоне частот от 10 Гц до 49 кГц с количеством частот $K = 300$, длительностью установления переходных процессов $t_{\text{trans}} = 20$ мс, длиной дискретной последова-

тельности $N = 1000$, размером данных $B = 8$ байт и скоростью передачи данных $S=115\,200$ бит в секунду, продолжительность измерения оценивается в 6,0 минут, из которых 5,5 минут приходится на обмен данными со встроенной системой управления. В связи с этим уменьшение объема передаваемых данных является приоритетной мерой в задаче сокращения суммарной продолжительности измерения частотной характеристики.

2.1 Алгоритм с изменяемой длительностью измерительного окна, равной периоду инжектируемого сигнала

Принципиальные особенности рассматриваемого алгоритма:

- Длительность измерительного окна T_h равна периоду инжектируемого сигнала T_z .
- Длина N последовательностей $x[n]$, $y[n]$, по которым вычисляются коэффициенты разложения в выражении (2.2), изменяется пропорционально периоду инжектируемого сигнала T_z .
- Период дискретизации T_s одинаков для всех значений периода инжектируемого сигнала T_z и равен периоду выполнения операций в системе T_d .

Таким образом, в серии из K измерений для каждого значения периода инжектируемого сигнала $T_z^{(k)}$, $k \in \{1, \dots, K\}$ (рисунок 2.2), выполняется:

$$T_h^{(k)} = T_z^{(k)} = N^{(k)} \cdot T_s = N^{(k)} \cdot T_d.$$

Длина массивов-откликов пропорциональна периоду инжектируемого сигнала

$$N^{(k)} = \frac{T_z^{(k)}}{T_s}, \quad (2.6)$$

что представляет одно из ключевых ограничений рассматриваемого алгоритма в области измерений низких частот.

В связи с тем, что длительность измерительного окна $T_h^{(k)}$ равна периоду инжектируемого сигнала $T_z^{(k)}$, составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)}[l]$, $Y^{(k)}[l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (2.3) при $L^{(k)} = 1$.




Рисунок 2.2 – Параметры в алгоритме с изменяемой длительностью измерительного окна, равной периоду инжектируемого сигнала

Изложенному алгоритму измерения характерно следующее:

1. Максимально возможный период инжектируемого сигнала T_z соответствует максимальному значению измерительного окна T_h , которое ограничено только параметром $N_{\max}$.
2. Шаг приращения периода инжектируемого сигнала T_z (разрешающая способность): $\Delta T_z = T_d$.
3. Длина N каждого массива-отклика $x[n]$, $y[n]$ не является постоянной, но пропорциональна периоду инжектируемого сигнала T_z (выражение (2.6)).
4. В случае $N_{\min} = 3$ максимально возможная частота f_z ограничена сверху значением $f_d/3$.
5. Потенциальные значения частот f_z инжектируемого сигнала неравномерно распределены на интервале $f \in (0; f_d/2)$ возможных значений:

- На полуинтервале $f \in [f_d/10; f_d/2)$ частота f_z может принимать значения всего из 8-ми возможных:
 $f_z = (f_d/10, f_d/9, \dots, f_d/3)$.
- На полуинтервале $f \in [f_d/100; f_d/10)$ – 90 возможных значений:
 $f_z = (f_d/100, f_d/99, \dots, f_d/11)$.
- На интервале $f \in (0; f_d/100)$ – сколь угодно много значений, ограниченных параметром $N_{\max}$.

2.2 Алгоритм с изменяемой длительностью измерительного окна, равной периоду инжектируемого сигнала, и децимацией

Рассматриваемый алгоритм представляет собой модификацию алгоритма 2.1 в части периода дискретизации T_s – период дискретизации пропорционален периоду инжектируемого сигнала T_z . Ввиду плавающего T_s длина N последовательностей $x[n]$, $y[n]$, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменна для всех значений периода инжектируемого сигнала T_z . Условие кратности периоду выполнения операций в системе T_d остается.

Постоянство N при изменении периода инжектируемого сигнала T_z обеспечивается децимацией (прореживанием) последовательностей $x'[n]$, $y'[n]$ с коэффициентом децимации $M^{(k)} \in \mathbb{N}$:

$$\begin{aligned} x^{(k)}[n] &= x'^{(k)}[n \cdot M^{(k)}] = x_c^{(k)}(n \cdot M^{(k)} \cdot T_d), \\ y^{(k)}[n] &= y'^{(k)}[n \cdot M^{(k)}] = y_c^{(k)}(n \cdot M^{(k)} \cdot T_d), \end{aligned}$$

Переменными $x'[n]$, $y'[n]$ обозначены последовательности, формируемые в результате дискретизации откликов $x_c(t)$, $y_c(t)$ непосредственно с периодом выполнения операций в системе T_d .

Таким образом, в серии из K измерений для каждого значения периода инжектируемого сигнала $T_z^{(k)}$, $k \in \{1, \dots, K\}$ (рисунок 2.3), выполняется:

$$T_h^{(k)} = T_z^{(k)} = N^{(k)} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}.$$




Рисунок 2.3 – Параметры в алгоритме с изменяемой длительностью измерительного окна, равной периоду инжектируемого сигнала, и децимацией

В связи с тем, что так же, как и в алгоритме 2.1, длительность измерительного окна $T_h^{(k)}$ равна периоду инжектируемого сигнала $T_z^{(k)}$, составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (2.3) при $L^{(k)} = 1$. **Принципиальное отличие от алгоритма 2.1** связано с потенциально меньшей длиной N массивов-откликов вследствие децимации.

Изложенному алгоритму измерения характерно следующее:

1. Максимально возможный период инжектируемого сигнала T_z соответствует максимальному значению измерительного окна T_h , но уже не ограничен параметром $N_{\max}$, т.к. длина N каждого массива-отклика

$x[n]$, $y[n]$ неизменна (не зависит от периода инжектируемого сигнала T_z).

2. Шаг приращения периода инжектируемого сигнала T_z (разрешающая способность) в N раз больше по сравнению с алгоритмом 2.1 ($\Delta T_z = N \cdot T_d$).
3. Грубый шаг приращения периода обуславливает еще более неравномерное распределение частот. Например, в диапазоне частот $f \in [f_d/100; f_d/10]$ при $N = 10$ частота инжектируемого сигнала f_z может принимать значения всего из 10-ти возможных:
 $f_z = (f_d/100, f_d/90, \dots, f_d/10)$.

2.3 Алгоритм с неизменной длительностью измерительного окна, кратной периоду инжектируемого сигнала

Принципиальные особенности рассматриваемого алгоритма:

- Длительность измерительного окна T_h неизменна и равна наибольшему среди K значений периодов инжектируемого сигнала T_z .
- Длина N последовательностей $x[n]$, $y[n]$, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменна для всех значений периода инжектируемого сигнала T_z .
- Период дискретизации T_s одинаков для всех значений периода инжектируемого сигнала T_z и кратен периоду выполнения операций в системе T_d .

Математическая обработка в соответствии с (2.2) накладывает ограничение на период T_z инжектируемого сигнала – требуется, чтобы измерительное окно T_h вмещало целое число $L \in \mathbb{N}$ периодов T_z .

Таким образом, в серии из K измерений для каждого значения периода инжектируемого сигнала $T_z^{(k)}$, $k \in \{1, \dots, K\}$ (рисунок 2.4), выполняется:

$$T_h = L^{(k)} \cdot T_z^{(k)} = N \cdot T_s, \quad (2.7)$$

причем $T_h = \text{const}$.




Рисунок 2.4 – Параметры в алгоритме с неизменной длительностью измерительного окна, кратной периоду инжектируемого сигнала

Частота инжектируемого сигнала потенциально принимает значения

$$f_z^{(k)} = L^{(k)} \frac{1}{T_h} = L^{(k)} \Delta f_z,$$

где Δf_z – шаг приращения частоты инжектируемого сигнала. Составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ выражения (2.3) при $l = L^{(k)}$.

Поскольку $\Delta f_z = const$, потенциальные значения частот инжектируемого сигнала f_z линейно распределены на интервале возможных значений, что является главной отличительной особенностью алгоритма по сравнению с алгоритмами 2.1, 2.2.

Изложенному алгоритму измерения характерно следующее:

1. Шаг приращения частоты инжектируемого сигнала f_z (разрешающая способность): $\Delta f_z = 1/T_h$.
2. В случае $N_{\min} = 3$ максимально возможная частота f_z ограничена сверху значением $f_d/3$.
3. Длина N каждого массива-отклика $x[n]$, $y[n]$ неизменна (не зависит от периода инжектируемого сигнала T_z).
4. Максимально возможный период инжектируемого сигнала T_z ограничен только параметром $N_{\max}$.
5. Период T_z инжектируемого сигнала потенциально принимает значения от $T_z^{\min} = 3T_s$ до $T_z^{\max} = T_h$, ограниченные только условием $T_h/T_s \in \mathbb{N}$.

Возможна модификация алгоритма, допускающая увеличение периода дискретизации (посредством децимации) для отдельных продолжительных значений периодов инжектируемого сигнала T_z , в которых длина N при исходном периоде дискретизации T_s превышает ограничение $N_{\max}$:

$$T_s \rightarrow T_s^{(k)} = \begin{cases} T_d, & \text{если } T_z^{(k)}/T_d \leq N_{\max}, \\ M^{(k)} \cdot T_d, & \text{иначе.} \end{cases}$$

При этом длительность измерительного окна T_h остается неизменной и соответствующей выражению (2.7).

2.4 Алгоритм с изменяемой длительностью измерительного окна, кратной периоду инжектируемого сигнала

Принципиальные отличия рассматриваемого алгоритма от алгоритма 2.3 заключаются в том, что длительность измерительного окна T_h и период дискретизации T_s – плавающие параметры, соответствующие каждому отдельному значению периода инжектируемого сигнала T_z . Остаются следующие ограничения:

- Возможные значения длительности измерительного окна T_h кратны периоду инжектируемого сигнала T_z .
- Период дискретизации T_s кратен периоду выполнения операций в системе T_d .

Эти ограничения сводятся к плавающим параметрам $L, M \in \mathbb{N}_{>0}$, в дополнение к плавающей длине последовательностей $N \in \mathbb{N}_{>0}$, что так же **отличается от алгоритма 2.3**.

Таким образом, в серии из K измерений для каждого значения периода инжектируемого сигнала $T_z^{(k)}$, $k \in \{1, \dots, K\}$ (рисунок 2.5), выполняется:

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)} = N^{(k)} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}} = L^{(k)} \cdot R^{(k)} \cdot T_d, \quad (2.8)$$

где $R^{(k)} \in \mathbb{R}_{>0}$ – отношение периода инжектируемого сигнала $T_z^{(k)}$ к периоду выполнения операций в системе T_d .




Рисунок 2.5 – Параметры в алгоритме с изменяемой длительностью измерительного окна, кратной периоду инжектируемого сигнала

Аналогично алгоритму 2.3, соотношение между периодом инжектируемого сигнала и периодом дискретизации может принимать дробные значения. В совокупности с изменяемой длительностью измерительного окна это обеспечивает на интервале $f \in (0; f_d/2)$ сколь угодно много потенциальных значений частот f_z инжектируемого сигнала, что **является главной отличительной особенностью алгоритма**.

Из равенства (2.8)

$$L^{(k)} = \frac{N^{(k)} \cdot M^{(k)}}{R^{(k)}}. \quad (2.9)$$

В связи с тем, что частота инжектируемого сигнала кратна частоте первой гармоники в спектре:

$$f_z^{(k)} = L^{(k)} \cdot f_h^{(k)} = \frac{L^{(k)}}{T_h^{(k)}},$$

и ограничена половиной частоты дискретизации:

$$f_z^{(k)} < \frac{f_s^{(k)}}{2} \quad \rightarrow \quad \frac{L^{(k)}}{T_h^{(k)}} < \frac{1}{2} \cdot \frac{f_d}{M^{(k)}},$$

множитель $L^{(k)}$ ограничен диапазоном

$$1 \leq L^{(k)} < \frac{N^{(k)}}{2},$$

что, с учетом (2.9), накладывает ограничение на коэффициент децимации

$$1 \leq M^{(k)} < \frac{R^{(k)}}{2}.$$

Таким образом, для каждой k -й заданной частоты f_z задача сводится к поиску наборов $\mathbf{s}_{(p)} \in \mathbb{N}_{>0}^3$ натуральных чисел $N_{(p)}, M_{(p)}, L_{(p)}$, при которых частота инжектируемого сигнала $f_{z(p)}$

$$f_{z(p)} = \frac{L_{(p)}}{N_{(p)} \cdot M_{(p)}} f_d$$

отличается от желаемой частоты f_z в пределах заданного отклонения $\Delta\epsilon_f^*$:

$$|f_{z(p)} - f_z| = \Delta\epsilon_{f(p)} \leq \Delta\epsilon_f^*,$$

при ограничениях

$$N_{\min} \leq N_{(p)} \leq N_{\max}, \quad 1 \leq M_{(p)} < R/2.$$

Оптимальным считается такой набор $\mathbf{s}_{(p^*)}$, в котором параметр $N_{(p)}$ минимален среди всех наборов $\mathbf{s}_{(p)}$, отвечающих условию

$$\Delta\epsilon_{f(p)} \leq \Delta\epsilon_f^*. \quad (2.10)$$

В случае, когда ни один набор параметров $\mathbf{s}_{(p)}$ не удовлетворяет условию (2.10), оптимальным считается набор, соответствующий минимальному отклонению $\Delta\epsilon_{f(p)}$. Таким образом, согласно выражению (2.5), минимум длины массивов-откликов N обеспечивает сокращение продолжительности измерения частотной характеристики.

2.5 Процедура поиска оптимального набора параметров

Поиск оптимального набора параметров – натуральных чисел N, M, L – требуется для каждой частоты инжектируемого сигнала f_z из исходного набора частот $f_z^{(k)}$, $k \in [1; K]$. В результате определяются такие K наборов параметров, при котором частотная характеристика измеряется алгоритмом 2.4 за минимальное время с отклонением от заданной частоты порядка $\Delta\epsilon_f^*$.

Входные данные:

- Частота инжектируемого сигнала: f_z .
- Максимальное абсолютное отклонение от заданной частоты f_z инжектируемого сигнала: $\Delta\epsilon_f^*$.
- Частота выполнения операций в системе: f_d .
- Максимальная длина последовательностей $x[n]$, $y[n]$ на интервале измерения: $N_{\max}$.
- Минимальная длина последовательностей $x[n]$, $y[n]$ на интервале измерения: $N_{\min}$.

Выходные данные:

- Длина дискретных последовательностей $x[n]$, $y[n]$ на интервале измерения: N .
- Коэффициент децимации: M .
- Коэффициент кратности длительности измерительного окна T_h к периоду инжектируемого сигнала T_z : L .

Последовательность действий:

1. Вычисляется отношение между периодом инжектируемого сигнала и периодом выполнения операций в системе:

$$R = \frac{f_d}{f_z}.$$

2. Вычисляется максимально возможное значение коэффициента децимации:

$$M_{\max} = \left\lfloor \frac{R}{2} \right\rfloor.$$

3. В цикле $M \in [1; M_{\max}]$:

- 3.1. Вычисляются всевозможные значения

$$L = \left\lfloor \frac{M \cdot N}{R} \right\rfloor$$

для $N \in [N_{\min}; N_{\max}]$, с округлением L до 1 при $L < 1$.

- 3.2. Значения L используются для вычисления всевозможных приближений к начальному значению коэффициента R :

$$R' = \frac{M \cdot N}{L}.$$

- 3.3. Значения R' используются для вычисления всевозможных приближений к исходному значению частоты f_z :

$$f'_z = \frac{f_d}{R'},$$

и соответствующих отклонений

$$\Delta \epsilon_f = \left| f'_z - f_z \right|.$$

- 3.4. Из набора значений f'_z исключаются те, для которых $\Delta\epsilon_f > \Delta\epsilon_f^*$.
- 3.5. Среди оставшихся f'_z определяется значение, соответствующее минимальному N . Формируется набор $s_{(p^*)}$ соответствующих параметров N, M, L .
- 3.6. Если нет значений f'_z , удовлетворяющих условию $\epsilon_f < \epsilon_f^*$, выбирается набор параметров N, M, L , соответствующий наименьшему отклонению $\Delta\epsilon_f$.
4. Среди найденных наборов параметров, соответствующих разным значениям M , рассматриваются наборы, удовлетворяющие условию $\Delta\epsilon_f \leq \Delta\epsilon_f^*$ и среди них выбирается набор с минимальным N .
5. Если нет наборов параметров, удовлетворяющих условию $\Delta\epsilon_f < \Delta\epsilon_f^*$, выбирается набор параметров, соответствующий наименьшему отклонению $\Delta\epsilon_f$.
6. Формируется итоговый набор параметров $s_{(p^*)} = (N_{(p^*)}, M_{(p^*)}, L_{(p^*)})$.

Примечания:

1. Отклонение от заданной частоты f_z инжектируемого сигнала допустимо задавать в относительных единицах ϵ_f^* , с последующим пересчетом в абсолютное значение

$$\Delta\epsilon_f^* = \epsilon_f^* \cdot f_z.$$

В таком случае на вход алгоритма возможно задать общее для всех частот относительное отклонение ϵ_f^* . Абсолютные значения отклонения $\Delta\epsilon_f^{*(k)}$ сформируются в соответствии с частотами $f_z^{(k)}$.

2. Максимальная длина последовательностей $N_{\max}$ определяется размером памяти, доступной в буфере встраиваемой системы управления, зарезервированном под внутрисхемное измерение частотных характеристик.

Листинг программы 2.1 – Программа поиска оптимального набора параметров

```
1 import numpy as np
2
3 def find_multipliers(fz: float, fd: float, err_rel_ref: float,
4                     Nmin: int, Nmax: int):
5
6     R = fd / fz
7     if R < 2:
8         raise ValueError("fz must be < fd/2 for a valid solution.")
9     err_abs_ref = fz * err_rel_ref
10    Mmax = int(R / 2)
11    N_vals = np.arange(Nmin, Nmax + 1, dtype=float)
12    N_arr = np.empty(Mmax, dtype=np.int64)
13    M_arr = np.empty(Mmax, dtype=np.int64)
14    L_arr = np.empty(Mmax, dtype=np.int64)
15    fz_approx_arr = np.empty(Mmax)
16    err_abs_arr = np.empty(Mmax)
17    tol_flag_arr = np.empty(Mmax, dtype=bool)
18    for mdx, M in enumerate(range(1, Mmax+1)):
19        L = np.floor(M * N_vals / R)
20        np.maximum(L, 1, out=L)
21        R_approx = M * N_vals / L
22        fz_approx = fd / R_approx
23        err_abs = np.abs(fz - fz_approx)
24        valid_idx = np.nonzero(err_abs <= err_abs_ref)[0]
25        if valid_idx.size > 0:
26            pos = valid_idx[0]
27            tol_flag_arr[mdx] = True
28        else:
29            pos = np.argmin(err_abs)
30            tol_flag_arr[mdx] = False
31        N_arr[mdx] = int(N_vals[pos])
32        M_arr[mdx] = M
33        L_arr[mdx] = int(L[pos])
34        fz_approx_arr[mdx] = fz_approx[pos]
35        err_abs_arr[mdx] = err_abs[pos]
36    if np.any(tol_flag_arr):
37        valid_mdx = np.nonzero(tol_flag_arr)[0]
38        best_mdx = valid_mdx[np.argmin(N_arr[valid_mdx])]
39    else:
40        best_mdx = np.argmin(err_abs_arr)
41
42    return (int(N_arr[best_mdx]),
43            int(M_arr[best_mdx]),
44            int(L_arr[best_mdx]))
```

Пример.

Заданы: $f_d = 100$ кГц, $N_{\min} = 10$, $N_{\max} = 1214$.

Определить: Набор параметров N , M , L для измерения на инжектируемой частоте $f_z = 22,1$ кГц с относительным отклонением до $0,1\%$ ($\epsilon_f^* = 0,001$).

Коэффициент соотношения между периодом инжектируемого сигнала и периодом выполнения операций в системе:

$$R = \frac{f_d}{f_z} = \frac{100\,000}{22\,100} = 4,525.$$

Максимально возможное значение коэффициента децимации:

$$M_{\max} = \left\lfloor \frac{R}{2} \right\rfloor = 2.$$

Оптимальный набор параметров: $N = 43$, $M = 2$, $L = 19$.

Соответствующее приближение к начальному значению коэффициента R :

$$R' = \frac{M \cdot N}{\lfloor L \rfloor} = \frac{2 \cdot 43}{19} = 4,526.$$

Соответствующее приближение к исходному значению частоты f_z :

$$f'_z = \frac{L}{M \cdot N} f_d = \frac{19}{2 \cdot 43} 100\,000 = 22\,093,023 \text{ Гц.}$$

Относительное отклонение частоты

$$\epsilon_f = \frac{|f'_z - f_z|}{f_z} = 0,000\,315$$

не превышает заданного ограничения $\epsilon_f^* = 0,001$.

Таким образом, для того, чтобы произвести измерение на частоте инжектируемого сигнала с отклонением до $0,1\%$, достаточно измерить $N = 43$ значений сигналов-откликов на $L = 19$ периодах инжектируемого сигнала. Период выборки при этом должен быть в $M = 2$ раза больше периода выполнения операций в системе.

2.6 Результаты измерений

Оценка качественных характеристик разработанного алгоритма внутрисхемного измерения частотных характеристик выполнена в серии экспериментов по измерению частотных характеристик динамических звеньев системы автоматического регулирования источника питания (Приложение Б). Численная оценка отличий произведена по среднеквадратичной ошибке

$$\text{RMSE} = \sqrt{\frac{1}{K} \sum_{k=1}^K |H_{\text{AP}}^{(k)} - H_{\text{DP}}^{(k)}|^2}, \quad (2.11)$$

вычисленной по комплексным коэффициентам передачи (2.3). Значения амплитуд и фаз комплексного коэффициента передачи $H_{\text{DP}}^{(k)}$ предварительно интерполированы на частоты характеристики $H_{\text{AP}}^{(k)}$.

Среднеквадратичная ошибка (2.11) использована в расчетах следующих метрик:

- Относительная среднеквадратичная ошибка (Relative Root Mean Square Error):

$$\text{RRMSE} = \frac{\text{RMSE}}{\sqrt{\frac{1}{K} \sum_{k=1}^K |H_{\text{AP}}^{(k)}|^2 + \varepsilon}}. \quad (2.12)$$

- Нормализованная среднеквадратичная ошибка (Normalized Root Mean Square Error):

$$\text{NRMSE} = \frac{\text{RMSE}}{\max(|H_{\text{AP}}^{(k)}|) - \min(|H_{\text{AP}}^{(k)}|) + \varepsilon}. \quad (2.13)$$

Частотные характеристики измерены в диапазоне частот от 10 Гц до 49 кГц. Измерения выполнены двумя способами: сертифицированным измерителем частотных характеристик AP300 и разработанным алгоритмом внутрисхемного измерения 2.4 (Digital Points: $f_d = 100$ кГц, $N_{\min} = 60$, $N_{\max} = 1214$, $\varepsilon_f^* = 0,001$). Прибор и алгоритм настроены на одинаковую продолжительность измерений – порядка 120 секунд на характеристику в $K = 300$ частот. Результаты в формулах (2.11)–(2.13) и на рисунках 2.6–2.10 обозначены «AP» и «DP», соответственно.




Рисунок 2.6 – Частотные характеристики звена преобразования тока в напряжение




Рисунок 2.7 – Частотные характеристики звена преобразования тока в напряжение с задержкой по времени




Рисунок 2.8 – Частотные характеристики ПИ-регулятора контура регулирования тока




Рисунок 2.9 – Частотные характеристики ПИД-регулятора контура регулирования тока




Рисунок 2.10 – Частотные характеристики ПИ-регулятора контура стабилизации напряжения

Метрики отклонения измеренных внутрисхемно частотных характеристик от эталонных в среднем не превышают 25% (таблица 2.1).

Таблица 2.1 – Результаты измерения частотных характеристик

	Частотные характеристики	RRMSE	NRMSE
1.	Звено преобр. тока в напряжение	0,0356	0,0144
2.	Звено преобр. тока в напряжение с задержкой	0,0307	0,0123
3.	ПИ-регулятор контура регулирования тока	0,5574	0,1381
4.	ПИД-регулятор контура регулирования тока	0,2557	0,0650
5.	ПИ-регулятор контура стабилизации напряжения	0,3255	0,0839
	СРЕДНЕЕ	0,2410	0,0627

3 РАЗРАБОТКА АЛГОРИТМОВ ИДЕНТИФИКАЦИИ ПАРАМЕТРОВ МАКРОМОДЕЛЕЙ

Поставленную задачу по идентификации параметров макромодели линейного звена системы автоматического регулирования предложено решать посредством идентификации параметров полюсов и нулей передаточной функции этого звена с последующим пересчетом в физические параметры, при необходимости. Разработана нейросетевая модель, реализующая по частотным характеристикам детектирование количества полюсов/нулей и областей частот, на которых они расположены. Частотная характеристика представлена в виде массива амплитуд, в децибелах, и массива углов, в градусах. Координаты полюсов/нулей вычисляются как центры детектируемых областей частот. Пересчет в физические параметры, при необходимости, осуществляется по математической модели самого звена, определяющей связь между физическими параметрами и полюсами/нулями передаточной функции. Перечисленные этапы составляют полный алгоритм идентификации параметров.

3.1 Архитектура модели сегментации

Модель основана на архитектуре энкодер-декодер (рисунок 3.1) [11], состоящей из N уровней и выполняющей преобразование C_{in} -канального тензора длины L_1 в C_{out} -канальный тензор той же длины:

$$\mathbf{Y} : \mathbb{R}^{C_{in} \times L_1} \mapsto \mathbb{R}^{C_{out} \times L_1}.$$




Рисунок 3.1 – Блок-схема архитектуры модели сегментации

Преобразование Y выполняется в 3 основных этапа:

- Кодирование в скрытое (латентное) пространство (CNN-энкодер):

$$\mathbf{E} : \mathbb{R}^{F_0 \times L_1} \mapsto \mathbb{R}^{F_N \times L_N}.$$

- Выделение наиболее информативных признаков в скрытом пространстве («Bottleneck»):

$$\mathbf{T} : \mathbb{R}^{F_N \times L_N} \mapsto \mathbb{R}^{F_{N+1} \times L_{N+1}} \mapsto \mathbb{R}^{F_{N+1} \times L_{N+1}}.$$

- Декодирование из скрытого пространства (CNN-декодер):

$$\mathbf{D} : \mathbb{R}^{F_{N+1} \times L_{N+1}} \mapsto \mathbb{R}^{F_1 \times L_1}.$$

Операция свертки на входе модели

$$\mathbb{R}^{C_{in} \times L_1} \mapsto \mathbb{R}^{F_0 \times L_1}$$

выполняет функцию предварительной фильтрации данных и имеет увеличенный размер ядра.

Операция свертки на входе «Bottleneck» предназначена для проекции числа каналов

$$\mathbb{R}^{F_N \times L_{N+1}} \mapsto \mathbb{R}^{F_{N+1} \times L_{N+1}},$$

и включает в себя нормализацию и активацию.

Операции свертки на выходе модели выполняют аналогичную функцию проекции числа каналов, но уже без нормализации и активации:

$$\begin{aligned} \mathbf{d}_n \in \mathbb{R}^{F_n \times L_n} &\mapsto \mathbf{d}'_n \in \mathbb{R}^{C_{\text{out}} \times L_n}, \\ \mathbf{d}'_n &= \mathbf{W}_n^{\text{DS}} * \mathbf{d}_n, \end{aligned}$$

где «*» – операция свертки, $\mathbf{W}_n^{\text{DS}} \in \mathbb{R}^{C_{\text{out}} \times F_n \times KS}$, KS – размер ядра («Kernel Size»). Количество каналов C_{out} соответствует количеству детектируемых объектов. Выходные тензоры $\mathbf{d}'_n$ представляют собой логиты.

Выходы глубокого супервизирования («Deep Supervision» [12]) с промежуточных слоев декодера $\mathbf{d}'_n$, $n > 1$, используются только на этапе обучения модели с целью повышения глубины обучения.

Выделение бинарных масок $\hat{y}_i$, $i \in \{1, \dots, L_1\}$, осуществляется преобразованием логитов d_i основного выхода модели $\mathbf{d}'_1$:

$$d_i \mapsto p_i = \frac{1}{1 + e^{-d_i}} \mapsto \hat{y}_i = \mathbb{I}(p_i > \tau), \quad (3.1)$$

где $\forall i: \hat{y}_i \in \{0, 1\}$,

$$\mathbb{I}(p_i \geq \tau) = \begin{cases} 1, & p_i \geq \tau, \\ 0, & p_i < \tau, \end{cases}$$

τ – пороговый уровень, $\tau \in [0; 1]$.

Количество обучаемых параметров построенной модели составляет порядка 5,3 М.

3.1.1 Энкодер

Энкодер преобразует входные данные в латентное (скрытое) пространство уменьшенной размерности. В созданной реализации энкодер состоит из каскада N сверточных базовых блоков. Заложена «residual»-архитектура

базового блока по типу «pre-activation» (рисунок 3.2), обеспечивающая улучшенный градиентный поток для ускорения сходимости при обучении [13].




Рисунок 3.2 – Блок-схема базового блока свертки в энкодере и декодере

Каждый n -й базовый блок, $n \in \{1, \dots, N\}$, выполняет последовательно две свертки с ядрами $\mathbf{W}_n^{1\text{enc}} \in \mathbb{R}^{F_{n-1} \times F_n \times KS}$, $\mathbf{W}_n^{2\text{enc}} \in \mathbb{R}^{F_n \times F_n \times KS}$:

$$\begin{aligned} \mathbf{z}_n^{1\text{enc}} &= \mathbf{W}_n^{1\text{enc}} * \sigma \left(\mathcal{N}_n^{1\text{enc}} (\mathbf{e}_{n-1}) \right), \\ \mathbf{z}_n^{2\text{enc}} &= \mathbf{W}_n^{2\text{enc}} * \sigma \left(\mathcal{N}_n^{2\text{enc}} (\mathbf{z}_n^{1\text{enc}}) \right), \\ \mathbf{e}_n &= \mathbf{z}_n^{2\text{enc}} \oplus \mathbf{s}_n^{\text{enc}}, \end{aligned}$$

где « $\oplus$ » – поэлементная сумма.

Обходная связь («skip-connection») $\mathbf{s}_n^{\text{enc}}$ базового блока проецируется по числу каналов («фичей»), при необходимости:

$$\mathbf{s}_n^{\text{enc}} = \begin{cases} \mathbf{W}_n^{\text{enc}} * \mathbf{e}_{n-1}, & \text{если } F_{n-1} \neq F_n, \\ \mathbf{e}_{n-1}, & \text{иначе,} \end{cases}$$

где ядро проекции $\mathbf{W}_n^{\text{enc}} \in \mathbb{R}^{F_n \times F_{n-1} \times KS}$.

Между слоями энкодера длина тензора уменьшается в 2 раза алгоритмом «nn.MaxPool1d»:

$$\mathbf{e}_n \rightarrow \mathbf{e}_n \downarrow_2.$$

Регуляризация во время обучения выполняется алгоритмом «nn.Dropout1d», выполняемым на выходе второй свертки.

Таким образом, в энкодере производится последовательное увеличение числа каналов («фичей») с одновременным уменьшением длины тензора.

3.1.2 «Bottleneck»

«Bottleneck» реализован на основе трансформера (рисунок 3.3), с предварительной проекцией числа каналов на входе.




Рисунок 3.3 – Блок-схема алгоритма «Bottleneck»

На вход «bottleneck» поступает тензор $\mathbf{e}_N \in \mathbb{R}^{F_N \times L_N}$ с выхода энкодера. Тензор преобразуется к $\mathbf{b}_{in} \in \mathbb{R}^{F_{N+1} \times L_{N+1}}$:

$$\mathbf{b}_{in} = \sigma \left(\mathcal{N}^P \left(\mathbf{W}^P * \mathbf{e}_N \downarrow_2 \right) \right),$$

где $\mathbf{W}^P \in \mathbb{R}^{F_{N+1} \times F_N \times KS}$, и к «permute»-формату $\mathbf{b}_{in,perm} \in \mathbb{R}^{L_{N+1} \times F_{N+1}}$:

$$\mathbf{b}_{in} \rightarrow \mathcal{N}^H(\mathbf{b}_{in}) \rightarrow \mathbf{b}_{in,perm}$$

для совместимости с популярной реализацией алгоритма «Multi-Head Self-Attention» (MHSA) [14]. Тензор разбивается на h -«голов» с количеством ка-

налов $d_k = F_{N+1}/h$ в каждой голове. Результаты вычисления h -«голов»

$$\mathbf{H}_m = \text{Softmax} \left(\frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_k}} \right) \mathbf{V}_m,$$

$\mathbf{H}_m \in \mathbb{R}^{L_{N+1} \times d_k}$, $m \in \{1, \dots, h\}$, объединяются в единый тензор

$$\mathbf{MH}_{\text{perm}} = \text{cat}(\mathbf{H}_1, \dots, \mathbf{H}_h) \mathbf{W}^O,$$

где « $\text{cat}(\cdot)$ » – операция слияния по каналам, $\mathbf{W}^O \in \mathbb{R}^{F_{N+1} \times F_{N+1}}$.

$\mathbf{MH}_{\text{perm}} \in \mathbb{R}^{L_{N+1} \times F_{N+1}}$ получается того же размера, что и $\mathbf{b}_{\text{in.perm}}$.

Входные переменные алгоритма MHSA $\mathbf{Q}_m, \mathbf{K}_m, \mathbf{V}_m \in \mathbb{R}^{L_{N+1} \times d_k}$ формируются в результате линейной проекции входа

$$\mathbf{Q}_m = \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^Q,$$

$$\mathbf{K}_m = \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^K,$$

$$\mathbf{V}_m = \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^V,$$

через соответствующие матрицы

$$\mathbf{W}_m^Q, \mathbf{W}_m^K, \mathbf{W}_m^V \in \mathbb{R}^{F_{N+1} \times d_k}.$$

Результирующим выходом алгоритма MHSA является сумма полученного тензора со входным тензором:

$$\mathbf{b}_{\text{attn}} = \mathbf{b}_{\text{in}} \oplus \mathbf{MH},$$

для чего форма представления тензора предварительно преобразуется обратно ($\mathbf{MH}_{\text{perm}} \rightarrow \mathbf{MH}$).

После алгоритма MHSA выполняется нормализация данных для их последующей обработки полносвязными слоями («Multi-Layer Perceptron», MLP). Реализованы два «Feed-Forward»-слоя поканальной обработки с промежуточным увеличением скрытого пространства в r раз:

$$\mathbf{z}^{\text{MLP}} = \mathbf{W}^{2\text{MLP}} \sigma \left(\mathbf{W}^{1\text{MLP}} \mathcal{N}^{\text{MLP}} (\mathbf{b}_{\text{attn}}) \right),$$

$$\mathbf{b}_{\text{out}} = \mathbf{b}_{\text{attn}} \oplus \mathbf{z}^{\text{MLP}},$$

$$\mathbf{W}^{1\text{MLP}} \in \mathbb{R}^{(r \cdot F_{N+1}) \times F_{N+1}},$$

$$\mathbf{W}^{2\text{MLP}} \in \mathbb{R}^{F_{N+1} \times (r \cdot F_{N+1})}.$$

Регуляризация во время обучения выполняется алгоритмом «nn.Dropout» после каждого «Feed-Forward»-слоя.

3.1.3 Декодер

Декодер последовательно приближает данные скрытого пространства к изначальной длине L_1 и числу каналов F_1 .

«Residual»-архитектура базового блока декодера в точности повторяет блок энкодера (рисунок 3.2):

$$\begin{aligned} \mathbf{z}_n^{1\text{dec}} &= \mathbf{W}_n^{1\text{dec}} * \sigma \left(\mathcal{N}^{1\text{dec}} (\tilde{\mathbf{d}}_n) \right), \\ \mathbf{z}_n^{2\text{dec}} &= \mathbf{W}_n^{2\text{dec}} * \sigma \left(\mathcal{N}^{2\text{dec}} (\mathbf{z}_n^{1\text{dec}}) \right), \\ \mathbf{d}_{n-1} &= \mathbf{z}_n^{2\text{dec}} \oplus \mathbf{s}_n^{\text{dec}}, \end{aligned}$$

где $\mathbf{W}_n^{1\text{dec}} \in \mathbb{R}^{F_n \times 2F_n \times KS}$, $\mathbf{W}_n^{2\text{dec}} \in \mathbb{R}^{F_n \times F_n \times KS}$.

В отличие от энкодера, входной тензор каждого слоя декодера $\tilde{\mathbf{d}}_n \in \mathbb{R}^{2F_n \times L_n}$ формируется слиянием каналов преобразованных тензоров энкодера $\tilde{\mathbf{e}}_n \in \mathbb{R}^{F_n \times L_n}$ и декодера $\mathbf{g}_n \in \mathbb{R}^{F_n \times L_n}$ соответствующих уровней:

$$\tilde{\mathbf{d}}_n = \text{cat} (\tilde{\mathbf{e}}_n, \mathbf{g}_n).$$

Преобразование тензора декодера аналогично преобразованию, выполняемому на входе «Bottleneck», только с предварительным увеличением длины тензора в 2 раза алгоритмом «nn.Upsample»:

$$\mathbf{g}_n = \sigma \left(\mathcal{N}^{\text{dec}} \left(\mathbf{W}^{\text{dec}} * \mathbf{d}_{n+1} \uparrow_2 \right) \right),$$

где $\mathbf{W}^{\text{dec}} \in \mathbb{R}^{F_n \times F_{n+1} \times KS}$.

Тензор $\tilde{\mathbf{e}}_n$ формируется «взвешиванием» выхода слоя n энкодера на соответствующую одноканальную карту признаков (карту «позиционного внима-

ния») $\psi_n(\mathbf{e}_n, \mathbf{g}_n) \in \mathbb{R}^{1 \times L_n}$, формирующуюся алгоритмом [15] (рисунок 3.4):

$$\tilde{\mathbf{e}}_n = \mathbf{e}_n \odot \psi_n(\mathbf{e}_n, \mathbf{g}_n),$$

$$\psi_n(\mathbf{e}_n, \mathbf{g}_n) = \sigma_{\text{Sigmoid}}(\mathcal{N}^\Psi(\mathbf{W}^\Psi * \sigma_{\text{ReLU}}(\mathbf{E}_n \oplus \mathbf{G}_n))),$$

$$\mathbf{E}_n = \mathcal{N}^E(\mathbf{W}^E * \mathbf{e}_n), \quad \mathbf{G}_n = \mathcal{N}^G(\mathbf{W}^G * \mathbf{g}_n),$$

$$\mathbf{W}^E, \mathbf{W}^G \in \mathbb{R}^{F_n/2 \times F_n \times KS}, \quad \mathbf{W}^\Psi \in \mathbb{R}^{1 \times F_n/2 \times KS},$$

где « $\odot$ » – операция поэлементного умножения.




Рисунок 3.4 – Блок-схема «взвешивания» обходных связей

3.2 Предварительная обработка данных

Диапазон изменения входных данных составляет до 6 порядков – от -60 дБ до +60 дБ. При этом, изменения характеристик в отдельных участках частот могут составлять единицы децибел. В связи с этим, типовые нормировки вида *norm/std*, *min/max* делают модель нечувствительной к малым изменениям характеристики.

Принято решение перейти от абсолютных значений амплитуды и фазы к наклонам этих характеристик. Наклоны представлены в $C_{in} = 4$ каналах. Длина каждого канала приводится к $L_1 = 512$ путем интерполяции. Массивы должны соответствовать логарифмическому масштабу по частоте. В примере на рисунках 3.5 и 3.6 на последних 4 графиках изображены данные, подаваемые на вход модели сегментации.




Рисунок 3.5 – Пример разбиения данных на 4 канала




Рисунок 3.6 – Пример разбиения данных на 4 канала, с аугментациями

3.3 Обучение модели сегментации

3.3.1 Набор данных

Обучение модели выполнено на синтетическом наборе данных, состоящем из «Train», «Val» и «Test»-коллекций csv-таблиц частотных характеристик и json-файлов с координатами полюсов/нулей [16].

Тренировочный набор данных представлен частотными характеристиками, соответствующими 72 случайным комбинациям полюсов/нулей. Каждой такой комбинации сгенерированы 500 вариантов координат полюсов/нулей и границ диапазона частот. Частотные характеристики вычислены по передаточной функции обобщенной модели линейного динамического звена:

$$H(s) = G \frac{\prod_{m=1}^M \left(1 + \frac{s}{\omega_{z(m)}} \right)}{s^K \prod_{n=1}^N \left(1 + \frac{s}{\omega_{p(n)}} \right)} e^{-s \cdot t_{\text{delay}}},$$

где

- G – пропорциональный коэффициент, $G \in \mathbb{R}$;
- t_{delay} – задержка времени, $t_{\text{delay}} > 0$;
- K – количество интеграторов, $K \in \mathbb{N}$;
- $\omega_{z(m)}$ – частоты нулей передаточной функции $H(s)$ в количестве M ;
- $\omega_{p(n)}$ – частоты полюсов передаточной функции $H(s)$ в количестве N .

Полюса и нули вещественные, причем как положительного, так и отрицательного знака: $\omega_{z(m)} \in \mathbb{R}$, $\omega_{p(n)} \in \mathbb{R}$.

В тренировочном наборе данных параметры G , t_{delay} заданы константами для последующего изменения аугментациями в ходе обучения. В валидационном и тестовом наборах данных параметры G , t_{delay} сгенерированы случайным образом. В тестовом наборе дополнительно частотные характеристики приближены к реалистичным данным путем введения шума с нормальным распределением.

Общий размер тренировочного набора данных – $72 \times 500 = 36\,000$ примеров. Размеры валидационного и тестового наборов – 14 400 и 7200 примеров, соответственно.

3.3.2 Функция потерь

Обучение производилось путем минимизации комбинированной функции потерь, вычисляемой по всем N выходам декодера (глубокое супервизирование):

$$\mathcal{L} = \frac{1}{w} \sum_{n=1}^N \left[w_n \left(w^{\text{BCE}} \cdot \mathcal{L}_n^{\text{BCE}} + w^{\text{Dice}} \cdot \mathcal{L}_n^{\text{Dice}} \right) \right], \quad (3.2)$$

где:

- $\mathcal{L}^{\text{BCE}}$ – бинарная перекрестная энтропия;
- $\mathcal{L}^{\text{Dice}}$ – функция потерь Дайса;
- $w^{\text{BCE}}, w^{\text{Dice}}$ – весовые коэффициенты функций потерь.

Бинарная перекрестная энтропия

$$\mathcal{L}^{\text{BCE}} = -\frac{1}{L} \sum_{i=1}^L \left[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i) \right],$$

где:

- y_i – истинные («ground truth») значения маски, $y_i \in \{0, 1\}$;
- p_i – вероятности (3.1), соответствующие логитам с выхода декодера, $p_i \in [0; 1]$,

и функция потерь Дайса

$$\mathcal{L}^{\text{Dice}} = 1 - 2 \frac{\sum_{i=1}^L d_i \cdot y_i}{\sum_{i=1}^L d_i + \sum_{i=1}^L y_i + \epsilon},$$

вычисляются по каждому каналу $\{1, C_{\text{out}}\}$; в функцию потерь (3.2) входят уже усредненные по каналам значения.

Весовые коэффициенты w_n выходов декодера заданы по возрастанию значений, так чтобы основному выходу модели соответствовало значение 1,0; нормированы к сумме $w = \sum_{n=1}^N w_n$:

$$\sum_{n=1}^N \frac{w_n}{w} = 1.$$

3.3.3 Метрики

В качестве основного показателя качества детекции модели использован коэффициент Дайса:

$$\text{Dice} = 2 \frac{\sum_{i=1}^L \hat{y}_i \cdot y_i}{\sum_{i=1}^L \hat{y}_i + \sum_{i=1}^L y_i + \epsilon},$$

где:

- $\hat{y}_i$ – предсказания модели, $\hat{y}_i \in \{0, 1\}$;
- y_i – истинные («ground truth») значения маски, $y_i \in \{0, 1\}$.

В качестве вспомогательной метрики применен коэффициент Жаккара:

$$\text{IoU} = \frac{\sum_{i=1}^L \hat{y}_i \cdot y_i}{\sum_{i=1}^L \hat{y}_i + \sum_{i=1}^L y_i - \sum_{i=1}^L \hat{y}_i \cdot y_i + \epsilon}.$$

Обучение выполнено на **NVIDIA GeForce RTX3060** (12 ГБ), torch=2.6.0, CUDA=12.6, cuDNN=9.5.1 при следующих гиперпараметрах:

- Количество уровней энкодера: $N = 4$.
- Количество каналов («фичей»):
 $F_0 = 32, F_1 = 32, F_2 = 64, F_3 = 128, F_4 = 256, F_5 = 512$.
- Количество «голов» алгоритма MHSA: $h = 8$.
- Весовые коэффициенты функции ошибки:
 $w^{\text{BCE}} = 0,5, w^{\text{Dice}} = 0,5$.
- Весовые коэффициенты глубокого супервизирования:
 $w_1 = 1,00, w_2 = 0,50, w_3 = 0,25, w_4 = 0,125$.
- Размер батча: 360.
- Решатель: «Adam».

Прогресс обучения оценивался по коэффициенту Дайса на валидации.

Таблица 3.1 – Метрики результирующие

		Dice	IoU	Комментарий
1.	Train	0,8131	0,7446	Случайные аугментации: G, t_{delay} , шумы.
2.	Val	0,8981	0,8448	Нет аугментаций.*
3.	Test	0,8163	0,7485	Нет аугментаций.**

* Набор данных изначально сформирован с разными G, t_{delay} .

** Набор данных изначально сформирован с разными G, t_{delay} и дополнен шумами.

3.4 Результаты детекции объектов и идентификации параметров

3.4.1 Результаты детекции объектов и идентификации параметров в случайных примерах из тестового набора данных

Маски, полученные на выходе модели при обработке случайных примеров из тестового набора данных, полностью перекрывают истинные координаты полюсов/нулей (рисунки 3.7–3.15). Ошибка идентификации параметров не превышает 15% (таблица 3.2).

Исключение, и в то же время интересный пример, представляет собой пример на рисунке 3.9. В области высоких частот ввиду близкого расположения левого полюса и левого нуля, обладающих взаимно компенсирующим действием, наблюдается ошибка детектирования и идентификации: левый полюс не детектирован; частота левого нуля идентифицирована с ошибкой 25% (таблица 3.2).




Рисунок 3.7 – Случайный пример 1 из тестового набора данных




Рисунок 3.8 – Случайный пример 2 из тестового набора данных




Рисунок 3.9 – Случайный пример 3 из тестового набора данных




Рисунок 3.10 – Случайный пример 4 из тестового набора данных




Рисунок 3.11 – Случайный пример 5 из тестового набора данных




Рисунок 3.12 – Случайный пример 6 из тестового набора данных




Рисунок 3.13 – Случайный пример 7 из тестового набора данных




Рисунок 3.14 – Случайный пример 8 из тестового набора данных




Рисунок 3.15 – Случайный пример 9 из тестового набора данных

Таблица 3.2 – Результаты идентификации параметров случайных примеров из тестового набора данных

	Пример	Объект	Предск. частота, Гц	Целев. частота, Гц	ε, %
1.	0zp0lp1rp2lz1rz_078	Полюс правый	755 362	744 592	1,45
		Ноль левый	20 837	19 393	7,45
		Ноль левый	142 768	153 397	6,93
		Ноль правый	3041	3041	0,00
2.	0zp1lp0rp0lz1rz_028	Полюс левый	485 222	502 183	3,38
		Ноль правый	12 496	12 283	1,73
3.	0zp2lp1rp1lz0rz_022	Полюс левый	3158	3322	4,93
		Полюс левый	–	48 515	–
		Полюс правый	15 940	15 779	1,02
		Ноль левый	42 107	33 703	24,93
4.	0zp2lp1rp1lz0rz_035	Полюс левый	7093	6918	2,53
		Полюс левый	455 504	438 739	3,82
		Полюс правый	237 801	243 821	2,47
		Ноль левый	68 992	70 739	2,47
5.	1zp0lp1rp2lz1rz_098	Полюс правый	1 993 848	2 166 833	7,98
		Ноль левый	35 256	36 247	2,74
		Ноль левый	1 010 657	942 959	7,18
		Ноль правый	14 315	14 118	1,40
6.	1zp1lp0rp1lz0rz_076	Полюс левый	8936	9311	4,03
		Ноль левый	200 057	198 008	1,03
7.	1zp1lp0rp1lz1rz_038	Полюс левый	135 091	142 793	5,39
		Ноль левый	6313	5890	7,18
		Ноль правый	877 627	889 877	1,38
8.	1zp2lp1rp1lz0rz_013	Полюс левый	21 613	22 897	5,61
		Полюс левый	907 506	1 048 381	13,44
		Полюс правый	3 897 730	4 250 240	8,29
		Ноль левый	56 832	58 496	2,84
9.	1zp2lp1rp1lz0rz_019	Полюс левый	36 549	32 367	12,92
		Полюс левый	522 511	508 590	2,74
		Полюс правый	1 068 787	1 054 453	1,36
		Ноль левый	10 989	11 757	6,53

3.4.2 Результаты детекции объектов и идентификации параметров в данных эксперимента

По частотным характеристикам, измеренным в серии экспериментов, выполнена детекция объектов и идентификация параметров линейных звеньев системы автоматического регулирования источника питания. Качество функционирования модели сегментации проверено как на характеристиках, измеренных внутрисхемно алгоритмом 2.4 (Приложение А), так и на характеристиках, измеренных анализатором цепей AP300 Frequency Response Analyzer (Приложение Б).

Теоретически ожидается, что комплексный коэффициент передачи исследованных звеньев аппроксимируется следующими малосигнальными моделями:

- Звено преобразования тока в напряжение (рисунок 3.16, 3.18):

$$H_{ui}(s) = \frac{R}{2} \cdot \frac{U_{in}}{U_{out}} \cdot \frac{\left(1 - \frac{s}{\omega_{RHP}}\right) \cdot \left(1 + \frac{s}{\omega_{ESR}}\right)}{1 + \frac{s}{\omega_{RC}}} e^{-s \cdot t_{delay}},$$

$$\text{где } \omega_{RHP} = \frac{U_{in}^2}{U_{out}^2} \cdot \frac{R}{L}, \omega_{ESR} = \frac{1}{ESR \cdot C}, \omega_{RC} = \frac{2}{R \cdot C}.$$

- ПИ-регулятор (рисунки 3.22, 3.26):

$$H_{PI}(s) = G_{PI} \frac{1 + \frac{s}{\omega_{PI}}}{s},$$

где G_{PI} , ω_{PI} – вещественные положительные числа.

- ПИД-регулятор (рисунок 3.24):

$$H_{PID}(s) = G_{PID} \frac{\left(1 + \frac{s}{\omega_{PI}}\right) \cdot \left(1 + \frac{s}{\omega_{PD}}\right)}{s \left(1 + \frac{s}{\omega_p}\right)},$$

где G_{PID} , ω_{PI} , ω_{PD} , ω_p – вещественные положительные числа.

- Выходной импеданс выключенного источника питания (рисунок 3.28):

$$H_{out}(s) = \frac{1}{C} \cdot \frac{1 + \frac{s}{\omega_{ESR}}}{s}.$$

- Выходной импеданс источника питания в режиме стабилизации тока (рис. 3.30):

$$H_{out}^I(s) = \frac{R}{2} \cdot \frac{1 + \frac{s}{\omega_{ESR}}}{1 + \frac{s}{\omega_{RC}}}.$$

Выбранные динамические звенья показательны: охватывают несколько наборов полюсов/нулей, включая ноль на нулевой частоте (интеграторы 0-го и 1-го порядка), правый ноль и задержки по времени.

В примерах на рисунках 3.16 и 3.18 не детектирован левый ноль, ожидаемый по теоретической модели динамического звена. В действительности этот левый ноль и не проявился, что подтверждается малой ошибкой аппроксимации моделью без левого нуля (рисунки 3.17 и 3.19) и почти в 2 раза большей ошибкой аппроксимации моделью с левым нулем (рисунки 3.20 и 3.21, таблица 3.3).

Таблица 3.3 – Ошибка аппроксимации измеренных частотных характеристик

	Частотные характеристики	RMSE¹	RMSE²	RMSE³
1.	Звено преобр. тока в напряжение	0,0814	0,1221	0,0593
2.	Звено преобр. тока в напряж. с задержкой	0,0583	0,1250	0,0509
3.	ПИ-регулятор контура регулир. тока	14,4284	14,4287	17,7491
4.	ПИД-регулятор контура регулир. тока	3,2634	3,1328	3,6439
5.	ПИ-регулятор контура стабилиз. напряж.	3,4304	3,4656	4,3966
6.	Выходной импеданс (источник выключен)	0,0201	0,0201	—
7.	Выходной импеданс (стабилизация тока)	0,0144	0,0146	—

¹ Параметры идентифицированы разработанным алгоритмом.

² Параметры теоретической модели.

³ Сравнение с частотными характеристиками, измеренными анализатором цепей.




Рисунок 3.16 – Частотные характеристики звена преобразования тока в напряжение (внутрисхемное измерение)




Рисунок 3.17 – Аппроксимация частотных характеристик звена преобразования тока в напряжение моделью типа «0zp1lp0rp0lz1rz»




Рисунок 3.18 – Частотные характеристики звена преобразования тока в напряжение с задержкой по времени (внутрисхемное измерение)




Рисунок 3.19 – Аппроксимация частотных характеристик звена преобразования тока в напряжение моделью типа «0zp1lp0rp0lz1rz» с задержкой по времени




Рисунок 3.20 – Аппроксимация частотных характеристик звена преобразования тока в напряжение моделью типа «0zp1lp0rp1lz1rz»




Рисунок 3.21 – Аппроксимация частотных характеристик звена преобразования тока в напряжение моделью типа «0zp1lp0rp1lz1rz» с задержкой по времени




Рисунок 3.22 – Частотные характеристики ПИ-регулятора контура регулирования тока (внутрисхемное измерение)




Рисунок 3.23 – Аппроксимация частотных характеристик ПИ-регулятора контура регулирования тока моделью типа «1zp0lp0rp1lz0rz»




Рисунок 3.24 – Частотные характеристики ПИД-регулятора контура регулирования тока (внутрисхемное измерение)




Рисунок 3.25 – Аппроксимация частотных характеристик ПИД-регулятора контура регулирования тока моделью типа «1zp0lp0rp2lz0rz»




Рисунок 3.26 – Частотные характеристики ПИ-регулятора контура стабилизации напряжения (внутрисхемное измерение)




Рисунок 3.27 – Аппроксимация частотных характеристик ПИ-регулятора контура стабилизации напряжения моделью типа «1zp0lp0rp1lz0rz»




Рисунок 3.28 – Частотные характеристики выходного импеданса выключенного источника питания (измерение внешним анализатором)




Рисунок 3.29 – Аппроксимация частотных характеристик выходного импеданса выключенного источника питания моделью типа «1zp0lp0rp1lz0rz»




Рисунок 3.30 – Частотные характеристики выходного импеданса источника питания в режиме стабилизации тока (измерение внешним анализатором)




Рисунок 3.31 – Аппроксимация частотных характеристик выходного импеданса источника питания в режиме стабилизации тока моделью типа «0zp1lp0rp1lz0rz»

ЗАКЛЮЧЕНИЕ

Решены все поставленные задачи работы и достигнуты следующие основные результаты:

1. **Алгоритм внутрисхемного измерения частотных характеристик**, основанный на инъекции в систему синусоидальных сигналов с последовательной сменой частоты и амплитуды, обеспечивающий оптимальный размер измеряемых сигналов-откликов системы с целью уменьшения продолжительности измерений.
2. **Алгоритм идентификации параметров линейного динамического звена по его частотной характеристике**, основанный на архитектуре энкодера-декодера, обеспечивающей однократную генерацию узких бинарных масок, соответствующих координатам частот вещественных полюсов и нулей передаточной функции звена.

В случае высокоскоростного канала связи, когда третье слагаемое выражения (2.5) уже не преобладает в полной сумме, на передний план выходит задача сокращения длительности измерительного окна, т.е. уменьшение параметра L . Обозначенная задача отнесена к перспективе дальнейших исследований.

Важно отметить, что архитектура модели сегментации разработана под широкий класс задач автоматизированного контроля и тестирования встраиваемых систем управления. Рассмотренная в данной работе задача детекции полюсов/нулей относится к простым примерам применения модели, под которые возможно синтезировать обучающий набор данных. Модель возможно обучить детекции разного рода отклонений при наличии соответствующих наборов данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Ridley R.* Measuring frequency response of switching power supplies // *Switching Power Magazine*. – 2006. – P. 1–8.
2. *Shirazi M., Zane R., Maksimovic D.* An autotuning digital controller for dc–dc power converters based on online frequency-response measurement // *IEEE Transactions on Power Electronics*. – 2009. – Nov. – No. 11. – P. 2578–2588. – DOI: [10.1109/TPEL.2009.2029691](https://doi.org/10.1109/TPEL.2009.2029691).
3. Stability of shipboard dc power distribution: online impedance-based systems methods / *A. Riccobono [et al.]* // *IEEE Electrification Magazine*. – 2017. – Sep. – No. 3. – P. 55–67. – DOI: [10.1109/MELE.2017.2718858](https://doi.org/10.1109/MELE.2017.2718858).
4. *Zhang C., Song F., Liu Y.* Crest factor minimization of multisine signals based on the Chebyshev norm approximation method: with application to wafer stage FRF identification // *Results in Engineering*. – 2025. – P. 1–10. – DOI: [10.1016/j.rineng.2025.106579](https://doi.org/10.1016/j.rineng.2025.106579).
5. Crest-factor minimization using nonlinear Chebyshev approximation methods / *P. Guillaume [et al.]* // *IEEE Transactions on Instrumentation and Measurement*. – 1991. – Dec. – No. 6. – P. 982–989. – DOI: [10.1109/19.106304](https://doi.org/10.1109/19.106304).
6. *Wunderlich A., Santi E.* Digital twin models of power electronic converters using dynamic neural networks // *2021 IEEE Applied Power Electronics Conference and Exposition (APEC)*. – 2021. – P. 2369–2376. – DOI: [10.1109/APEC42165.2021.9487201](https://doi.org/10.1109/APEC42165.2021.9487201).
7. *Triverio P.* Vector fitting // *arXiv*. – 2019. – P. 1–39.
8. *Hua Q., Shen M.* Deep learning-enhanced parameter extraction for equivalent circuit modeling in electrochemical impedance spectroscopy // *2023 IEEE Nordic Circuits and Systems Conference (NorCAS)*. – 2023. – P. 1–6. – DOI: [10.1109/NorCAS58970.2023.10305482](https://doi.org/10.1109/NorCAS58970.2023.10305482).
9. Deep learning for segmentation of cracks in high-resolution images of steel bridges / *A. Kompanets [et al.]* // *Automation in Construction*. –

2025. – P. 1–23. – Preprint submitted to Automation in Construction, arXiv:2403.17725v1.
10. Optimized deep encoder-decoder methods for crack segmentation / J. König [et al.] // Digital Signal Processing. – 2021. – P. 1–27. – DOI: [10.1016/j.dsp.2020.102907](https://doi.org/10.1016/j.dsp.2020.102907).
 11. *Gorbunov R.* frequency-response-encoder [Электронный ресурс]. – 2026. – URL: <https://github.com/romangorbunov91/frequency-response-encoder> ; (дата обращения 31.05.2026).
 12. Deeply-supervised nets / C.-Y. Lee [et al.] // Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics. Vol. 38 / под ред. G. Lebanon, S. V. N. Vishwanathan. – San Diego, California, USA, 2015. – P. 562–570. – (Proceedings of Machine Learning Research).
 13. Identity mappings in deep residual networks / K. He [et al.] // European Conference on Computer Vision (ECCV). – Springer, 2016. – P. 630–645. – DOI: [10.1007/978-3-319-46493-0_38](https://doi.org/10.1007/978-3-319-46493-0_38). – arXiv: [1603.05027](https://arxiv.org/abs/1603.05027) [cs.CV].
 14. Attention is all you need / A. Vaswani [et al.] // Advances in Neural Information Processing Systems. Vol. 30. – 2017. – P. 5998–6008.
 15. Attention U-Net: learning where to look for the pancreas / O. Oktay [et al.] // 1st Conference on Medical Imaging with Deep Learning (MIDL). – 2018. – P. 1–10.
 16. *Gorbunov R.* zeros-poles-masks [Электронный ресурс]. – 2026. – URL: <https://github.com/romangorbunov91/zeros-poles-masks> ; (дата обращения 31.05.2026).

ПРИЛОЖЕНИЕ А

Внедрение результатов работы

Разработанный алгоритм внутрисхемного измерения частотных характеристик внедрен компанией ООО «Вайс Верса» (ИНН 5473015789) в коммерческую версию программного обеспечения «Digital Points».




Рисунок А.1 – Окно измерения частотных характеристик программного обеспечения «Digital Points»

Общество с ограниченной ответственностью «ВАЙС ВЕРСА»
Россия, 630090, г. Новосибирск, ул. Николаева, д. 12
ОГРН 1245400020612
ИНН 5473015789 / КПП 547301001

+7 (953) 884-71-25
info@vversa.ru

Акт
внедрения результатов
выпускной квалификационной работы

№ 001 от 14.05.2026

Настоящим подтверждается, что алгоритм внутрисхемного измерения частотных характеристик, основанный на инъекции в систему синусоидальных сигналов с последовательной сменой частоты и амплитуды, обеспечивающий оптимальный размер измеряемых сигналов-откликов системы с целью уменьшения продолжительности измерений, разработанный в выпускной квалификационной работе **Горбунова Романа Леонидовича** на тему «Алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания», успешно прошел аппаратные испытания и внедрен в коммерческую версию программного обеспечения «Digital Points».

Генеральный директор



Н.А. Севостьянов

ПРИЛОЖЕНИЕ Б

Лабораторный стенд

1. Макет источника питания 180 Вт – 1 шт.
2. Источник питания GW INSTEK GPC-3060D (2x30 В, 2x6 А) – 1 шт.
3. Нагрузка электронная АКИП 1380/1 (150 В, 30 А, 300 Вт) – 1 шт.
4. Измеритель частотных характеристик AP300 – 1 шт.
5. Осциллограф АКИП-4126/4А-Х – 1 шт.
6. Мультиметр FLUKE 17B+ – 1 шт.




Рисунок Б.1 – Лабораторный стенд