

Университет ИТМО

Факультет технологий искусственного интеллекта

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

по направлению подготовки

27.04.03 Системный анализ и управление

Тема: «Алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания»

Выполнил: Горбунов Роман Леонидович

Научный руководитель: к.ф.-м.н., Бабушкин М.В.

Санкт-Петербург, 2026

Аннотация

Краткое описание работы.

Ключевые слова: ключ1, ключ2, ключ3.

Содержание

Введение	5
1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов	6
1.1. Алгоритмы измерения частотных характеристик	6
1.2. Алгоритмы идентификации параметров	8
1.2.1. Vector Fitting	8
1.2.2. Алгоритмы на основе CNN-архитектур	11
1.2.3. Архитектуры для задач сегментации	14
2. Разработка алгоритмов внутрисхемного измерения частотных характеристик	18
2.1. Алгоритм с варьируемыми длительностью измерительного окна и количеством точек	20
2.2. Алгоритм с варьируемой длительностью измерительного окна и неизменным количеством точек	22
2.3. Алгоритм с неизменными длительностью измерительного окна и количеством точек	25
2.4. Алгоритм комбинированный	27
2.5. Алгоритм поиска оптимального набора параметров	30
2.6. Результаты измерений	34
3. Разработка алгоритмов идентификации параметров макромоделей . .	35
3.1. Архитектура модели	35
3.1.1. Энкодер	36
3.1.2. Bottleneck	37
3.1.3. Декодер	40
3.2. Предварительная обработка данных	40
3.3. Обучение модели	40
3.3.1. Набор данных	40
3.3.2. Функция потерь	41
3.3.3. Метрики	42
3.4. Результаты измерений	43

Закключение	44
Список использованных источников	45
Приложение А. Лабораторный стенд.	47
Приложение Б. Внедрение результатов работы.	48

Введение

Актуальность темы работы Работа связана с системами управления вторичными источниками электропитания, их настройкой, отладкой и контролем состояния.

Цели и задачи работы

Цель работы - разработать алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания.

Задачи работы:

1. Разработать алгоритмы внутрисхемного измерения частотных характеристик.
2. Разработать алгоритмы идентификации параметров на основе измеренных частотных характеристик.
3. Выполнить экспериментальную оценку показателей качества измерений и идентификации параметров.

Основные результаты работы

Практическая значимость результатов работы

Апробация результатов работы

Объем и структура работы

1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов

1.1. Алгоритмы измерения частотных характеристик

В качестве возбуждения используется псевдослучайная бинарная последовательность (PRBS) (рис. 1.1), близкая по спектру к белому шуму. Сигнал вводится в управляющий контур преобразователя:

- В цикл управления скважностью (duty cycle);
- В опорные сигналы тока и напряжения.

Такое распределение гарантирует, что тестовый сигнал не будет подавлен регуляторами в широком частотном диапазоне, обеспечивая возбуждение системы на частотах выше и ниже полосы пропускания контуров управления [1].




Рисунок 1.1. Алгоритм PRBS

В процессе возмущения измеряются мгновенные значения напряжения $v(t)$ и тока $i(t)$. С помощью быстрого преобразования Фурье (БПФ) получают

частотные спектры:

$$V(j\omega) = \mathcal{F}\{v(t)\}, \quad I(j\omega) = \mathcal{F}\{i(t)\}. \quad (1.1)$$

Импеданс подсистемы вычисляется как:

$$Z(j\omega) = \frac{V(j\omega)}{I(j\omega)}. \quad (1.2)$$

Для получения параметрической модели (передаточной функции) к непараметрической оценке применяется алгоритм наименьших квадратов, позволяющий аппроксимировать импеданс моделью заданного порядка (число полюсов/нулей).

Измеренные импедансы и передаточные функции используются для автоматической перенастройки локальных контроллеров преобразователей. Алгоритм адаптации работает в цикле:

1. **Возмущение:** Ввод PRBS-сигнала в контур управления.
2. **Сбор данных:** Запись откликов $v(t)$, $i(t)$ в течение времени T_{IDENT} .
3. **Анализ:** БПФ-обработка и вычисление частотной характеристики $G(j\omega)$.
4. **Аппроксимация:** Подбор параметрической модели с заданным числом полюсов и нулей.
5. **Синтез:** Расчёт новых коэффициентов регулятора (например, методом Internal Model Control) с учётом пользовательских ограничений по устойчивости и быстродействию.
6. **Обновление:** Загрузка новых коэффициентов в цифровой контроллер (FPGA/DSP).

Полный цикл адаптации занимает время $T_{\text{TOTAL}} \propto T_{\text{IDENT}}$. Метод позволяет компенсировать влияние CPL, входных LC-фильтров и изменений ёмкостей шины, сохраняя заданное затухание переходных процессов без вмешательства оператора.

Таким образом, описанный подход объединяет пассивный критерий устойчивости (PBSC), методику онлайн-идентификации на основе PRBS и цифровое адаптивное управление. Решение позволяет в реальном времени отслеживать импедансы шин постоянного тока, оценивать запас устойчивости и автоматически перенастраивать регуляторы преобразователей, что критиче-

ски важно для многопреобразовательных, реконфигурируемых и инерционно-слабых систем электроснабжения.

1.2. Алгоритмы идентификации параметров

1.2.1. Vector Fitting

Метод *Vector Fitting* (VF) [2] предназначен для построения редуцированных моделей линейных стационарных систем по дискретным выборкам их частотной характеристики. Пусть заданы $\bar{k}$ измерений передаточной функции:

$$H_k = H(j\omega_k), \quad k = 1, \dots, \bar{k}. \quad (1.3)$$

Требуется найти рациональную аппроксимацию $\tilde{H}(s)$, минимизирующую среднеквадратичную ошибку:

$$e^2 = \frac{1}{\bar{k}} \sum_{k=1}^{\bar{k}} |H_k - \tilde{H}(j\omega_k)|^2. \quad (1.4)$$

Прямое решение этой нелинейной задачи наименьших квадратов (НКМ) затруднено из-за неизвестных коэффициентов в знаменателе, что приводит к плохой обусловленности (матрицы Вандермонда) и риску попадания в локальные минимумы.

VF заменяет полиномиальный базис s^n на базис частичных дробей с фиксированными на текущей итерации полюсами $p_n^{(i-1)}$. Аппроксимант и весовая функция записываются в виде:

$$\tilde{H}^{(i)}(s) = r_0^{(i)} + \sum_{n=1}^{\bar{n}} \frac{r_n^{(i)}}{s - p_n^{(i-1)}}, \quad (1.5)$$

$$w^{(i)}(s) = 1 + \sum_{n=1}^{\bar{n}} \frac{w_n^{(i)}}{s - p_n^{(i-1)}}, \quad (1.6)$$

где $\bar{n}$ – порядок модели. Вводится линеаризованный функционал ошибки:

$$(e_{SK}^{(i)})^2 = \frac{1}{\bar{k}} \sum_{k=1}^{\bar{k}} \left| H_k w^{(i)}(j\omega_k) - \tilde{H}^{(i)}(j\omega_k) \right|^2. \quad (1.7)$$

В отличие от классического метода Санатханана–Кёрнера, весовая функция $w^{(i)}(s)$ применяется *неявно* через перенос полюсов на каждой итерации, что радикально улучшает обусловленность системы уравнений.

Алгоритм выполняется циклически ($i = 1, 2, \dots$):

1. **Инициализация полюсов.** Выбираются начальные полюса $p_n^{(0)}$ с малой отрицательной вещественной частью, равномерно распределённые по диапазону частот $[\omega_1, \omega_{\bar{k}}]$:

$$p_n^{(0)} = \begin{cases} (-\alpha + j) \frac{\omega_{\bar{k}}}{\bar{n}/2} n, & n = 1, \dots, \bar{n}/2, \\ (p_{n-\bar{n}/2}^{(0)})^*, & n = \bar{n}/2 + 1, \dots, \bar{n}, \end{cases} \quad (1.8)$$

где обычно $\alpha = 0.01$.

2. **Решение линейной системы НКМ.** Минимизация $(e_{SK}^{(i)})^2$ сводится к решению:

$$\begin{bmatrix} \Phi_0^{(i)} & -\mathbf{D}_H \Phi_1^{(i)} \end{bmatrix} \begin{bmatrix} \mathbf{c}_H^{(i)} \\ \mathbf{c}_w^{(i)} \end{bmatrix} = \mathbf{V}_H, \quad (1.9)$$

где $\Phi_0^{(i)}, \Phi_1^{(i)}$ содержат значения базисных функций $\frac{1}{j\omega_k - p_n^{(i-1)}}$, $\mathbf{D}_H = \text{diag}(H_1, \dots, H_{\bar{k}})$, $\mathbf{V}_H = [H_1, \dots, H_{\bar{k}}]^T$, а $\mathbf{c}_H^{(i)}, \mathbf{c}_w^{(i)}$ – векторы неизвестных вычетов и весовых коэффициентов. Система решается через QR-разложение.

3. **Обновление полюсов.** Новые полюса $p_n^{(i)}$ вычисляются как нули функции $w^{(i)}(s)$, что эквивалентно задаче на собственные значения:

$$\{p_n^{(i)}\} = \text{eig} \left(\mathbf{A}^{(i-1)} - \mathbf{b}_w (\mathbf{c}_w^{(i)})^T \right), \quad (1.10)$$

где $\mathbf{A}^{(i-1)} = \text{diag}(p_1^{(i-1)}, \dots, p_{\bar{n}}^{(i-1)})$, $\mathbf{b}_w = [1, \dots, 1]^T$.

4. **Проверка сходимости.** Итерации останавливаются, когда:

$$\max_k \left| w^{(i)}(j\omega_k) - 1 \right| \leq \varepsilon_w. \quad (1.11)$$

После выполнения условия фиксируются полюса $p_n^{(i)}$ и решается окончательная задача НКМ только для вычетов:

$$\Phi_0^{(i+1)} \mathbf{c}_H^{(i+1)} = \mathbf{V}_H, \quad (1.12)$$

что гарантирует минимизацию исходной ошибки e^2 .

Для систем с $\bar{m}$ входами и $\bar{q}$ выходами измеряемые данные представляют собой матрицы $\mathbf{H}_k \in \mathbb{C}^{\bar{q} \times \bar{m}}$. Модель строится с *общими полюсами* для всех элементов передаточной матрицы:

$$\tilde{\mathbf{H}}(s) = \mathbf{R}_0 + \sum_{n=1}^{\bar{n}} \frac{\mathbf{R}_n}{s - p_n}, \quad (1.13)$$

где $\mathbf{R}_n \in \mathbb{C}^{\bar{q} \times \bar{m}}$. Минимизируется норма Фробениуса ошибки. Для снижения вычислительной сложности применяется *Fast VF*, использующий блочные QR-разложения и распараллеливание по каналам.

Для реальных систем полюса и вычеты должны быть вещественными или образовывать комплексно-сопряжённые пары. Это обеспечивается явным разделением базиса на вещественную и комплексную части.

Чтобы гарантировать устойчивость и причинность модели, на шаге обновления полюсов применяется принудительная стабилизация:

$$p_n^{(i)} \leftarrow \begin{cases} p_n^{(i)}, & \text{Re}\{p_n^{(i)}\} < 0, \\ -\text{Re}\{p_n^{(i)}\} + j \text{Im}\{p_n^{(i)}\}, & \text{Re}\{p_n^{(i)}\} > 0. \end{cases} \quad (1.14)$$

При отсутствии шума в данных это не снижает точность, но делает модель пригодной для временного моделирования.

Полученная модель в форме “полюса–вычеты” преобразуется к пространству состояний (реализация Гилберта):

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t), \\ \mathbf{y}(t) = \mathbf{C}\mathbf{x}(t) + \mathbf{D}\mathbf{u}(t), \end{cases} \quad (1.15)$$

где $\mathbf{D} = \mathbf{R}_0$, а блочно-диагональная матрица $\mathbf{A}$ и блочные $\mathbf{B}, \mathbf{C}$ формируются из SVD-разложений матриц вычетов $\mathbf{R}_n = \mathbf{U}_n \mathbf{\Sigma}_n \mathbf{V}_n^H$. Такая реализация гарантирует минимальный порядок системы и исключает неуправляемые/ненаблюдаемые состояния.

Таким образом, метод Vector Fitting преобразует нелинейную задачу рациональной аппроксимации в последовательность линейных задач НКМ за счёт неявного весового перевзвешивания и переноса полюсов. Метод облада-

ет высокой скоростью сходимости (обычно 4–6 итераций), численной устойчивостью и легко масштабируется на многоканальные системы. Существуют расширения алгоритма для работы во временной области (z -VF), учёта шумов (Relaxed VF), параметрического моделирования и распределённых систем с задержками.

1.2.2. Алгоритмы на основе CNN-архитектур

Электрохимическая импедансная спектроскопия (EIS) позволяет характеризовать электрохимические системы через измерение комплексного импеданса Z в диапазоне частот $f = [f_1, f_2, \dots, f_M]$. Для интерпретации данных широко используется моделирование эквивалентными электрическими схемами (ЕСМ), где импеданс описывается функцией от параметров компонентов:

$$Z = F(f; p_1, p_2, \dots, p_N), \quad (1.16)$$

где $\mathbf{p} = [p_1, \dots, p_N]$ — вектор параметров (сопротивления, ёмкости, индуктивности, элементы постоянной фазы и т.д.).

Традиционный метод комплексных нелинейных наименьших квадратов (CNLS), реализуемый через алгоритм Левенберга–Марквардта, требует задания начального приближения $\mathbf{p}^{(0)}$. Сильная нелинейность модели и наличие шума часто приводят к сходимости в локальные минимумы или расходимости. Для решения проблемы авторы предлагают использовать сверточную нейронную сеть (CNN) для автоматической генерации качественного начального приближения [3].




Рисунок 1.2

Для обучения регрессионной модели генерируется синтетический набор данных. Параметры $\mathbf{p}$ выбираются случайно в физически обоснованном диапазоне, после чего с помощью симулятора рассчитываются соответствующие спектры импеданса. Входные данные нормализуются и представляются в виде 4 каналов: действительная часть (Z'), мнимая часть (Z''), модуль ($|Z|$) и фаза ($\angle Z$).

Архитектура сети включает:

- Три слоя Conv1D с количеством фильтров 128, 256, 128 и длинами ядер 4, 5, 4 соответственно.
- Слой Flatten.
- Слой Gaussian Noise со стандартным отклонением $\sigma = 0.05$ для повышения обобщающей способности.
- Три полносвязных (Dense) слоя размерности 256, 64 и p (число параметров схемы).

Во всех слоях используется функция активации ReLU:

$$\text{ReLU}(x) = \max(0, x). \quad (1.17)$$

Обучение проводится с помощью оптимизатора Adam (learning rate = 0.001). Функция потерь определяется как среднеквадратичная ошибка (MSE)

между предсказанными сетью параметрами p'_n и истинными параметрами p_n :

$$\mathcal{L}_{\text{CNN}} = \frac{1}{N} \sum_{n=1}^N (p'_n - p_n)^2. \quad (1.18)$$

Обученная модель выступает в роли этапа предфиттинга. Процедура состоит из следующих шагов:

1. Измеренный спектр импеданса нормализуется и подаётся на вход CNN.
2. Сеть генерирует начальное приближение параметров $\mathbf{p}_{\text{init}}$.
3. $\mathbf{p}_{\text{init}}$ передаётся в алгоритм CNLS (Левенберг–Марквардт) для точной оптимизации.

CNLS минимизирует ошибку между измеренными значениями z_m и модельными Z_m на каждой частоте:

$$\text{MSE}_{\text{CNLS}} = \frac{1}{M} \sum_{m=1}^M (z_m - Z_m)^2. \quad (1.19)$$

Благодаря качественному начальному приближению, алгоритм быстро сходится к глобальному минимуму без ручного вмешательства.

Для валидации метода используется средняя абсолютная процентная ошибка (MAPE), вычисляемая по всем частотным точкам:

$$\text{MAPE} = \frac{1}{M} \sum_{m=1}^M \frac{|z_m - Z_m|}{|z_m|}. \quad (1.20)$$

Фиттинг считается успешным, если $\text{MAPE} < 0.01$. Эксперименты на открытом датасете показали, что предложенный метод повышает успешность фиттинга до 87.5% (на 25% выше по сравнению с CNLS со случайными начальными значениями и стохастическими методами), при этом сокращая общее время вычислений и обеспечивая стабильную сходимость.

1.2.3. Архитектуры для задач сегментации




Рисунок 1.3. Архитектура автоэнкодера для сегментации «узких» объектов

Метод [4] основан на архитектуре **кодировщик-декодировщик** (encoder-decoder), адаптированной для работы с высокоразрешающими изображениями (4608×3456 пикселей). Сеть выполняет бинарную посимвольную классификацию: каждому пикселю присваивается значение 0 (фон) или 1 (трещина).

В качестве экстрактора признаков используется архитектура **ConvNeXt** (версия Tiny), предобученная на наборе данных ImageNet. ConvNeXt состоит из 4 стадий, каждая из которых включает свёрточные блоки с увеличением глубины каналов и уменьшением пространственного разрешения. Использование предобученных весов реализует стратегию трансферного обучения, позволяя сети эффективно извлекать низкоуровневые и семантические признаки даже на ограниченном доменном наборе данных.

Декодировщик состоит из 6 уровней и модифицирует архитектуру [5]. Основные компоненты:

- **Модули внимания:** На каждом уровне применяются пространственные и каналные слои squeeze-and-excitation, которые адаптивно взвешивают карты признаков, усиливая релевантные области.

- **Skip-connections:** Карты признаков декодировщика конкатенируются с соответствующими картами кодировщика для восстановления пространственной информации, потерянной при даунсэмплинге.
- **Остаточные блоки:** После конкатенации и свёртки 3×3 применяются residual-блоки с batch normalization и функцией активации ReLU.
- **Финальный слой:** Поточечная свёртка с сигмоидальной активацией формирует итоговую карту сегментации со значениями в диапазоне $[0, 1]$.

Прямая подача полного изображения в сеть требует ~ 189 ГБ ОЗУ, что превышает возможности стандартных GPU (40 ГБ). Для решения проблемы применяется **патч-ориентированный подход**:

- Изображение разбивается на непересекающиеся патчи размером 512×512 пикселей.
- Каждый патч обрабатывается сетью независимо.
- Полученные карты сегментации склеиваются (stitching) для формирования глобальной карты всего изображения.

Эксперименты показали, что уменьшение размера патча (например, до 128×128) снижает точность, так как сеть теряет глобальный контекст, необходимый для отличия трещин от *crack-like features* (стыки, тени, коррозия).

Стандартной функцией потерь для сегментации трещин является сумма бинарной кросс-энтропии (BCE) и Dice-потери, которая компенсирует сильный класс-имбаланс (трещины занимают малую площадь):

$$L_{\text{BCE}}(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)], \quad (1.21)$$

$$L_{\text{Dice}}(y, \hat{y}) = 1 - \frac{\sum_{i=1}^N y_i \hat{y}_i + \epsilon}{\sum_{i=1}^N y_i + \sum_{i=1}^N \hat{y}_i + \epsilon}, \quad (1.22)$$

$$L(y, \hat{y}) = L_{\text{BCE}}(y, \hat{y}) + L_{\text{Dice}}(y, \hat{y}), \quad (1.23)$$

где N — число пикселей, $y_i \in [0, 1]$ и $\hat{y}_i \in \{0, 1\}$ — значения i -го пикселя в эталонной и предсказанной картах соответственно, $\epsilon = 1$.

Проблема фона: Для патчей без трещин $\sum_{i=1}^N y_i = 0$. В этом случае $L_{\text{Dice}} \approx 1$ при любом $\sum \hat{y}_i \gg \epsilon$, что делает функцию нечувствительной к ложноположительным срабатываниям на фоне.

Решение (Loss Inversion): Для фоновых патчей вводится операция инверсии меток:

$$L_{\text{inversion}}(y, \hat{y}) = \begin{cases} L(\text{inv}(y), \text{inv}(\hat{y})), & \text{если } \sum_{i=1}^N y_i = 0, \\ L(y, \hat{y}), & \text{иначе,} \end{cases} \quad (1.24)$$

где $\text{inv}(z) = -z + 1$. При обучении на фоне сеть оптимизируется как «сегментатор фона», что позволяет штрафовать ошибки и использовать в обучающей выборке до 90% фоновых патчей без попадания в локальный минимум «all-white segmentation maps».

Для стабилизации градиентов и ускорения сходимости на промежуточных уровнях декодировщика (уровни 2–5) формируются дополнительные карты сегментации. Итоговая функция потерь вычисляется как взвешенная сумма:

$$L_{\text{total}}(y, \hat{y}) = L_{\text{target}}(y, \hat{y}) + \sum_{i=0}^n w_i L_{\text{companion}}^i(y, \hat{y}_i), \quad (1.25)$$

где n — число вспомогательных карт, $w_i = 1$, а $\hat{y}_i$ масштабируются до размера входного изображения методом ближайших соседей и проходят через сигмоиду.

- **Оптимизатор:** ADAMW с $\lambda_{\text{initial}} = 0.001$ и weight decay $1 \cdot 10^{-5}$.
- **Экспоненциальное затухание LR:** $\lambda = \lambda_{\text{initial}} \cdot \gamma^e$, где $\gamma = 0.99$, e — номер эпохи.
- **Поэтапное затухание LR (ConvNeXt):** $\lambda_{\text{stage}} = \lambda \cdot k^{N+1-n}$, где $k = 0.7$, $N = 4$ (число стадий), n — номер стадии.
- **Аугментация:** Флипы, повороты $\{0^\circ, 90^\circ, 180^\circ, 270^\circ\}$, изменение яркости/контраста/насыщения (75–125%), сдвиг оттенка ($\pm 10\%$), аддитивный шум, случайное масштабирование и зум.
- **Баланс патчей:** Оптимальное соотношение трещина/фон для стандартной потери $\approx 70/30$. При использовании $L_{\text{inversion}}$ возможно обучение на полном наборе ($\sim 6.5/93.5$).

Качество оценивается по агрегированным Precision (Pr), Recall (Re) и F1-score на всём тестовом множестве (суммирование TP, FP, FN по всем изобра-

жениям для избежания смещения из-за фонового доминирования):

$$\text{Pr} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad (1.26)$$

$$\text{Re} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad (1.27)$$

$$\text{F1} = 2 \cdot \frac{\text{Pr} \cdot \text{Re}}{\text{Pr} + \text{Re}} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}}, \quad (1.28)$$

где бинаризация предсказаний выполняется порогом $\theta = 0,5$.

2. Разработка алгоритмов внутрисхемного измерения частотных характеристик

Рассматриваемая система аналого-цифрового преобразования и цифровой обработки сигналов с воздействием на объект управления посредством импульсной модуляции (рис. 2.1).




Рисунок 2.1. Рассматриваемая система

Операции выполняются циклически с постоянным периодом T_d , соответствующим базовой частоте дискретного регулирования $f_d = 1/T_d$.

В канал управления системы аддитивно инжектируется сигнал в виде дискретной последовательности $z[n]$.

Откликом системы являются два непрерывных сигнала: $x_c(t)$, $y_c(t)$.

Система преобразует непрерывные сигналы $x_c(t)$, $y_c(t)$ в дискретные последовательности $x[n]$, $y[n]$.

В системе резервируется буфер размером $2N_{\max}$ под хранение откликов $x[n]$, $y[n]$ при внутрисхемном измерении частотных характеристик.

Преобразование осуществляется посредством дискретизации:

$$\begin{aligned} x[n] &= x_c(nT_s), \\ y[n] &= y_c(nT_s), \end{aligned} \tag{2.1}$$

где T_s – период дискретизации, $T_s \geq T_d$.

Коэффициенты разложения дискретных последовательностей

$$x[n] = \frac{1}{N} \sum_{l=0}^{N-1} X[l] e^{j \frac{2\pi}{N} ln},$$

$$y[n] = \frac{1}{N} \sum_{l=0}^{N-1} Y[l] e^{j \frac{2\pi}{N} ln}$$

определяются по N -последовательным отсчетам дискретных последовательностей $x[n]$, $y[n]$:

$$X[l] = \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} nl},$$

$$Y[l] = \sum_{n=0}^{N-1} y[n] e^{-j \frac{2\pi}{N} nl}.$$
(2.2)

Коэффициенты $X[l]$, $Y[l] \in \mathbb{C}$, представляют собой дискретные периодические последовательности с периодом N .

При условии, что измерительное окно длительностью T_h вмещает целое количество N периодов дискретизации T_s ($T_h = N \cdot T_s$) дискретные последовательности $X[l]$, $Y[l]$ на отрезке $l \in [0; N-1]$ длины N содержат коэффициенты разложения $x[n]$, $y[n]$ в диапазоне частот $f \in [0, f_s/2]$ с шагом по частоте $\Delta f = 1/T_h$.

Составляющим с частотой f_h соответствуют $X[l]$, $Y[l]$ при $l = 1$, а с частотой $f_s/2$ – при $l = \lfloor (N-1)/2 \rfloor$.

В данном разделе рассматриваются алгоритмы измерения частотных характеристик, основанные на воздействии на систему дискретной последовательностью $z[n]$ моногармонического типа, определяемой косинусоидальной функцией

$$z[n] = Z \cos(\underbrace{2\pi f_z T_d n}_{\omega_z})$$

с частотой f_z .

Минимальное количество отсчетов N на измерительном окне T_h принято равным 3, поэтому частота f_z ограничена сверху значением $f_d/3$.

Модель сигналов-откликов системы принята следующей:

$$\begin{aligned}x_c(t) &= X_0 + X_z \cos(\omega_z t + \phi_x) + X_g \cos(\omega_g t), \\y_c(t) &= Y_0 + Y_z \cos(\omega_z t + \phi_y) + Y_g \cos(\omega_g t),\end{aligned}$$

где $\omega_z = 2\pi f_z$.

Алгоритм измерения частотной характеристики звена системы основан на последовательной смене периода инжектируемого сигнала $T_z = 1/f_z$ в серии из K -измерений.

Каждому k -му измерению, $k \in [1, K]$, соответствует пара параметров $Z^{(k)}$, $T_z^{(k)}$, следовательно, и набор дискретных последовательностей $x^{(k)}[n]$, $y^{(k)}[n]$, $z^{(k)}[n]$, а также коэффициентов $X^{(k)}[l]$, $Y^{(k)}[l]$.

Под частотной характеристикой понимается набор пар значений $f_z^{(k)}$, $W^{(k)}$, где в каждом k -ом измерении

$$W^{(k)} = \frac{Y^{(k)}[L^{(k)}]}{X^{(k)}[L^{(k)}]} = |W^{(k)}| e^{j\angle W^{(k)}}, \quad (2.3)$$

$$L^{(k)} = T_h^{(k)} / T_z^{(k)}.$$

Пары значений $f_z^{(k)}$, $|W^{(k)}|$ и $f_z^{(k)}$, $\angle W^{(k)}$ образуют амплитудно-частотную и фазо-частотную характеристики, соответственно.

$$\begin{aligned}|W^{(k)}| &= \frac{|Y^{(k)}[L^{(k)}]|}{|X^{(k)}[L^{(k)}]|}, \\ \angle W^{(k)} &= \angle Y^{(k)}[L^{(k)}] - \angle X^{(k)}[L^{(k)}].\end{aligned} \quad (2.4)$$

2.1. Алгоритм с варьируемыми длительностью измерительного окна и количеством точек

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}$, $k \in [1; K]$):

- Длительность T_h измерительного окна равна периоду T_z инжектируемого сигнала ($T_h^{(k)} = T_z^{(k)}$, $T_h^{(k)} - var$).
- Период дискретизации T_s одинаков для всех значений T_z и равен периоду T_d выполнения операций в системе ($T_s^{(k)} = T_d$, $T_s^{(k)} = const$).

- Количество точек N дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), изменяется пропорционально $T_z (N^{(k)} - var)$.

Период инжектируемого сигнала

$$T_z^{(k)} = N^{(k)} \cdot T_s^{(k)} = N^{(k)} \cdot T_d$$

кратен периоду T_d выполнения операций в системе (рис. 2.2).




Рисунок 2.2. Размер $N^{(k)}$ дискретной последовательности при изменении периода $T_z^{(k)}$ инжектируемого сигнала

В связи с тем, что $T_h^{(k)} = T_z^{(k)}$ составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (2.3) при $L^{(k)} = 1$.

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты f_z инжектируемого сигнала в серии из K измерений **характерны следующие особенности:**

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , которое ограничено сверху только объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.
2. Максимально возможная частота f_z в пределе составляет $f_d/3$.
3. В памяти достаточно хранить $N^{(k)} = f_d/f_z^{(k)}$ -значений каждого массива-отклика $x^{(k)}[n]$, $y^{(k)}[n]$, причем величина N не является постоянной и уменьшается с ростом частоты f_z вплоть до $N = 3$ при $f_z \rightarrow f_d/3$.
4. Шаг приращения периода T_z инжектируемого сигнала (разрешающая способность): $\Delta T_z = T_d$.
5. Потенциальные значения частот f_z инжектируемого сигнала неравномерно распределены на интервале $f \in (0; f_d/2)$ возможных значений:
 - На полуинтервале $f \in [f_d/10; f_d/2)$ частота f_z может принимать значения всего из 8-ми возможных:

$$f_z = (f_d/10, f_d/9, \dots, f_d/3).$$
 - На полуинтервале $f \in [f_d/100; f_d/10)$ – одно из 90 возможных:

$$f_z = (f_d/100, f_d/99, \dots, f_d/11).$$
 - На интервале $f \in (0; f_d/100)$ – сколь угодно много значений, ограниченное исключительно объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.

2.2. Алгоритм с варьируемой длительностью измерительного окна и неизменным количеством точек

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}$, $k \in [1; K]$):

- Длительность T_h измерительного окна равна периоду T_z инжектируемого сигнала ($T_h^{(k)} = T_z^{(k)}$, $T_h^{(k)} - var$).
- Количество точек N дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменно для всех значений периода T_z ($N^{(k)} = const$).
- Период дискретизации T_s изменяется в целях обеспечить $N^{(k)} = const$ при изменении периода T_z инжектируемого сигнала ($T_s^{(k)} - var$).

Постоянство N при изменении периода T_z инжектируемого сигнала обеспечивается децимацией (прореживанием) дискретных последовательностей $x'[n]$, $y'[n]$.

Выражениями $x'[n]$, $y'[n]$ обозначены дискретные последовательности, формируемые в результате дискретизации откликов системы $x_c(t)$, $y_c(t)$ непосредственно с периодом T_d выполнения операций в системе.

Дискретные последовательности $x^{(k)}[n]$, $y^{(k)}[n]$ формируются в результате децимации $x'^{(k)}[n]$, $y'^{(k)}[n]$ с коэффициентом децимации $M^{(k)} \in \mathbb{N}$

$$\begin{aligned} x^{(k)}[n] &= x'^{(k)}[n \cdot M^{(k)}] = x_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}) \\ y^{(k)}[n] &= y'^{(k)}[n \cdot M^{(k)}] = y_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}), \end{aligned}$$

так, что период инжектируемого сигнала всегда кратен периоду T_d выполнения операций в системе:

$$T_z^{(k)} = N^{(k)} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}.$$

Дискретные последовательности $x^{(k)}[n]$, $y^{(k)}[n]$ формируются по правилу (2.1) фактически с эквивалентным периодом дискретизации $T_s^{(k)} = M^{(k)} \cdot T_d$ (рис. 2.3). Под эквивалентным понимается такой период дискретизации, при котором формировалась бы точно такая же дискретная последовательность.




Рисунок 2.3. Период дискретизации $T_s^{(k)}$ при изменении периода $T_z^{(k)}$ инжестируемого сигнала

Измерительное окно $T_h^{(k)} = T_z^{(k)}$ при всех k , поэтому, также как и в алгоритме 2.1, составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)}[l]$, $Y^{(k)}[l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (2.3) при $L^{(k)} = 1$.

Принципиальное отличие от алгоритма 2.1 связано с потенциально меньшим размером N массивов-откликов $x[n]$, $y[n]$ ($N \in \mathbb{N}$ – независимая переменная, $N > 2$).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты f_z инжестируемого сигнала в серии из K измерений **характерны следующие особенности**:

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , причем требуемый объем па-

мости для хранения массивов-откликов $x^{(k)}[n]$, $y^{(k)}[n]$ одинаков для всех длительностей $T_h^{(k)}$ и частот $f_z^{(k)}$.

2. Максимально возможная частота f_z составляет f_d/N .
3. Шаг приращения периода T_z инжектируемого сигнала (разрешающая способность) в N -раз больше, в сравнении с алгоритмом 2.1 ($\Delta T_z = N \cdot T_d$).
4. Грубый шаг приращения периода обуславливает еще более неравномерное распределение частот. Например, в диапазоне частот $f \in [f_d/100; f_d/10]$ при $N = 10$ частота f_z инжектируемого сигнала может принимать значения всего из 10-ти возможных:
 $f_z = (f_d/100, f_d/90, \dots, f_d/10)$.

2.3. Алгоритм с неизменными длительностью измерительного окна и количеством точек

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}$, $k \in [1; K]$):

- Длительность T_h измерительного окна неизменна и равна наибольшему периоду инжектируемого сигнала ($T_h^{(k)} = T_z^{max}$, $T_h^{(k)} = const$).
- Период дискретизации T_s одинаков для всех значений T_z ($T_s^{(k)} = const$) и кратен периоду T_d выполнения операций в системе ($T_s^{(k)} = M \cdot T_d$); коэффициент децимации $M = const$, $M \in \mathbb{N}$.
- Количество точек $N \in \mathbb{N}$ дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменно для всех значений $T_z^{(k)}$ ($N^{(k)} = const$),

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

Математическая обработка в соответствии с (2.2) накладывает ограничение на период T_z инжектируемого сигнала – требуется, чтобы измерительное окно T_h вмещало целое число периодов T_z (рис. 2.4), т.е. для каждого значения $T_z^{(k)}$ должно выполняться

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)}, \quad (2.5)$$

где $L^{(k)} \in \mathbb{N}$.




Рисунок 2.4. Период инжектируемого сигнала при $T_h^{(k)} = const$

В соответствии с (2.5), частота $f_z^{(k)}$ инжектируемого сигнала потенциально принимает значения

$$f_z^{(k)} = L^{(k)} \frac{1}{T_h} = L^{(k)} \Delta f_z,$$

где Δf_z – шаг приращения частоты инжектируемого сигнала

В связи с $\Delta f_z = const$ потенциальные значения частот $f_z^{(k)}$ равномерно распределены на интервале возможных значений, что **является главной отличительной особенностью алгоритма** в сравнении с алгоритмами 2.1, 2.2.

Составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ при разных значениях $L^{(k)}$, определяемых выражением (2.3).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты $f_z^{(k)}$ инжектируемого сигнала в серии из K измерений **характерны следующие особенности:**

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , которое ограничено сверху только объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.
2. Максимально возможная частота f_z в пределе составляет $f_s/3$.
3. Требуемый объем памяти для хранения массивов-откликов $x^{(k)}[n]$, $y^{(k)}[n]$ одинаков для всех частот $f_z^{(k)}$ инжектируемого сигнала.
4. Период T_z инжектируемого сигнала потенциально принимает значения от $T_z^{min} = 3T_s$ до $T_z^{max} = T_h$, но при условии $T_h/T_s \in \mathbb{N}$.
5. Шаг приращения частоты f_z инжектируемого сигнала (разрешающая способность): $\Delta f_z = 1/T_h$.

2.4. Алгоритм комбинированный

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала $(T_z^{(k)}, k \in [1; K])$:

- Длительность T_h измерительного окна кратна периоду инжектируемого сигнала ($T_h^{(k)} = L^{(k)}T_z^{(k)}$, $T_h^{(k)} = \text{var}$).
- Период дискретизации T_s кратен периоду T_d выполнения операций в системе ($T_s^{(k)} = M^{(k)}T_d$); коэффициент децимации $M^{(k)} = \text{var}$, $M \in \mathbb{N}_{>0}$.
- Количество точек $N \in \mathbb{N}_{>0}$ дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), соответствует каждому отдельному значению $T_z^{(k)}$ ($N^{(k)} = \text{var}$).

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

В отличие от алгоритма 2.3, длительность измерительного окна варьируется (рис. 2.5):

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)} = L^{(k)} \cdot \underbrace{R^{(k)}}_{N^{(k)}} \cdot T_d = \underbrace{L^{(k)} \cdot Q^{(k)}}_{N^{(k)}} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}, \quad (2.6)$$

где $R^{(k)} \in \mathbb{R}$ – соотношение между периодом инжектируемого сигнала и периодом выполнения операций в системе:

$$R^{(k)} = \frac{T_z^{(k)}}{T_d} = Q^{(k)} \cdot M^{(k)},$$

$Q^{(k)} \in \mathbb{R}$.




Рисунок 2.5. Параметры N, M, L алгоритма при разных $T_z^{(k)}$

Аналогично алгоритму 2.3, соотношение между периодом инжектируемого сигнала и периодом дискретизации может принимать дробные значения. В совокупности с изменяемой длительностью измерительного окна это обеспечивает на интервале $f \in (0; f_d/2)$ сколь угодно много потенциальных значений частот f_z инжектируемого сигнала, что **является главной отличительной особенностью алгоритма**.

Из равенства (2.6)

$$L^{(k)} = \frac{N^{(k)} \cdot M^{(k)}}{R^{(k)}}. \quad (2.7)$$

В связи с тем, что частота инжектируемого сигнала кратна частоте первой гармоники в спектре

$$f_z^{(k)} = L^{(k)} \cdot f_h^{(k)} = \frac{L^{(k)}}{T_h^{(k)}},$$

множитель $L^{(k)}$ ограничен диапазоном

$$1 \leq L^{(k)} < \frac{N^{(k)}}{2},$$

что, с учетом (2.7), накладывает ограничение

$$M^{(k)} < \frac{R^{(k)}}{2}.$$

Таким образом, для каждой k -й частоты f_z задача сводится к поиску наборов $\mathbf{s}_{(p)} \in \mathbb{N}_{>0}^3$ целых чисел N, M, L , при которых обеспечивается частота $f_{z(p)}$ с заданной степенью приближения $\Delta\epsilon_f^*$ к f_z

$$|f_{z(p)} - f_z| = \Delta\epsilon_{f(p)} < \Delta\epsilon_f^*,$$

при ограничениях

$$N_{\min} \leq N_{(p)} \leq N_{\max},$$

$$M_{(p)} < \frac{R}{2}.$$

Оптимальным считается такой набор $\mathbf{s}^*$, в котором параметр N минимален из всех $\mathbf{s}_{(p)}$, отвечающих условию

$$\Delta\epsilon_{f(p)} < \Delta\epsilon_f^*. \quad (2.8)$$

Минимум количества точек N обеспечивает максимальную скорость измерения частотной характеристики.

В случае, когда ни один набор параметров не удовлетворяет условию (2.8), оптимальным считается набор $\mathbf{s}_{(p)}^*$, соответствующий минимальному отклонению $\Delta\epsilon_{f(p)}$.

2.5. Алгоритм поиска оптимального набора параметров

Поиск оптимального набора параметров требуется для каждой частоты инжектируемого сигнала из исходного набора частот $f_z^{(k)}$, $k \in [1; K]$. В результате определяются такие K -наборы параметров, при котором частотная характеристика измеряется алгоритмом 2.4 за минимальное время с точностью воспроизведения частоты $f_z^{(k)}$ близкой к заданной $\Delta\epsilon_f^*$.

Входные данные:

- Частота инжектируемого сигнала: f_z .
- Максимальное абсолютное отклонение от заданной частоты f_z инжектируемого сигнала: $\Delta\epsilon_f^*$.
- Частота выполнения операций в системе: f_d .
- Максимальное количество точек дискретных последовательностей $x[n]$, $y[n]$ на интервале измерения: $N_{\max}$.
- Минимальное количество точек дискретных последовательностей $x[n]$, $y[n]$ на интервале измерения: $N_{\min}$.

Выходные данные:

- Количество точек дискретных последовательностей $x[n]$, $y[n]$ на интервале измерения: N .
- Коэффициент децимации: M .
- Коэффициент кратности длительности измерительного окна T_h к периоду инжектируемого сигнала T_z : L .

Последовательность действий:

1. Вычисляется коэффициент соотношения между периодом инжектируемого сигнала и периодом выполнения операций в системе:

$$R = \frac{f_d}{f_z}.$$

2. Вычисляется максимально возможное значение коэффициента децимации:

$$M_{\max} = \left\lfloor \frac{R}{2} \right\rfloor.$$

3. В цикле $M \in [1; M_{\max}]$:

3.1. Вычисляются всевозможные значения

$$L = \left\lfloor \frac{M \cdot N}{R} \right\rfloor$$

для $N \in [N_{\min}; N_{\max}]$, с округлением L до 1 при $L < 1$.

3.2. Значения L используются для вычисления всевозможных приближений к начальному значению коэффициента R :

$$R' = \frac{M \cdot N}{L}.$$

3.3. Значения R' используются для вычисления всевозможных приближений к исходному значению частоты f_z :

$$f'_z = \frac{f_d}{R'},$$

и соответствующих отклонений

$$\Delta \epsilon_f = \left| f'_z - f_z \right|.$$

3.4. Из набора значений f'_z исключаются те, для которых $\Delta \epsilon_f > \Delta \epsilon_f^*$.

3.5. Среди оставшихся f'_z определяется значение, соответствующее минимальному N . Формируется набор $\mathbf{s}^*$ соответствующих параметров N, M, L .

3.6. Если нет значений f'_z , удовлетворяющих условию $\epsilon_f < \epsilon_f^*$, выбирается набор параметров N, M, L , соответствующий наименьшему отклонению $\Delta \epsilon_f$.

4. Среди найденных наборов параметров $\mathbf{s}^*$, соответствующих разным M , рассматриваются наборы, удовлетворяющие условию $\Delta \epsilon_f < \Delta \epsilon_f^*$ и среди них выбирается набор с минимальным N .

5. Если нет наборов параметров $\mathbf{s}^*$, удовлетворяющих условию $\Delta \epsilon_f < \Delta \epsilon_f^*$, выбирается набор параметров, соответствующий наименьшему отклонению $\Delta \epsilon_f$.

6. Формируется итоговый набор $\mathbf{s}^* = (N, M, L)$.

Примечания:

1. Отклонение от заданной частоты f_z инжектируемого сигнала допустимо задавать в относительных единицах ϵ_f^* , с последующим пересчетом в абсолютное значение

$$\Delta\epsilon_f^* = \epsilon_f^* \cdot f_z.$$

В таком случае, на вход алгоритма получается задать общее для всех частот относительное отклонение ϵ_f^* . Абсолютные значения отклонения $\Delta\epsilon_f^{*(k)}$ сформируются в соответствии частотами $f_z^{(k)}$.

2. Максимальное количество точек $N_{\max}$ определяется размером памяти, доступной в буфере встраиваемой системы управления, зарезервированном под внутрисхемное измерение частотных характеристик.

Пример.

Заданы: $f_d = 100$ кГц, $N_{\min} = 10$, $N_{\max} = 1214$.

Определить набор параметров N, M, L для измерения на инжектируемой частоте $f_z = 22,1$ кГц с относительным отклонением до 0,1% ($\epsilon_f^* = 0,001$).

Коэффициент соотношения между периодом инжектируемого сигнала и периодом выполнения операций в системе:

$$R = \frac{f_d}{f_z} = \frac{100\,000}{22\,100} = 4,525.$$

Максимально возможное значение коэффициента децимации:

$$M_{\max} = \left\lfloor \frac{R}{2} \right\rfloor = 2.$$

Оптимальный набор параметров: $N = 43$, $M = 2$, $L = 19$.

Соответствующее приближение к начальному значению коэффициента R :

$$R' = \frac{M \cdot N}{\lfloor L \rfloor} = \frac{2 \cdot 43}{19} = 4,526.$$

Соответствующее приближение к исходному значению частоты f_z :

$$f'_z = \frac{L}{M \cdot N} f_d = \frac{19}{2 \cdot 43} 100\,000 = 22\,093,023 \text{ Гц.}$$

Листинг программы 2.1. Программа поиска оптимального набора параметров

```
1 import numpy as np
2
3 def find_multipliers(fz: float, fd: float, err_rel_ref: float,
4                     Nmin: int, Nmax: int):
5
6     R = fd / fz
7     if R < 2:
8         raise ValueError("fz must be < fd/2 for a valid solution.")
9     err_abs_ref = fz*err_rel_ref
10    Mmax = int(R / 2)
11    N_vals = np.arange(Nmin, Nmax + 1, dtype=float)
12    N_arr = np.empty(Mmax, dtype=np.int64)
13    M_arr = np.empty(Mmax, dtype=np.int64)
14    L_arr = np.empty(Mmax, dtype=np.int64)
15    fz_approx_arr = np.empty(Mmax)
16    err_abs_arr = np.empty(Mmax)
17    tol_flag_arr = np.empty(Mmax, dtype=bool)
18    for mdx, M in enumerate(range(1, Mmax+1)):
19        L = np.floor(M * N_vals / R)
20        np.maximum(L, 1, out=L)
21        R_approx = M * N_vals / L
22        fz_approx = fd / R_approx
23        err_abs = np.abs(fz - fz_approx)
24        valid_idx = np.nonzero(err_abs < err_abs_ref)[0]
25        if valid_idx.size > 0:
26            pos = valid_idx[0]
27            tol_flag_arr[mdx] = True
28        else:
29            pos = np.argmin(err_abs)
30            tol_flag_arr[mdx] = False
31        N_arr[mdx] = int(N_vals[pos])
32        M_arr[mdx] = M
33        L_arr[mdx] = int(L[pos])
34        fz_approx_arr[mdx] = fz_approx[pos]
35        err_abs_arr[mdx] = err_abs[pos]
36    if np.any(tol_flag_arr):
37        valid_mdx = np.nonzero(tol_flag_arr)[0]
38        best_mdx = valid_mdx[np.argmin(N_arr[valid_mdx])]
39    else:
40        best_mdx = np.argmin(err_abs_arr)
41
42    return (int(N_arr[best_mdx]),
43            int(M_arr[best_mdx]),
44            int(L_arr[best_mdx]))
```

Относительное отклонение частоты

$$\epsilon_f = \frac{|f'_z - f_z|}{f_z} = 0,000\,315$$

не превышает заданного ограничения $\epsilon_f^* = 0,001$.

Таким образом, чтобы воспроизвести частоту инжектируемого сигнала с точностью до 0,1% достаточно измерить $N = 43$ точки на $L = 19$ периодах инжектируемого сигнала. Период выборки при этом должен быть в $M = 2$ раза больше периода выполнения операций в системе.

2.6. Результаты измерений

3. Разработка алгоритмов идентификации параметров макромоделей

Фактически решаемая задача по идентификации параметров сведена к задаче instance-сегментации. Разработанная архитектура модели реализует детектирование целевых объектов по частотным характеристикам звеньев системы – определяются количество объектов и области частот, где они расположены.

3.1. Архитектура модели

Модель основана на автокодировщике, выполняющем преобразование C_{in} -канального тензора длиной L в C_{out} -канальный тензор той же длины:

$$\Gamma : \mathbb{R}^{C_{in} \times L} \mapsto \mathbb{R}^{C_{out} \times L}.$$

Выход представляет собой бинарную маску, каждый канал которой соответствует типу детектируемых объектов.

Преобразование Γ выполняется в 3 основных этапа:

- Кодирование в скрытое (латентное) пространство (CNN-энкодер):

$$\mathbf{F} : \mathbb{R}^{F_0 \times L} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Выделение наиболее информативных признаков в скрытом пространстве (bottleneck):

$$\mathbf{H} : \mathbb{R}^{F_3 \times L_3} \mapsto \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Декодирование из скрытого пространства (CNN-декодер):

$$\mathbf{Y} : \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_1 \times L_1}.$$

На входе и выходе архитектуры имеются дополнительные сверточные слой (без нормализации и активации). В декодер проброшены attention gated-skip-связи.




Рисунок 3.1. Блок-схема архитектуры модели

Количество обучаемых параметров модели порядка 5M.

3.1.1. Энкодер

Энкодер преобразует входные данные в латентное (скрытое) пространство уменьшенной размерности. В созданной реализации энкодер состоит из каскада N сверточных базовых блоков. Заложена residual-архитектура базового блока по типу «pre-activation».



Рисунок 3.2. Блок-схема базового блока энкодера/декодера

Каждый n -й базовый блок, $n \in \{1, \dots, N\}$, выполняет последовательно две свертки с ядрами $\mathbf{W}_n^1, \mathbf{W}_n^2$, соответственно.

$$\begin{aligned}\mathbf{z}_n^1 &= \mathbf{W}_n^1 * \sigma(\mathcal{N}(\mathbf{e}_{n-1})), \\ \mathbf{z}_n^2 &= \mathbf{W}_n^2 * \sigma(\mathcal{N}(\mathbf{z}_n^1)), \\ \mathbf{x}_n &= \mathbf{z}_n^2 \oplus \mathbf{s}_n,\end{aligned}$$

где $*$ – операция свертки, $\oplus$ – поэлементная сумма.

Сквозная связь «вход-выход» $\mathbf{s}_n$ (skip-connection) базового слоя приводится к числу каналов (фичей) на выходе (при необходимости):

$$\mathbf{s}_n = \begin{cases} \mathbf{W}_n^s * \mathbf{e}_{n-1}, & \text{если } F_{n-1} \neq F_n \\ \mathbf{e}_{n-1}, & \text{иначе,} \end{cases}$$

где $\mathbf{W}_n^s \in \mathbb{R}^{F_n \times F_{n-1}}$ – ядро проекции.

Между слоями энкодера выполняется уменьшение размерности тензор в 2 раза алгоритмом «nn.MaxPool1d»:

$$\mathbf{e}_n \rightarrow \mathbf{e}_n \downarrow_2.$$

Таким образом, в энкодере выполняется последовательное увеличение числа каналов (фичей) с одновременным уменьшением размерности тензора. Residual-архитектура с pre-activation обеспечивают лучший градиентный поток для быстрой сходимости при обучении [6]. Регуляризация выполняется алгоритмом «nn.Dropout1d» на выходе второй свертки.

3.1.2. Bottleneck

Bottleneck реализован на основе трансформера.




Рисунок 3.3. Блок-схема bottleneck-алгоритма

С выхода энкодера поступает тензор $\mathbf{e}_3 \in \mathbb{R}^{F_3 \times L_3}$. На входе Bottleneck длина тензора уменьшается до L_4 , а количество каналов увеличивается до F_4 :

$$\mathbf{b}_{\text{in}} = \sigma \left(\mathcal{N} \left(\mathbf{W}^P * \mathbf{e}_3 \downarrow \right) \right),$$

где $\mathbf{W}^P \in \mathbb{R}^{F_4 \times F_3}$, $\mathbf{b}_{\text{in}} \in \mathbb{R}^{F_4 \times L_4}$.

На входе данные нормализуются (pre-normalization, [7]), затем тензор преобразуется (permute) к формату $L \times F$

$$\mathbf{b}_{\text{in}} \rightarrow \mathcal{N}(\mathbf{b}_{\text{in}}) \rightarrow \mathbf{b}_{\text{in.perm}},$$

$\mathbf{b}_{\text{in.perm}} \in \mathbb{R}^{L_4 \times F_4}$, для совместимости с популярной реализацией алгоритма Multi-Head Self-Attention (MHSA, [8]):

$$\begin{aligned}
\mathbf{Q}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^Q, \\
\mathbf{K}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^K, \\
\mathbf{V}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^V, \\
\mathbf{H}_m &= \text{Softmax} \left(\frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_k}} \right) \mathbf{V}_m,
\end{aligned}$$

где $d_k = F_4/h$,

$$\begin{aligned}
\mathbf{W}_m^Q, \mathbf{W}_m^K, \mathbf{W}_m^V &\in \mathbb{R}^{F_4 \times d_k}, \\
\mathbf{Q}_m, \mathbf{K}_m, \mathbf{V}_m, \mathbf{H}_m &\in \mathbb{R}^{L_4 \times d_k},
\end{aligned}$$

$m \in \{1, \dots, h\}$.

Результаты вычисления h -«голов» алгоритма MHSA конкатенируются

$$\mathbf{MH}_{\text{perm}} = \text{Concat}(\mathbf{H}_1, \dots, \mathbf{H}_h) \mathbf{W}^O,$$

где $\mathbf{W}^O \in \mathbb{R}^{L_4 \times d_k}$, т.е. $\mathbf{MH}_{\text{perm}} \in \mathbb{R}^{L_4 \times F_4}$ – той же размерности, что и $\mathbf{b}_{\text{in.perm}}$.

Выход формируется в виде суммы со входным тензором, для чего размерности преобразуются обратно ($\mathbf{MH}_{\text{perm}} \rightarrow \mathbf{MH}$).

$$\mathbf{b}_{\text{attn}} = \mathbf{b}_{\text{in}} \oplus \mathbf{MH}.$$

После алгоритма MHSA выполняется нормализация данных для их последующей обработки полносвязными слоями (Multi-Layer Perceptron, MLP). Реализованы два Feed-Forward-слоя поканальной обработки с промежуточным увеличением скрытого пространства в r -раз:

$$\mathbf{MLP} = \mathbf{W}^{\text{MLP2}} \sigma \left(\mathbf{W}^{\text{MLP1}} \mathcal{N}(\mathbf{b}_{\text{attn}}) \right),$$

$$\mathbf{b}_{\text{out}} = \mathbf{b}_{\text{attn}} \oplus \mathbf{MLP},$$

$$\mathbf{W}^{\text{MLP1}} \in \mathbb{R}^{(r \cdot F_4) \times F_4},$$

$$\mathbf{W}^{\text{MLP2}} \in \mathbb{R}^{F_4 \times (r \cdot F_4)},$$

где $r > 1$ – кратность масштабирования скрытого пространства в MLP-алгоритме.

Регуляризация выполняется алгоритмом «nn.Dropout» после каждого Feed-Forward-слоя.

3.1.3. Декодер

Каждый слой декодера увеличивает разрешение и число каналов тензора, последовательно приближая данные к маскам длины L . Применяются residual-архитектура базового блока, в точности повторяющая блок энкодера (рис. 3.2):

$$\begin{aligned} \mathbf{x}_{\uparrow} &= \text{Upsample}(\mathbf{x}), \\ \mathbf{z} &= \mathbf{W} * \mathbf{x}_{\uparrow}, \\ \mathbf{y} &= \sigma(\mathcal{N}(\mathbf{z})). \end{aligned}$$

Слои декодера связаны с соответствующими выходами энкодера посредством Attention-gated-связей, по аналогии с [9].

Применено глубокое супервизирование (Deep Supervision) [10].

3.2. Предварительная обработка данных

Входные данные измеряются в широком диапазоне от -60 дБ до +60 дБ. Это 6 порядков. Типовые нормировки вида norm/std, min/max делают очень мелкими участки данных, модель к таким мелким изменениям нечувствительна. Более того, большую роль играют участки положительных и отрицательных значений. В общем, ломаются важные характерные особенности данных.

Принято решение перейти к наклонам и участкам выпуклости.

3.3. Обучение модели

3.3.1. Набор данных

Обучение модели выполнено на синтетическом наборе данных, сгенерированном под обучение разработанной архитектуры модели. Набор данных включает ‘Train’, ‘Val’ и ‘Test’-коллекций csv-таблиц частотных характеристик и json-файлов с координатами полюсов/нулей.

Тренировочный набор данных состоит из 72 случайных комбинаций полюсов/нулей обобщенной модели линейного динамического звена:

$$H(s) = G \frac{\prod_{m=1}^M \left(1 + \frac{s}{\omega_{z(m)}}\right)}{s^K \prod_{n=1}^N \left(1 + \frac{s}{\omega_{p(n)}}\right)} e^{-st_{\text{delay}}},$$

где

- G – пропорциональный коэффициент, $G \in \mathbb{R}$;
- t_{delay} – задержка времени, $t_{\text{delay}} > 0$;
- K – количество интеграторов, $K \in \mathbb{N}$;
- $\omega_{z(m)}$ – частоты нулей передаточной функции $H(s)$ в количестве M , $\omega_{z(m)} \in \mathbb{R}$;
- $\omega_{p(n)}$ – частоты полюсов передаточной функции $H(s)$ в количестве N , $\omega_{p(n)} \in \mathbb{R}$.

Каждой комбинации соответствует 500 значений, отличающихся диапазонами частот и частотами полюсов/нулей. Параметры G , t_{delay} заданы константами для последующего изменения в ходе обучения. Общий размер тренировочного набора данных – $72 \times 500 = 36\,000$ примеров. Размеры валидационного и тестового наборов – 14 400 и 7 200 примеров, соответственно.

В тестовом наборе данных параметры G , t_{delay} сгенерированы случайным образом; частотные характеристики приближены к реальным данным путем введения шума с нормальным распределением.

Полное описание генератора набора данных приведено в репозитории [11].

3.3.2. Функция потерь

Обучение производилось путем минимизации комбинированной функции потерь

$$w^{\text{BCE}} \mathcal{L}^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}^{\text{Dice}},$$

где

- $\mathcal{L}^{\text{BCE}}$ – перекрестная энтропия,
- $\mathcal{L}^{\text{Dice}}$ – функция потерь Дайса,
- w^{BCE} , w^{Dice} – весовые коэффициенты.

Перекрестная энтропия:

$$\mathcal{L}^{\text{BCE}} = -\frac{1}{L} \sum_{i=1}^L \left[t_i \log(\sigma(d_i)) + (1 - t_i) \log(1 - \sigma(d_i)) \right],$$

где t_i – ожидаемое значение (0 или 1), d_i – логиты с выхода декодера (логит). Логиты преобразуются в непрерывный диапазон $[0; 1]$ функцией

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Функция потерь Дайса:

$$\mathcal{L}^{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^L d_i t_i}{\sum_{i=1}^L d_i + \sum_{i=1}^L t_i + \epsilon}. \quad (3.1)$$

С целью более глубокого обучения полная функция ошибки формируется по каждому выходу n декодера:

$$\mathcal{L} = \frac{1}{w} \sum_{n=1}^N \left[w_n \left(w^{\text{BCE}} \mathcal{L}_n^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}_n^{\text{Dice}} \right) \right],$$

w – сумма всех коэффициентов w_n .

3.3.3. Метрики

Оценка качества работы модели производилась по коэффициенту Дайса:

$$\text{Dice} = \frac{2 \sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i + \epsilon}, \quad (3.2)$$

где p_i – значения бинарной маски на выходе модели,

$$p_i = \mathbb{I}(\sigma(d_i) > 0,5). \quad (3.3)$$

где $\mathbb{I}(\cdot)$ – индикаторная функция, принимающая значения «0» или «1».

В качестве вспомогательной метрики использовался коэффициент Жак-кара:

$$\text{IoU} = \frac{\sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i - \sum_{i=1}^L p_i t_i + \epsilon}. \quad (3.4)$$

Обучение выполнено на NVIDIA GeForce RTX3060 (12 ГБ), torch=2.6.0, CUDA=12.6, cuDNN=9.5.1. Размер батча: 360. Решатель: «Adam». Обучение модели выполнялось по лучшему коэффициенту Дайса на валидации (см. раздел 3.1). Весовые коэффициенты функции ошибки: $w^{\text{BCE}} = 0,25$, $w^{\text{Dice}} = 0,75$.

Таблица 3.1. Метрики результирующие

		Dice	IoU	Комментарий
1	Train	0.9092	0.8580	Случайные аугментации: G , t_{delay} , шумы.
2	Val	0.9393	0.9030	Нет аугментаций.*
3	Test	0.9221	0.8774	Нет аугментаций.**

* Набор данных изначально сформирован с разными G , t_{delay} .

** Набор данных изначально сформирован с шумами и разными G , t_{delay} .

Результаты инференса случайных примеров из тестового набора данных

3.4. Результаты измерений

Проведен эксперимент на лабораторном стенде (Приложение А). Внутрисхемно измерена частотная характеристика цифрового звена

$$H(z) = \frac{\alpha}{1 - (1 - \alpha)z^{-1}},$$

где $\alpha = 0.12566$, частота тактирования 100 кГц, и выполнена детекция его полюсов и нулей

Заключение

Выводы по работе, ключевые результаты, перспективы дальнейших исследований.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Stability of Shipboard DC Power Distribution: Online Impedance-Based Systems Methods / A. Riccobono [и др.] // IEEE Electrification Magazine. — 2017. — Сент. — Т. 5, № 3. — С. 55—67. — ISSN 2325-5987. — DOI: [10.1109/MELE.2017.2718858](https://doi.org/10.1109/MELE.2017.2718858).
2. Triverio P. Vector Fitting. — 2019. — arXiv: [1908.08977v1](https://arxiv.org/abs/1908.08977) [physics.comp-ph]. — URL: <https://arxiv.org/abs/1908.08977> ; Draft of book chapter to appear in *Handbook on Model Order Reduction*, edited by P. Benner, S. Grivet-Talocia, A. Quarteroni, G. Rozza, W. H. A. Schilders, L. M. Silveira, De Gruyter.
3. Hua Q., Shen M. Deep Learning-Enhanced Parameter Extraction for Equivalent Circuit Modeling in Electrochemical Impedance Spectroscopy // 2023 IEEE Nordic Circuits and Systems Conference (NorCAS). — IEEE, 2023. — С. 1—6. — DOI: [10.1109/NorCAS58970.2023.10305482](https://doi.org/10.1109/NorCAS58970.2023.10305482). — URL: <https://doi.org/10.1109/NorCAS58970.2023.10305482> ; Accepted author manuscript, peer reviewed version.
4. Deep Learning for Segmentation of Cracks in High-Resolution Images of Steel Bridges / A. Kompanets [и др.] // Automation in Construction. — 2025. — URL: <https://arxiv.org/abs/2403.17725> ; Preprint submitted to Automation in Construction, arXiv:2403.17725v1.
5. Optimized deep encoder-decoder methods for crack segmentation / J. König [и др.] // Digital Signal Processing. — 2021. — Т. 108. — С. 102907. — DOI: [10.1016/j.dsp.2020.102907](https://doi.org/10.1016/j.dsp.2020.102907).
6. Identity Mappings in Deep Residual Networks / K. He [и др.] // European Conference on Computer Vision (ECCV). — Springer, 2016. — С. 630—645. — DOI: [10.1007/978-3-319-46493-0_38](https://doi.org/10.1007/978-3-319-46493-0_38). — arXiv: [1603.05027](https://arxiv.org/abs/1603.05027) [cs.CV]. — URL: <https://arxiv.org/abs/1603.05027>.
7. On Layer Normalization in the Transformer Architecture / R. Xiong [и др.] // Proceedings of the 37th International Conference on Machine Learning

- (ICML). — PMLR, 2020. — C. 10524—10533. — URL: <https://arxiv.org/abs/2002.04745>.
8. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. T. 30. — Curran Associates, Inc., 2017. — C. 5998—6008. — URL: <https://arxiv.org/abs/1706.03762>.
 9. Attention U-Net: Learning Where to Look for the Pancreas / O. Oktay [и др.] // 1st Conference on Medical Imaging with Deep Learning (MIDL). — 2018. — URL: <https://arxiv.org/abs/1804.03999>.
 10. Deeply-Supervised Nets / C.-Y. Lee [и др.] // Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics. T. 38 / под ред. G. Lebanon, S. V. N. Vishwanathan. — San Diego, California, USA : PMLR, 09–12 May.2015. — C. 562—570. — (Proceedings of Machine Learning Research). — URL: <https://proceedings.mlr.press/v38/lee15a.html>.
 11. *Gorbunov R.* zeros-poles-masks. — 2026. — GitHub repository; last accessed: 2026-05-04. <https://github.com/romangorbunov91/zeros-poles-masks>.

Приложение А. Лабораторный стенд

1. Макет источника питания 180 Вт – 1 шт.
2. Источник питания GW INSTEK GPC-3060D (2x30 В, 2x6 А) – 1 шт.
3. Нагрузка электронная АКИП 1380/1 (150 В, 30 А, 300 Вт) – 1 шт.
4. Измеритель частотных характеристик AP300 – 1 шт.
5. Осциллограф АКИП-4126/4А-Х – 1 шт.
6. Мультиметр FLUKE 17B+ – 1 шт.




Рисунок А.1. Лабораторный стенд

Приложение Б. Внедрение результатов работы