

**Университет ИТМО**

Факультет технологий искусственного интеллекта

**МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ**

по направлению подготовки

**27.04.03 Системный анализ и управление**

**Тема: «Алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания»**

**Выполнил:** Горбунов Роман Леонидович

**Научный руководитель:** к.ф.-м.н., Бабушкин М.В.

Санкт-Петербург, 2026

## **Аннотация**

Краткое описание работы.

**Ключевые слова:** ключ1, ключ2, ключ3.

## Содержание

|                                                                                                                             |    |
|-----------------------------------------------------------------------------------------------------------------------------|----|
| Введение . . . . .                                                                                                          | 4  |
| 1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов . . . . . | 5  |
| 1.1. Алгоритмы измерения частотных характеристик . . . . .                                                                  | 5  |
| 1.2. Алгоритмы идентификации параметров . . . . .                                                                           | 5  |
| 2. Разработка алгоритмов внутрисхемного измерения частотных характеристик . . . . .                                         | 6  |
| 2.1. Общие сведения . . . . .                                                                                               | 6  |
| 2.2. Алгоритм 1 . . . . .                                                                                                   | 8  |
| 2.3. Алгоритм 2 . . . . .                                                                                                   | 10 |
| 2.4. Алгоритм 3 . . . . .                                                                                                   | 13 |
| 2.5. Оптимальный алгоритм . . . . .                                                                                         | 15 |
| 3. Разработка алгоритмов идентификации параметров макромоделей . .                                                          | 17 |
| 3.1. Архитектура модели . . . . .                                                                                           | 17 |
| 3.1.1. Энкодер . . . . .                                                                                                    | 18 |
| 3.1.2. Bottleneck . . . . .                                                                                                 | 19 |
| 3.1.3. Декодер . . . . .                                                                                                    | 21 |
| 3.2. Обучение модели . . . . .                                                                                              | 22 |
| 3.2.1. Набор данных . . . . .                                                                                               | 22 |
| 3.2.2. Функция потерь . . . . .                                                                                             | 23 |
| 3.2.3. Метрики . . . . .                                                                                                    | 23 |
| 3.3. Результаты . . . . .                                                                                                   | 24 |
| Заключение . . . . .                                                                                                        | 25 |
| Список использованных источников . . . . .                                                                                  | 26 |
| Приложение А. Лабораторный стенд . . . . .                                                                                  | 27 |
| Приложение Б. Внедрение результатов работы . . . . .                                                                        | 28 |

## **Введение**

**Актуальность темы работы** Работа связана с системами управления вторичными источниками электропитания, их настройкой, отладкой и контролем состояния.

### **Цели и задачи работы**

**Цель работы** - разработать алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания.

### **Задачи работы:**

1. Разработать алгоритмы внутрисхемного измерения частотных характеристик.
2. Разработать алгоритмы идентификации параметров на основе измеренных частотных характеристик.
3. Выполнить экспериментальную оценку показателей качества измерений и идентификации параметров.

### **Основные результаты работы**

### **Практическая значимость результатов работы**

### **Апробация результатов работы**

### **Объем и структура работы**

# **1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов**

## **1.1. Алгоритмы измерения частотных характеристик**

## **1.2. Алгоритмы идентификации параметров**

## 2. Разработка алгоритмов внутрисхемного измерения частотных характеристик

### 2.1. Общие сведения

Рассматриваемая система аналого-цифрового преобразования и цифровой обработки сигналов с воздействием на объект управления посредством широтно-импульсной модуляции (рис. (2.1)).




Рисунок 2.1. Рассматриваемая система

Операции выполняются циклически с постоянным периодом  $T_d$ , соответствующим базовой частоте дискретного регулирования  $f_d = 1/T_d$ .

В канал управления системы аддитивно инжектируется сигнал в виде дискретной последовательности  $z[n]$ .

Откликом системы являются два непрерывных сигнала:  $x_c(t)$ ,  $y_c(t)$ .

Система преобразует непрерывные сигналы  $x_c(t)$ ,  $y_c(t)$  в дискретные последовательности  $x[n]$ ,  $y[n]$ .

Преобразование осуществляется посредством дискретизации:

$$\begin{aligned} x[n] &= x_c(nT_s), \\ y[n] &= y_c(nT_s), \end{aligned} \tag{2.1}$$

где  $T_s$  – период дискретизации,  $T_s \geq T_d$ .

## Коэффициенты разложения дискретных последовательностей

$$x[n] = \frac{1}{N} \sum_{l=0}^{N-1} X[l] e^{j \frac{2\pi}{N} ln},$$

$$y[n] = \frac{1}{N} \sum_{l=0}^{N-1} Y[l] e^{j \frac{2\pi}{N} ln}$$

определяются по  $N$ -последовательным отсчетам дискретных последовательностей  $x[n]$ ,  $y[n]$ :

$$X[l] = \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} nl},$$

$$Y[l] = \sum_{n=0}^{N-1} y[n] e^{-j \frac{2\pi}{N} nl}.$$
(2.2)

Коэффициенты  $X[l]$ ,  $Y[l] \in \mathbb{C}$ , представляют собой дискретные периодические последовательности с периодом  $N$ .

При условии, что измерительное окно длительностью  $T_h$  вмещает целое количество  $N$  периодов дискретизации  $T_s$  ( $T_h = N \cdot T_s$ ) дискретные последовательности  $X[l]$ ,  $Y[l]$  на отрезке  $l \in [0; N-1]$  длины  $N$  содержат коэффициенты разложения  $x[n]$ ,  $y[n]$  в диапазоне частот  $f \in [0, f_s/2]$  с шагом по частоте  $\Delta f = 1/T_h$ .

Составляющим с частотой  $f_h$  соответствуют  $X[l]$ ,  $Y[l]$  при  $l = 1$ , а с частотой  $f_s/2$  – при  $l = \lfloor (N-1)/2 \rfloor$ .

В данном разделе рассматриваются алгоритмы измерения частотных характеристик, основанные на воздействии на систему дискретной последовательностью  $z[n]$  моногармонического типа, определяемой косинусоидальной функцией

$$z[n] = Z \cos(\underbrace{2\pi f_z T_d n}_{\omega_z})$$

с частотой  $f_z$ .

Минимальное количество отсчетов  $N$  на измерительном окне  $T_h$  принято равным 3, поэтому частота  $f_z$  ограничена сверху значением  $f_d/3$ .

Модель сигналов-откликов системы принята следующей:

$$\begin{aligned}x_c(t) &= X_0 + X_z \cos(\omega_z t + \phi_x) + X_g \cos(\omega_g t), \\y_c(t) &= Y_0 + Y_z \cos(\omega_z t + \phi_y) + Y_g \cos(\omega_g t),\end{aligned}$$

где  $\omega_z = 2\pi f_z$ .

Алгоритм измерения частотной характеристики звена системы основан на последовательной смене периода инжектируемого сигнала  $T_z = 1/f_z$  в серии из  $K$ -измерений.

Каждому  $k$ -му измерению,  $k \in [1, K]$ , соответствует пара параметров  $Z^{(k)}$ ,  $T_z^{(k)}$ , следовательно, и набор дискретных последовательностей  $x^{(k)}[n]$ ,  $y^{(k)}[n]$ ,  $z^{(k)}[n]$ , а также коэффициентов  $X^{(k)}[l]$ ,  $Y^{(k)}[l]$ .

Под частотной характеристикой понимается набор пар значений  $f_z^{(k)}$ ,  $W^{(k)}$ , где в каждом  $k$ -ом измерении

$$W^{(k)} = \frac{Y^{(k)}[L^{(k)}]}{X^{(k)}[L^{(k)}]} = |W^{(k)}| e^{j\angle W^{(k)}}, \quad (2.3)$$

$$L^{(k)} = T_h^{(k)} / T_z^{(k)}.$$

Пары значений  $f_z^{(k)}$ ,  $|W^{(k)}|$  и  $f_z^{(k)}$ ,  $\angle W^{(k)}$  образуют амплитудно-частотную и фазо-частотную характеристики, соответственно.

$$\begin{aligned}|W^{(k)}| &= \frac{|Y^{(k)}[L^{(k)}]|}{|X^{(k)}[L^{(k)}]|}, \\ \angle W^{(k)} &= \angle Y^{(k)}[L^{(k)}] - \angle X^{(k)}[L^{(k)}].\end{aligned} \quad (2.4)$$

## 2.2. Алгоритм 1

$$T_h - var, N - var$$

Данный алгоритм характеризуется тем, что в серии из  $K$  изменений периода  $T_z$  инжектируемого сигнала ( $T_z^{(k)}$ ,  $k \in [1; K]$ ):

- Длительность  $T_h$  измерительного окна равна периоду  $T_z$  инжектируемого сигнала ( $T_h^{(k)} = T_z^{(k)}$ ,  $T_h^{(k)} - var$ ).
- Период дискретизации  $T_s$  одинаков для всех значений  $T_z$  и равен периоду  $T_d$  выполнения операций в системе ( $T_s^{(k)} = T_d$ ,  $T_s^{(k)} = const$ ).

- Количество точек  $N$  дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), изменяется пропорционально  $T_z (N^{(k)} - var)$ .

Период инжектируемого сигнала

$$T_z^{(k)} = N^{(k)} \cdot T_s^{(k)} = N^{(k)} \cdot T_d$$

кратен периоду  $T_d$  выполнения операций в системе (рис. 2.2).




Рисунок 2.2. Размер  $N^{(k)}$  дискретной последовательности при изменении периода  $T_z^{(k)}$  инжектируемого сигнала

В связи с тем, что  $T_h^{(k)} = T_z^{(k)}$  составляющей с частотой  $f_z^{(k)}$  соответствуют коэффициенты  $X^{(k)} [l]$ ,  $Y^{(k)} [l]$  всегда при  $l = 1$ , т.е. коэффициент передачи динамического звена на частоте  $f_z^{(k)}$  определяется выражением (2.3) при  $L^{(k)} = 1$ .

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты  $f_z$  инжектируемого сигнала в серии из  $K$  измерений **характерны следующие особенности:**

1. Минимально возможная частота  $f_z$  напрямую определяется максимальным значением измерительного окна  $T_h$ , которое ограничено сверху

только объемом памяти для хранения массивов-откликов  $x[n]$ ,  $y[n]$ .

2. Максимально возможная частота  $f_z$  в пределе составляет  $f_d/3$ .
3. В памяти достаточно хранить  $N^{(k)} = f_d/f_z^{(k)}$ -значений каждого массива-отклика  $x^{(k)}[n]$ ,  $y^{(k)}[n]$ , причем величина  $N$  не является постоянной и уменьшается с ростом частоты  $f_z$  вплоть до  $N = 3$  при  $f_z \rightarrow f_d/3$ .
4. Шаг приращения периода  $T_z$  инжектируемого сигнала (разрешающая способность):  $\Delta T_z = T_d$ .
5. Потенциальные значения частот  $f_z$  инжектируемого сигнала неравномерно распределены на интервале  $f \in (0; f_d/2)$  возможных значений:
  - На полуинтервале  $f \in [f_d/10; f_d/2)$  частота  $f_z$  может принимать значения всего из 8-ми возможных:  
 $f_z = (f_d/10, f_d/9, \dots, f_d/3)$ .
  - На полуинтервале  $f \in [f_d/100; f_d/10)$  – одно из 90 возможных:  
 $f_z = (f_d/100, f_d/99, \dots, f_d/11)$ .
  - На интервале  $f \in (0; f_d/100)$  – сколь угодно много значений, ограниченное исключительно объемом памяти для хранения массивов-откликов  $x[n]$ ,  $y[n]$ .

### 2.3. Алгоритм 2

$$T_h - var, N = const$$

Данный алгоритм характеризуется тем, что в серии из  $K$  изменений периода  $T_z$  инжектируемого сигнала ( $T_z^{(k)}$ ,  $k \in [1; K]$ ):

- Длительность  $T_h$  измерительного окна равна периоду  $T_z$  инжектируемого сигнала ( $T_h^{(k)} = T_z^{(k)}$ ,  $T_h^{(k)} - var$ ).
- Количество точек  $N$  дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменно для всех значений периода  $T_z$  ( $N^{(k)} = const$ ).
- Период дискретизации  $T_s$  изменяется в целях обеспечить  $N^{(k)} = const$  при изменении периода  $T_z$  инжектируемого сигнала ( $T_s^{(k)} - var$ ).

Постоянство  $N$  при изменении периода  $T_z$  инжектируемого сигнала обеспечивается децимацией (прореживанием) дискретных последовательностей  $x'[n]$ ,  $y'[n]$ .

Выражениями  $x'[n]$ ,  $y'[n]$  обозначены дискретные последовательности,

формируемые в результате дискретизации откликов системы  $x_c(t)$ ,  $y_c(t)$  непосредственно с периодом  $T_d$  выполнения операций в системе.

Дискретные последовательности  $x^{(k)}[n]$ ,  $y^{(k)}[n]$  формируются в результате децимации  $x'^{(k)}[n]$ ,  $y'^{(k)}[n]$  с коэффициентом децимации  $M^{(k)} \in \mathbb{N}$

$$\begin{aligned} x^{(k)}[n] &= x'^{(k)}[n \cdot M^{(k)}] = x_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}) \\ y^{(k)}[n] &= y'^{(k)}[n \cdot M^{(k)}] = y_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}), \end{aligned}$$

так, что период инжектируемого сигнала всегда кратен периоду  $T_d$  выполнения операций в системе:

$$T_z^{(k)} = N^{(k)} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}.$$

Дискретные последовательности  $x^{(k)}[n]$ ,  $y^{(k)}[n]$  формируются по правилу (2.1) фактически с эквивалентным периодом дискретизации  $T_s^{(k)} = M^{(k)} \cdot T_d$  (рис. (2.3)). Под эквивалентным понимается такой период дискретизации, при котором формировалась бы точно такая же дискретная последовательность.




Рисунок 2.3. Период дискретизации  $T_s^{(k)}$  при изменении периода  $T_s^{(z)}$  инжестируемого сигнала

Измерительное окно  $T_h^{(k)} = T_z^{(k)}$  при всех  $k$ , поэтому, также как и в алгоритме 2.2, составляющей с частотой  $f_z^{(k)}$  соответствуют коэффициенты  $X^{(k)}[l]$ ,  $Y^{(k)}[l]$  всегда при  $l = 1$ , т.е. коэффициент передачи динамического звена на частоте  $f_z^{(k)}$  определяется выражением (2.3) при  $L^{(k)} = 1$ .

**Принципиальное отличие** от алгоритма 2.2 связано с потенциально меньшим размером  $N$  массивов-откликов  $x[n]$ ,  $y[n]$  ( $N \in \mathbb{N}$  – независимая переменная,  $N > 2$ ).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты  $f_z$  инжестируемого сигнала в серии из  $K$  измерений **характерны следующие особенности**:

1. Минимально возможная частота  $f_z$  напрямую определяется максимальным значением измерительного окна  $T_h$ , причем требуемый объем памяти для хранения массивов-откликов  $x^{(k)}[n]$ ,  $y^{(k)}[n]$  одинаков для всех длительностей  $T_h^{(k)}$  и частот  $f_z^{(k)}$ .
2. Максимально возможная частота  $f_z$  составляет  $f_d/N$ .

3. Шаг приращения периода  $T_z$  инжектируемого сигнала (разрешающая способность) в  $N$ -раз больше, в сравнении с алгоритмом 2.2 ( $\Delta T_z = N \cdot T_d$ ).
4. Грубый шаг приращения периода обуславливает еще более неравномерное распределение частот. Например, в диапазоне частот  $f \in [f_d/100; f_d/10]$  при  $N = 10$  частота  $f_z$  инжектируемого сигнала может принимать значения всего из 10-ти возможных:  
 $f_z = (f_d/100, f_d/90, \dots, f_d/10)$ .

## 2.4. Алгоритм 3

$$T_h = \text{const}, N = \text{const}$$

Данный алгоритм характеризуется тем, что в серии из  $K$  изменений периода  $T_z$  инжектируемого сигнала ( $T_z^{(k)}, k \in [1; K]$ ):

- Длительность  $T_h$  измерительного окна неизменна и равна наибольшему периоду инжектируемого сигнала ( $T_h^{(k)} = T_z^{\max}, T_h^{(k)} = \text{const}$ ).
- Период дискретизации  $T_s$  одинаков для всех значений  $T_z$  ( $T_s^{(k)} = \text{const}$ ) и кратен периоду  $T_d$  выполнения операций в системе ( $T_s^{(k)} = M \cdot T_d$ ); коэффициент децимации  $M = \text{const}, M \in \mathbb{N}$ .
- Количество точек  $N \in \mathbb{N}$  дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), неизменно для всех значений  $T_z^{(k)}$  ( $N^{(k)} = \text{const}$ ),

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

Математическая обработка в соответствии с (2.2) накладывает ограничение на период  $T_z$  инжектируемого сигнала – требуется, чтобы измерительное окно  $T_h$  вмещало целое число периодов  $T_z$  (рис. 2.4), т.е. для каждого значения  $T_z^{(k)}$  должно выполняться

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)}, \quad (2.5)$$

где  $L^{(k)} \in \mathbb{N}$ .




Рисунок 2.4. Период инжектируемого сигнала при  $T_h^{(k)} = \text{const}$

В соответствии с (2.5), частота  $f_z^{(k)}$  инжектируемого сигнала потенциально принимает значения

$$f_z^{(k)} = L^{(k)} \frac{1}{T_h} = L^{(k)} \Delta f_z,$$

где  $\Delta f_z$  – шаг приращения частоты инжектируемого сигнала

В связи с  $\Delta f_z = \text{const}$  потенциальные значения частот  $f_z^{(k)}$  равномерно распределены на интервале возможных значений, что **является главной отличительной особенностью алгоритма** в сравнении с алгоритмами 2.2, 2.3.

Составляющей с частотой  $f_z^{(k)}$  соответствуют коэффициенты  $X^{(k)}[l]$ ,  $Y^{(k)}[l]$  при разных значениях  $L^{(k)}$ , определяемых выражением (2.3).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты  $f_z^{(k)}$  инжектируемого сигнала в серии из  $K$  измерений **характерны следующие особенности**:

1. Минимально возможная частота  $f_z$  напрямую определяется максимальным значением измерительного окна  $T_h$ , которое ограничено сверху только объемом памяти для хранения массивов-откликов  $x[n]$ ,  $y[n]$ .

2. Максимально возможная частота  $f_z$  в пределе составляет  $f_s/3$ .
3. Требуемый объем памяти для хранения массивов-откликов  $x^{(k)}[n]$ ,  $y^{(k)}[n]$  одинаков для всех частот  $f_z^{(k)}$  инжектируемого сигнала.
4. Период  $T_z$  инжектируемого сигнала потенциально принимает значения от  $T_z^{min} = 3T_s$  до  $T_z^{max} = T_h$ , но при условии  $T_h/T_s \in \mathbb{N}$ .
5. Шаг приращения частоты  $f_z$  инжектируемого сигнала (разрешающая способность):  $\Delta f_z = 1/T_h$ .

## 2.5. Оптимальный алгоритм

Данный алгоритм характеризуется тем, что в серии из  $K$  изменений периода  $T_z$  инжектируемого сигнала ( $T_z^{(k)}$ ,  $k \in [1; K]$ ):

- Длительность  $T_h$  измерительного окна кратен периоду инжектируемого сигнала ( $T_h^{(k)} = L^{(k)}T_z^{(k)}$ ,  $T_h^{(k)} = \text{var}$ ).
- Период дискретизации  $T_s$  кратен периоду  $T_d$  выполнения операций в системе ( $T_s^{(k)} = M^{(k)} \cdot T_d$ ); коэффициент децимации  $M^{(k)} = \text{var}$ ,  $M \in \mathbb{N}_{>0}$ .
- Количество точек  $N \in \mathbb{N}_{>0}$  дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (2.2), соответствует конкретному значению  $T_z^{(k)}$  ( $N^{(k)} = \text{var}$ ).

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

Соотношение между периодом инжектируемого сигнала и периодом дискретизации

$$R^{(k)} = \frac{T_z^{(k)}}{T_s^{(k)}},$$

где  $R^{(k)} \in \mathbb{R}$

Длительность измерительного окна

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)} = L^{(k)} \cdot R^{(k)} \cdot T_s^{(k)} = \underbrace{L^{(k)} \cdot R^{(k)}}_{N^{(k)}} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}.$$

Таким образом, для каждой  $k$ -й частоты  $f_z$  задача сводится к поиску набора целых чисел  $\mathbf{p}^{(k)} = (N^{(k)}, M^{(k)}, L^{(k)}) \in \mathbb{N}_{>0}^3$ , при которых обеспечивается

частота  $f_z$  с заданной степенью приближения к  $f_z$ .

При ограничениях

$$N_{\min} \leq N^{(k)} \leq N_{\max},$$

Если несколько наборов параметров удовлетворяют заданной точности, то из них выбирается с наименьшим  $N$ .

Если ни один набор параметров не удовлетворяет заданной точности, то выбирается набор с наименьшим отклонением  $f_z$  от заданной  $f_z$ .

Последовательность в алгоритме:

1. Вычисляется коэффициент
2. Перебираются значения  $N$  из диапазона  $N_{\min}, N_{\max}$ .

### 3. Разработка алгоритмов идентификации параметров макромоделей

Фактически решаемая задача по идентификации параметров сведена к задаче instance-сегментации. Разработанная архитектура модели реализует детектирование целевых объектов по частотным характеристикам звеньев системы – определяются количество объектов и области частот, где они расположены.

#### 3.1. Архитектура модели

Модель основана на автокодировщике, выполняющем преобразование  $C_{in}$ -канального тензора длиной  $L$  в  $C_{out}$ -канальный тензор той же длины:

$$\Gamma : \mathbb{R}^{C_{in} \times L} \mapsto \mathbb{R}^{C_{out} \times L}.$$

Выход представляет собой бинарную маску, каждый канал которой соответствует типу детектируемых объектов.

Преобразование  $\Gamma$  выполняется в 3 основных этапа:

- Кодирование в скрытое (латентное) пространство (CNN-энкодер):

$$\mathbf{F} : \mathbb{R}^{F_0 \times L} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Выделение наиболее информативных признаков в скрытом пространстве (bottleneck):

$$\mathbf{H} : \mathbb{R}^{F_3 \times L_3} \mapsto \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Декодирование из скрытого пространства (CNN-декодер):

$$\mathbf{Y} : \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_1 \times L_1}.$$

На входе и выходе архитектуры имеются дополнительные сверточные слои (без нормализации и активации). В декодер проброшены attention gated-skip-

СВЯЗИ.




Рисунок 3.1. Блок-схема архитектуры модели

### 3.1.1. Энкодер

Энкодер преобразует входные данные в латентное (скрытое) пространство уменьшенной размерности. В созданной реализации энкодер состоит из каскада  $N$  сверточных базовых блоков. Заложена residual-архитектура базового блока по типу «pre-activation».




Рисунок 3.2. Блок-схема базового блока энкодера

Каждый  $n$ -й базовый блок,  $n \in \{1, \dots, N\}$ , выполняет последовательно две свертки с ядрами  $W_n^1$ ,  $W_n^2$ , соответственно.

$$\begin{aligned}
\mathbf{z}_n^1 &= \mathbf{W}_n^1 * \sigma(\mathcal{N}(\mathbf{e}_{n-1})), \\
\mathbf{z}_n^2 &= \mathbf{W}_n^2 * \sigma(\mathcal{N}(\mathbf{z}_n^1)), \\
\mathbf{x}_n &= \mathbf{z}_n^2 \oplus \mathbf{s}_n,
\end{aligned}$$

где  $*$  – операция свертки,  $\oplus$  – поэлементная сумма.

Сквозная связь «вход-выход»  $\mathbf{s}_n$  (skip-connection) базового слоя приводится к числу каналов (фичей) на выходе (при необходимости):

$$\mathbf{s}_n = \begin{cases} \mathbf{W}_n^s * \mathbf{e}_{n-1}, & \text{если } F_{n-1} \neq F_n \\ \mathbf{e}_{n-1}, & \text{иначе,} \end{cases}$$

где  $\mathbf{W}_n^s \in \mathbb{R}^{F_n \times F_{n-1}}$  – ядро проекции.

Между слоями энкодера выполняется уменьшение размерности тензор в 2 раза алгоритмом «nn.MaxPool1d»:

$$\mathbf{e}_n \rightarrow \mathbf{e}_n \downarrow_2.$$

Таким образом, в энкодере выполняется последовательное увеличение числа каналов (фичей) с одновременным уменьшением размерности тензора. Residual-архитектура с pre-activation обеспечивают лучший градиентный поток для быстрой сходимости при обучении [1]. Регуляризация выполняется алгоритмом «nn.Dropout1d» на выходе второй свертки.

### 3.1.2. Bottleneck

Bottleneck реализован на основе трансформера.




Рисунок 3.3. Блок-схема bottleneck-алгоритма

С выхода энкодера поступает тензор  $\mathbf{e}_3 \in \mathbb{R}^{F_3 \times L_3}$ . На входе Bottleneck длина тензора уменьшается до  $L_4$ , а количество каналов увеличивается до  $F_4$ :

$$\mathbf{b}_{\text{in}} = \sigma \left( \mathcal{N} \left( \mathbf{W}^P * \mathbf{e}_3 \downarrow \right) \right),$$

где  $\mathbf{W}^P \in \mathbb{R}^{F_4 \times F_3}$ ,  $\mathbf{b}_{\text{in}} \in \mathbb{R}^{F_4 \times L_4}$ .

На входе данные нормализуются (pre-normalization, [2]), затем тензор преобразуется (permute) к формату  $L \times F$

$$\mathbf{b}_{\text{in}} \rightarrow \mathcal{N}(\mathbf{b}_{\text{in}}) \rightarrow \mathbf{b}_{\text{in.perm}},$$

$\mathbf{b}_{\text{in.perm}} \in \mathbb{R}^{L_4 \times F_4}$ , для совместимости с популярной реализацией алгоритма Multi-Head Self-Attention (MHSA, [3]):

$$\begin{aligned} \mathbf{Q}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^Q, \\ \mathbf{K}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^K, \\ \mathbf{V}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^V, \\ \mathbf{H}_m &= \text{Softmax} \left( \frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_k}} \right) \mathbf{V}_m, \end{aligned}$$

где  $d_k = F_4/h$ ,

$$\begin{aligned} \mathbf{W}_m^Q, \mathbf{W}_m^K, \mathbf{W}_m^V &\in \mathbb{R}^{F_4 \times d_k}, \\ \mathbf{Q}_m, \mathbf{K}_m, \mathbf{V}_m, \mathbf{H}_m &\in \mathbb{R}^{L_4 \times d_k}, \end{aligned}$$

$m \in \{1, \dots, h\}$ .

Результаты вычисления  $h$ -«голов» алгоритма MHSA конкатенируются

$$\mathbf{MH}_{\text{perm}} = \text{Concat}(\mathbf{H}_1, \dots, \mathbf{H}_h) \mathbf{W}^O,$$

где  $\mathbf{W}^O \in \mathbb{R}^{L_4 \times d_k}$ , т.е.  $\mathbf{MH}_{\text{perm}} \in \mathbb{R}^{L_4 \times F_4}$  – той же размерности, что и  $\mathbf{b}_{\text{in.perm}}$ .

Выход формируется в виде суммы со входным тензором, для чего размерности преобразуются обратно ( $\mathbf{MH}_{\text{perm}} \rightarrow \mathbf{MH}$ ).

$$\mathbf{b}_{\text{attn}} = \mathbf{b}_{\text{in}} \oplus \mathbf{MH}.$$

После алгоритма MHSA выполняется нормализация данных для их последующей обработки полносвязными слоями (Multi-Layer Perceptron, MLP). Реализованы два Feed-Forward-слоя с промежуточным увеличением скрытого пространства в  $r$ -раз:

$$\mathbf{MLP} = \text{Dropout} \left( \mathbf{W}^{\text{MLP2}} \cdot \sigma \left( \mathbf{W}^{\text{MLP1}} \mathcal{N}(\mathbf{b}_{\text{attn}}) \right) \right),$$

$$\mathbf{b}_{\text{out}} = \mathbf{b}_{\text{attn}} \oplus \mathbf{MLP},$$

$$\mathbf{W}^{\text{MLP1}} \in \mathbb{R}^{(r \cdot F_4) \times F_4},$$

$$\mathbf{W}^{\text{MLP2}} \in \mathbb{R}^{F_4 \times (r \cdot F_4)},$$

где  $r$  – кратность масштабирования скрытого пространства в MLP-алгоритме.

Регуляризация выполняется алгоритмом «nn.Dropout» после каждого Feed-Forward-слоя.

### 3.1.3. Декодер

Каждый слой декодера увеличивает разрешение массива, последовательно приближая данные к маскам длины  $L$ .

$$\mathbf{x}_{\uparrow} = \text{Upsample}(\mathbf{x}),$$

$$\mathbf{z} = \mathbf{W} * \mathbf{x}_{\uparrow},$$

$$\mathbf{y} = \sigma(\mathcal{N}(\mathbf{z}))$$

Слои декодера связаны с соответствующими выходами энкодера посредством Attention-gated-связей, по аналогии с [4].

## 3.2. Обучение модели

### 3.2.1. Набор данных

Обучение модели выполнено на синтетическом наборе данных, сгенерированном под обучение разработанной архитектуры модели. Набор данных включает ‘Train’, ‘Val’ и ‘Test’-коллекций csv-таблиц частотных характеристик и json-файлов с координатами полюсов/нулей.

Тренировочный набор данных состоит из 72 случайных комбинаций полюсов/нулей обобщенной модели линейного динамического звена:

$$H(s) = G \frac{\prod_{m=1}^M \left(1 + \frac{s}{\omega_{z(m)}}\right)}{s^K \prod_{n=1}^N \left(1 + \frac{s}{\omega_{p(n)}}\right)} e^{-st_{\text{delay}}},$$

где

- $G$  – пропорциональный коэффициент,  $G \in \mathbb{R}$ ;
- $t_{\text{delay}}$  – задержка времени,  $t_{\text{delay}} > 0$ ;
- $K$  – количество интеграторов,  $K \in \mathbb{N}$ ;
- $\omega_{z(m)}$  – частоты нулей передаточной функции  $H(s)$  в количестве  $M$ ,  $\omega_{z(m)} \in \mathbb{R}$ ;
- $\omega_{p(n)}$  – частоты полюсов передаточной функции  $H(s)$  в количестве  $N$ ,  $\omega_{p(n)} \in \mathbb{R}$ .

Каждой комбинации соответствует 500 значений, отличающихся диапазонами частот и частотами полюсов/нулей. Параметры  $G$ ,  $t_{\text{delay}}$  заданы константами для последующего изменения в ходе обучения. Общий размер тренировочного набора данных –  $72 \times 500 = 36\,000$  примеров. Размеры валидационного и тестового наборов – 14 400 и 7 200 примеров, соответственно.

В тестовом наборе данных параметры  $G$ ,  $t_{\text{delay}}$  сгенерированы случайным образом; частотные характеристики приближены к реальным данным путем введения шума с нормальным распределением.

Полное описание генератора набора данных приведено в репозитории [5].

### 3.2.2. Функция потерь

Обучение производилось путем минимизации комбинированной функции потерь

$$w^{\text{BCE}} \mathcal{L}^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}^{\text{Dice}},$$

где

- $\mathcal{L}^{\text{BCE}}$  – перекрестная энтропия,
- $\mathcal{L}^{\text{Dice}}$  – функция потерь Дайса,
- $w^{\text{BCE}}$ ,  $w^{\text{Dice}}$  – весовые коэффициенты.

Перекрестная энтропия:

$$\mathcal{L}^{\text{BCE}} = -\frac{1}{L} \sum_{i=1}^L \left[ t_i \log(\sigma(d_i)) + (1 - t_i) \log(1 - \sigma(d_i)) \right],$$

где  $t_i$  – ожидаемое значение (0 или 1),  $d_i$  – логиты с выхода декодера (логит). Логиты преобразуются в непрерывный диапазон  $[0; 1]$  функцией

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Функция потерь Дайса:

$$\mathcal{L}^{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^L d_i t_i}{\sum_{i=1}^L d_i + \sum_{i=1}^L t_i + \varepsilon}. \quad (3.1)$$

С целью более глубокого обучения полная функция ошибки формируется по каждому выходу  $n$  декодера:

$$\mathcal{L} = \frac{1}{w} \sum_{n=1}^N \left[ w_n \left( w^{\text{BCE}} \mathcal{L}_n^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}_n^{\text{Dice}} \right) \right],$$

$w$  – сумма всех коэффициентов  $w_n$ .

### 3.2.3. Метрики

Оценка качества работы модели производилась по коэффициенту Дайса:

$$\text{Dice} = \frac{2 \sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i + \varepsilon}, \quad (3.2)$$

где  $p_i$  – значения бинарной маски на выходе модели,

$$p_i = \mathbb{I}(\sigma(d_i) > 0,5). \quad (3.3)$$

где  $\mathbb{I}(\cdot)$  – индикаторная функция, принимающая значения «0» или «1».

В качестве вспомогательной метрики использовался коэффициент Жаккара:

$$\text{IoU} = \frac{\sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i - \sum_{i=1}^L p_i t_i + \varepsilon}. \quad (3.4)$$

### 3.3. Результаты

Обучение модели выполнялось по лучшему коэффициенту Дайса на валидации (см. раздел 3.1). Весовые коэффициенты функции ошибки:  $w^{\text{BCE}} = 0.25$ ,  $w^{\text{Dice}} = 0.75$ .

Таблица 3.1. Метрики результирующие

|          |              | <b>Dice</b> | <b>IoU</b> | <b>Комментарий</b>                                      |
|----------|--------------|-------------|------------|---------------------------------------------------------|
| <b>1</b> | <b>Train</b> | 0.9092      | 0.8580     | Случайные аугментации: $G$ , $t_{\text{delay}}$ , шумы. |
| <b>2</b> | <b>Val</b>   | 0.9393      | 0.9030     | Нет аугментаций.*                                       |
| <b>3</b> | <b>Test</b>  | 0.9221      | 0.8774     | Нет аугментаций.**                                      |

\* Набор данных изначально сформирован с разными  $G$ ,  $t_{\text{delay}}$ .

\*\* Набор данных изначально сформирован с шумами и разными  $G$ ,  $t_{\text{delay}}$ .

Результаты инференса случайных примеров из тестового набора данных

Проведен эксперимент на лабораторном стенде (приложение А). Внутрисхемно измерена частотная характеристика цифрового звена

$$H(z) = \frac{\alpha}{1 - (1 - \alpha)z^{-1}},$$

где  $\alpha = 0.12566$ , частота тактирования 100 кГц, и выполнена детекция его полюсов и нулей

## **Заключение**

Выводы по работе, ключевые результаты, перспективы дальнейших исследований.

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Identity Mappings in Deep Residual Networks / К. Хе [и др.] // European Conference on Computer Vision (ECCV). — Springer, 2016. — С. 630—645. — DOI: [10.1007/978-3-319-46493-0\\_38](https://doi.org/10.1007/978-3-319-46493-0_38). — arXiv: [1603.05027 \[cs.CV\]](https://arxiv.org/abs/1603.05027). — URL: <https://arxiv.org/abs/1603.05027>.
2. On Layer Normalization in the Transformer Architecture / R. Xiong [и др.] // Proceedings of the 37th International Conference on Machine Learning (ICML). — PMLR, 2020. — С. 10524—10533. — URL: <https://arxiv.org/abs/2002.04745>.
3. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. Т. 30. — Curran Associates, Inc., 2017. — С. 5998—6008. — URL: <https://arxiv.org/abs/1706.03762>.
4. Attention U-Net: Learning Where to Look for the Pancreas / O. Oktay [и др.] // 1st Conference on Medical Imaging with Deep Learning (MIDL). — 2018. — URL: <https://arxiv.org/abs/1804.03999>.
5. *Gorbunov R.* zeros-poles-masks. — 2026. — GitHub repository; last accessed: 2026-05-04. <https://github.com/romangorbunov91/zeros-poles-masks>.

## Приложение А. Лабораторный стенд

1. Макет источника питания 180 Вт – 1 шт.
2. Источник питания GW INSTEK GPC-3060D (2x30 В, 2x6 А) – 1 шт.
3. Нагрузка электронная АКИП 1380/1 (150 В, 30 А, 300 Вт) – 1 шт.
4. Измеритель частотных характеристик AP300 – 1 шт.
5. Осциллограф АКИП-4126/4А-Х – 1 шт.
6. Мультиметр FLUKE 17B+ – 1 шт.




Рисунок А.1. Лабораторный стенд

## **Приложение Б. Внедрение результатов работы**