

Университет ИТМО

Факультет технологий искусственного интеллекта

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

по направлению подготовки

27.04.03 Системный анализ и управление

Тема: «Алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания»

Выполнил: Горбунов Роман Леонидович

Научный руководитель: к.ф.-м.н., Бабушкин М.В.

Санкт-Петербург, 2026

Аннотация

Краткое описание работы.

Ключевые слова: ключ1, ключ2, ключ3.

Содержание

Введение

Актуальность темы работы Работа связана с системами управления вторичными источниками электропитания, их настройкой, отладкой и контролем состояния.

Цели и задачи работы

Цель работы - разработать алгоритмы внутрисхемного измерения частотных характеристик и идентификации параметров вторичных источников электропитания.

Задачи работы:

1. Разработать алгоритмы внутрисхемного измерения частотных характеристик.
2. Разработать алгоритмы идентификации параметров на основе измеренных частотных характеристик.
3. Выполнить экспериментальную оценку показателей качества измерений и идентификации параметров.

Основные результаты работы

Практическая значимость результатов работы

Апробация результатов работы

Объем и структура работы

1. Обзор алгоритмов измерения частотных характеристик и идентификации параметров макромоделей физических объектов

1.1. Алгоритмы измерения частотных характеристик

1.2. Алгоритмы идентификации параметров

2. Разработка алгоритмов внутрисхемного измерения частотных характеристик

2.1. Общие сведения

Рассматриваемая система аналого-цифрового преобразования и цифровой обработки сигналов с воздействием на объект управления посредством широтно-импульсной модуляции (рис. (??)).




Рисунок 2.1. Рассматриваемая система

Операции выполняются циклически с постоянным периодом T_d , соответствующим базовой частоте дискретного регулирования $f_d = 1/T_d$.

В канал управления системы аддитивно инжектируется сигнал в виде дискретной последовательности $z[n]$.

Откликом системы являются два непрерывных сигнала: $x_c(t)$, $y_c(t)$.

Система преобразует непрерывные сигналы $x_c(t)$, $y_c(t)$ в дискретные последовательности $x[n]$, $y[n]$.

Преобразование осуществляется посредством дискретизации:

$$\begin{aligned} x[n] &= x_c(nT_s), \\ y[n] &= y_c(nT_s), \end{aligned} \tag{2.1}$$

где T_s – период дискретизации, $T_s \geq T_d$.

Коэффициенты разложения дискретных последовательностей

$$x[n] = \frac{1}{N} \sum_{l=0}^{N-1} X[l] e^{j \frac{2\pi}{N} ln},$$

$$y[n] = \frac{1}{N} \sum_{l=0}^{N-1} Y[l] e^{j \frac{2\pi}{N} ln}$$

определяются по N -последовательным отсчетам дискретных последовательностей $x[n]$, $y[n]$:

$$\begin{aligned} X[l] &= \sum_{n=0}^{N-1} x[n] e^{-j \frac{2\pi}{N} nl}, \\ Y[l] &= \sum_{n=0}^{N-1} y[n] e^{-j \frac{2\pi}{N} nl}. \end{aligned} \tag{2.2}$$

Коэффициенты $X[l]$, $Y[l] \in \mathbb{C}$, представляют собой дискретные периодические последовательности с периодом N .

При условии, что измерительное окно длительностью T_h вмещает целое количество N периодов дискретизации T_s ($T_h = N \cdot T_s$) дискретные последовательности $X[l]$, $Y[l]$ на отрезке $l \in [0; N-1]$ длины N содержат коэффициенты разложения $x[n]$, $y[n]$ в диапазоне частот $f \in [0, f_s/2]$ с шагом по частоте $\Delta f = 1/T_h$.

Составляющим с частотой f_h соответствуют $X[l]$, $Y[l]$ при $l = 1$, а с частотой $f_s/2$ – при $l = \lfloor (N-1)/2 \rfloor$.

В данном разделе рассматриваются алгоритмы измерения частотных характеристик, основанные на воздействии на систему дискретной последовательностью $z[n]$ моногармонического типа, определяемой косинусоидальной функцией

$$z[n] = Z \cos(\underbrace{2\pi f_z T_d n}_{\omega_z})$$

с частотой f_z .

Минимальное количество отсчетов N на измерительном окне T_h принято равным 3, поэтому частота f_z ограничена сверху значением $f_d/3$.

Модель сигналов-откликов системы принята следующей:

$$\begin{aligned}x_c(t) &= X_0 + X_z \cos(\omega_z t + \phi_x) + X_g \cos(\omega_g t), \\y_c(t) &= Y_0 + Y_z \cos(\omega_z t + \phi_y) + Y_g \cos(\omega_g t),\end{aligned}$$

где $\omega_z = 2\pi f_z$.

Алгоритм измерения частотной характеристики звена системы основан на последовательной смене периода инжектируемого сигнала $T_z = 1/f_z$ в серии из K -измерений.

Каждому k -му измерению, $k \in [1, K]$, соответствует пара параметров $Z^{(k)}$, $T_z^{(k)}$, следовательно, и набор дискретных последовательностей $x^{(k)}[n]$, $y^{(k)}[n]$, $z^{(k)}[n]$, а также коэффициентов $X^{(k)}[l]$, $Y^{(k)}[l]$.

Под частотной характеристикой понимается набор пар значений $f_z^{(k)}$, $W^{(k)}$, где в каждом k -ом измерении

$$W^{(k)} = \frac{Y^{(k)}[L^{(k)}]}{X^{(k)}[L^{(k)}]} = |W^{(k)}| e^{j\angle W^{(k)}}, \quad (2.3)$$

$$L^{(k)} = T_h^{(k)} / T_z^{(k)}.$$

Пары значений $f_z^{(k)}$, $|W^{(k)}|$ и $f_z^{(k)}$, $\angle W^{(k)}$ образуют амплитудно-частотную и фазо-частотную характеристики, соответственно.

$$\begin{aligned}|W^{(k)}| &= \frac{|Y^{(k)}[L^{(k)}]|}{|X^{(k)}[L^{(k)}]|}, \\ \angle W^{(k)} &= \angle Y^{(k)}[L^{(k)}] - \angle X^{(k)}[L^{(k)}].\end{aligned} \quad (2.4)$$

2.2. Алгоритм $T_h - var$, $N - var$

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}$, $k \in [1; K]$):

- Длительность T_h измерительного окна равна периоду T_z инжектируемого сигнала ($T_h^{(k)} = T_z^{(k)}$, $T_h^{(k)} - var$).
- Период дискретизации T_s одинаков для всех значений T_z и равен периоду T_d выполнения операций в системе ($T_s^{(k)} = T_d$, $T_s^{(k)} = const$).
- Количество точек N дискретной последовательности, по которым вы-

числяются коэффициенты разложения в выражении (??), изменяется пропорционально $T_z (N^{(k)} - var)$.

Период инжектируемого сигнала

$$T_z^{(k)} = N^{(k)} \cdot T_s^{(k)} = N^{(k)} \cdot T_d$$

кратен периоду T_d выполнения операций в системе (рис. ??).




Рисунок 2.2. Размер $N^{(k)}$ дискретной последовательности при изменении периода $T_z^{(k)}$ инжектируемого сигнала

В связи с тем, что $T_h^{(k)} = T_z^{(k)}$ составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (??) при $L^{(k)} = 1$.

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты f_z инжектируемого сигнала в серии из K измерений **характерны следующие особенности:**

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , которое ограничено сверху только объемом памяти для хранения массивов-откликов $x [n]$, $y [n]$.

2. Максимально возможная частота f_z в пределе составляет $f_d/3$.
3. В памяти достаточно хранить $N^{(k)} = f_d/f_z^{(k)}$ -значений каждого массива-отклика $x^{(k)}[n]$, $y^{(k)}[n]$, причем величина N не является постоянной и уменьшается с ростом частоты f_z вплоть до $N = 3$ при $f_z \rightarrow f_d/3$.
4. Шаг приращения периода T_z инжектируемого сигнала (разрешающая способность): $\Delta T_z = T_d$.
5. Потенциальные значения частот f_z инжектируемого сигнала неравномерно распределены на интервале $f \in (0; f_d/2)$ возможных значений:
 - На полуинтервале $f \in [f_d/10; f_d/2)$ частота f_z может принимать значения всего из 8-ми возможных:

$$f_z = (f_d/10, f_d/9, \dots, f_d/3).$$
 - На полуинтервале $f \in [f_d/100; f_d/10)$ – одно из 90 возможных:

$$f_z = (f_d/100, f_d/99, \dots, f_d/11).$$
 - На интервале $f \in (0; f_d/100)$ – сколь угодно много значений, ограниченное исключительно объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.

2.3. Алгоритм $T_h - var, N = const$

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}, k \in [1; K]$):

- Длительность T_h измерительного окна равна периоду T_z инжектируемого сигнала ($T_h^{(k)} = T_z^{(k)}, T_h^{(k)} - var$).
- Количество точек N дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (??), неизменно для всех значений периода T_z ($N^{(k)} = const$).
- Период дискретизации T_s изменяется в целях обеспечить $N^{(k)} = const$ при изменении периода T_z инжектируемого сигнала ($T_s^{(k)} - var$).

Постоянство N при изменении периода T_z инжектируемого сигнала обеспечивается децимацией (прореживанием) дискретных последовательностей $x'[n]$, $y'[n]$.

Выражениями $x'[n]$, $y'[n]$ обозначены дискретные последовательности, формируемые в результате дискретизации откликов системы $x_c(t)$, $y_c(t)$ непосредственно с периодом T_d выполнения операций в системе.

Дискретные последовательности $x^{(k)}[n]$, $y^{(k)}[n]$ формируются в резуль-

тате децимации $x'^{(k)}[n]$, $y'^{(k)}[n]$ с коэффициентом децимации $M^{(k)} \in \mathbb{N}$

$$x^{(k)}[n] = x'^{(k)}[n \cdot M^{(k)}] = x_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}})$$

$$y^{(k)}[n] = y'^{(k)}[n \cdot M^{(k)}] = y_c^{(k)}(\underbrace{n \cdot M^{(k)} \cdot T_d}_{T_s^{(k)}}),$$

так, что период инжектируемого сигнала всегда кратен периоду T_d выполнения операций в системе:

$$T_z^{(k)} = N^{(k)} \cdot \underbrace{M^{(k)} \cdot T_d}_{T_s^{(k)}}.$$

Дискретные последовательности $x^{(k)}[n]$, $y^{(k)}[n]$ формируются по правилу (??) фактически с эквивалентным периодом дискретизации $T_s^{(k)} = M^{(k)} \cdot T_d$ (рис. (??)). Под эквивалентным понимается такой период дискретизации, при котором формировалась бы точно такая же дискретная последовательность.




Рисунок 2.3. Период дискретизации $T_s^{(k)}$ при изменении периода $T_s^{(z)}$ инжектируемого сигнала

Измерительное окно $T_h^{(k)} = T_z^{(k)}$ при всех k , поэтому, также как и в алгоритме ??, составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)}[l]$, $Y^{(k)}[l]$ всегда при $l = 1$, т.е. коэффициент передачи динамического звена на частоте $f_z^{(k)}$ определяется выражением (??) при $L^{(k)} = 1$.

Принципиальное отличие от алгоритма ?? связано с потенциально меньшим размером N массивов-откликов $x[n]$, $y[n]$ ($N \in \mathbb{N}$ – независимая переменная, $N > 2$).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты f_z инжектируемого сигнала в серии из K измерений **характерны следующие особенности**:

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , причем требуемый объем памяти для хранения массивов-откликов $x^{(k)}[n]$, $y^{(k)}[n]$ одинаков для всех длительностей $T_h^{(k)}$ и частот $f_z^{(k)}$.
2. Максимально возможная частота f_z составляет f_d/N .

3. Шаг приращения периода T_z инжектируемого сигнала (разрешающая способность) в N -раз больше, в сравнении с алгоритмом ?? ($\Delta T_z = N \cdot T_d$).
4. Грубый шаг приращения периода обуславливает еще более неравномерное распределение частот. Например, в диапазоне частот $f \in [f_d/100; f_d/10]$ при $N = 10$ частота f_z инжектируемого сигнала может принимать значения всего из 10-ти возможных:
 $f_z = (f_d/100, f_d/90, \dots, f_d/10)$.

2.4. Алгоритм $T_h = const, N = const$

Данный алгоритм характеризуется тем, что в серии из K изменений периода T_z инжектируемого сигнала ($T_z^{(k)}, k \in [1; K]$):

- Длительность T_h измерительного окна неизменна и равна наибольшему периоду инжектируемого сигнала ($T_h^{(k)} = T_z^{max}, T_h^{(k)} = const$).
- Период дискретизации T_s одинаков для всех значений T_z ($T_s^{(k)} = const$) и кратен периоду T_d выполнения операций в системе ($T_s^{(k)} = M \cdot T_d$); коэффициент децимации $M = const, M \in \mathbb{N}$.
- Количество точек $N \in \mathbb{N}$ дискретной последовательности, по которым вычисляются коэффициенты разложения в выражении (??), неизменно для всех значений $T_z^{(k)}$ ($N^{(k)} = const$),

$$N^{(k)} = \frac{T_h^{(k)}}{T_s^{(k)}}.$$

Математическая обработка в соответствии с (??) накладывает ограничение на период T_z инжектируемого сигнала – требуется, чтобы измерительное окно T_h вмещало целое число периодов T_z (рис. ??), т.е. для каждого значения $T_z^{(k)}$ должно выполняться

$$T_h^{(k)} = L^{(k)} \cdot T_z^{(k)}, \quad (2.5)$$

где $L^{(k)} \in \mathbb{N}$.




Рисунок 2.4. Период инжектируемого сигнала при $T_h^{(k)} = const$

В соответствии с (??), частота $f_z^{(k)}$ инжектируемого сигнала потенциально принимает значения

$$f_z^{(k)} = L^{(k)} \frac{1}{T_h} = L^{(k)} \Delta f_z,$$

где Δf_z – шаг приращения частоты инжектируемого сигнала

В связи с $\Delta f_z = const$ потенциальные значения частот $f_z^{(k)}$ равномерно распределены на интервале возможных значений, что **является главной отличительной особенностью алгоритма** в сравнении с алгоритмами ??, ??.

Составляющей с частотой $f_z^{(k)}$ соответствуют коэффициенты $X^{(k)} [l]$, $Y^{(k)} [l]$ при разных значениях $L^{(k)}$, определяемых выражением (??).

Таким образом, изложенному алгоритму измерения частотных характеристик с последовательной сменой частоты $f_z^{(k)}$ инжектируемого сигнала в серии из K измерений **характерны следующие особенности:**

1. Минимально возможная частота f_z напрямую определяется максимальным значением измерительного окна T_h , которое ограничено сверху

только объемом памяти для хранения массивов-откликов $x[n]$, $y[n]$.

2. Максимально возможная частота f_z в пределе составляет $f_s/3$.
3. Требуемый объем памяти для хранения массивов-откликов $x^{(k)}[n]$, $y^{(k)}[n]$ одинаков для всех частот $f_z^{(k)}$ инжектируемого сигнала.
4. Период T_z инжектируемого сигнала потенциально принимает значения от $T_z^{min} = 3T_s$ до $T_z^{max} = T_h$, но при условии $T_h/T_s \in \mathbb{N}$.
5. Шаг приращения частоты f_z инжектируемого сигнала (разрешающая способность): $\Delta f_z = 1/T_h$.

3. Разработка алгоритмов идентификации параметров макромоделей

Фактически решаемая задача по идентификации параметров сведена к задаче instance-сегментации. Разработанная архитектура модели реализует детектирование целевых объектов по частотным характеристикам звеньев системы – определяются количество объектов и области частот, где они расположены.

3.1. Архитектура модели

Модель основана на автокодировщике, выполняющем преобразование C_{in} -канального тензора длиной L в C_{out} -канальный тензор той же длины:

$$\Gamma : \mathbb{R}^{C_{in} \times L} \mapsto \mathbb{R}^{C_{out} \times L}.$$

Выход представляет собой бинарную маску, каждый канал которой соответствует типу детектируемых объектов.

Преобразование Γ выполняется в 3 основных этапа:

- Кодирование в скрытое (латентное) пространство (CNN-энкодер):

$$\mathbf{F} : \mathbb{R}^{F_0 \times L} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Выделение наиболее информативных признаков в скрытом пространстве (bottleneck):

$$\mathbf{H} : \mathbb{R}^{F_3 \times L_3} \mapsto \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_3 \times L_3}.$$

- Декодирование из скрытого пространства (CNN-декодер):

$$\mathbf{Y} : \mathbb{R}^{F_4 \times L_4} \mapsto \mathbb{R}^{F_1 \times L_1}.$$

На входе и выходе архитектуры имеются дополнительные сверточные слои (без нормализации и активации). В декодер проброшены attention gated-skip-

СВЯЗИ.




Рисунок 3.1. Блок-схема архитектуры модели

3.1.1. Энкодер

Энкодер преобразует входные данные в латентное (скрытое) пространство уменьшенной размерности. В созданной реализации энкодер состоит из каскада N сверточных базовых блоков. Заложена residual-архитектура базового блока по типу «pre-activation».




Рисунок 3.2. Блок-схема базового блока энкодера

Каждый n -й базовый блок, $n \in \{1, \dots, N\}$, выполняет последовательно две

свертки с ядрами $\mathbf{W}_n^1, \mathbf{W}_n^2$, соответственно.

$$\begin{aligned}\mathbf{z}_n^1 &= \mathbf{W}_n^1 * \sigma(\mathcal{N}(\mathbf{e}_{n-1})), \\ \mathbf{z}_n^2 &= \mathbf{W}_n^2 * \sigma(\mathcal{N}(\mathbf{z}_n^1)), \\ \mathbf{x}_n &= \mathbf{z}_n^2 \oplus \mathbf{s}_n,\end{aligned}$$

где $*$ – операция свертки, $\oplus$ – поэлементная сумма.

Сквозная связь «вход-выход» $\mathbf{s}_n$ (skip-connection) базового слоя приводится к числу каналов (фичей) на выходе (при необходимости):

$$\mathbf{s}_n = \begin{cases} \mathbf{W}_n^s * \mathbf{e}_{n-1}, & \text{если } F_{n-1} \neq F_n \\ \mathbf{e}_{n-1}, & \text{иначе,} \end{cases}$$

где $\mathbf{W}_n^s \in \mathbb{R}^{F_n \times F_{n-1}}$ – ядро проекции.

Между слоями энкодера выполняется уменьшение размерности тензор в 2 раза алгоритмом «nn.MaxPool1d»:

$$\mathbf{e}_n \rightarrow \mathbf{e}_n \downarrow_2.$$

Таким образом, в энкодере выполняется последовательное увеличение числа каналов (фичей) с одновременным уменьшением размерности тензора. Residual-архитектура с pre-activation обеспечивают лучший градиентный поток для быстрой сходимости при обучении [1]. Регуляризация выполняется алгоритмом «nn.Dropout1d» на выходе второй свертки.

3.1.2. Bottleneck

Bottleneck реализован на основе трансформера.

С выхода энкодера поступает тензор $\mathbf{e}_3 \in \mathbb{R}^{F_3 \times L_3}$. На входе Bottleneck длина тензора уменьшается до L_4 , а количество каналов увеличивается до F_4 :

$$\mathbf{b}_{\text{in}} = \sigma(\mathcal{N}(\mathbf{W}^P * \mathbf{e}_3 \downarrow)),$$

где $\mathbf{W}^P \in \mathbb{R}^{F_4 \times F_3}$, $\mathbf{b}_{\text{in}} \in \mathbb{R}^{F_4 \times L_4}$.

На входе данные нормализуются (pre-normalization, [2]), затем тензор пре-

образуется (permute) к формату $L \times F$

$$\mathbf{b}_{\text{in}} \rightarrow \mathcal{N}(\mathbf{b}_{\text{in}}) \rightarrow \mathbf{b}_{\text{in.perm}},$$

$\mathbf{b}_{\text{in.perm}} \in \mathbb{R}^{L_4 \times F_4}$, для совместимости с популярной реализацией алгоритма Multi-Head Self-Attention (MHSA, [3]):

$$\begin{aligned} \mathbf{Q}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^Q, \\ \mathbf{K}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^K, \\ \mathbf{V}_m &= \mathbf{b}_{\text{in.perm}} \mathbf{W}_m^V, \\ \mathbf{H}_m &= \text{Softmax} \left(\frac{\mathbf{Q}_m \mathbf{K}_m^\top}{\sqrt{d_k}} \right) \mathbf{V}_m, \end{aligned}$$

где $d_k = F_4/h$,

$$\begin{aligned} \mathbf{W}_m^Q, \mathbf{W}_m^K, \mathbf{W}_m^V &\in \mathbb{R}^{F_4 \times d_k}, \\ \mathbf{Q}_m, \mathbf{K}_m, \mathbf{V}_m, \mathbf{H}_m &\in \mathbb{R}^{L_4 \times d_k}, \end{aligned}$$

$m \in \{1, \dots, h\}$.

Результаты вычисления h -«голов» алгоритма MHSA конкатенируются

$$\mathbf{MH}_{\text{perm}} = \text{Concat}(\mathbf{H}_1, \dots, \mathbf{H}_h) \mathbf{W}^O,$$

где $\mathbf{W}^O \in \mathbb{R}^{L_4 \times d_k}$, т.е. $\mathbf{MH}_{\text{perm}} \in \mathbb{R}^{L_4 \times F_4}$ – той же размерности, что и $\mathbf{b}_{\text{in.perm}}$.

Выход формируется в виде суммы со входным тензором, для чего размерности преобразуются обратно ($\mathbf{MH}_{\text{perm}} \rightarrow \mathbf{MH}$).

$$\mathbf{b}_{\text{attn}} = \mathbf{b}_{\text{in}} \oplus \mathbf{MH}.$$

После алгоритма MHSA выполняется нормализация данных для их последующей обработки полносвязными слоями (Multi-Layer Perceptron, MLP). Реализованы два Feed-Forward-слоя с промежуточным увеличением скрытого пространства в r -раз:

$$\mathbf{MLP} = \text{Dropout} \left(\mathbf{W}^{\text{MLP2}} \cdot \sigma \left(\mathbf{W}^{\text{MLP1}} \mathcal{N}(\mathbf{b}_{\text{attn}}) \right) \right),$$

$$\mathbf{b}_{\text{out}} = \mathbf{b}_{\text{attn}} \oplus \mathbf{MLP},$$

$$\mathbf{W}^{\text{MLP1}} \in \mathbb{R}^{(r \cdot F_4) \times F_4},$$

$$\mathbf{W}^{\text{MLP2}} \in \mathbb{R}^{F_4 \times (r \cdot F_4)},$$

где r – кратность масштабирования скрытого пространства в MLP-алгоритме.

Регуляризация выполняется алгоритмом «nn.Dropout» после каждого Feed-Forward-слоя.

3.1.3. Декодер

Каждый слой декодера увеличивает разрешение массива, последовательно приближая данные к маскам длины L .

$$\mathbf{x}_{\uparrow} = \text{Upsample}(\mathbf{x}),$$

$$\mathbf{z} = \mathbf{W} * \mathbf{x}_{\uparrow},$$

$$\mathbf{y} = \sigma(\mathcal{N}(\mathbf{z}))$$

Слои декодера связаны с соответствующими выходами энкодера посредством Attention-gated-связей, по аналогии с [4].

3.2. Обучение модели

3.2.1. Набор данных

Обучение модели выполнено на синтетическом наборе данных, сгенерированном под обучение разработанной архитектуры модели. Набор данных включает ‘Train’, ‘Val’ и ‘Test’-коллекций csv-таблиц частотных характеристик и json-файлов с координатами полюсов/нулей.

Тренировочный набор данных состоит из 72 случайных комбинаций полюсов/нулей обобщенной модели линейного динамического звена:

$$H(s) = G \frac{\prod_{m=1}^M \left(1 + \frac{s}{\omega_{z(m)}}\right)}{s^K \prod_{n=1}^N \left(1 + \frac{s}{\omega_{p(n)}}\right)} e^{-s t_{\text{delay}}},$$

где

- G – пропорциональный коэффициент, $G \in \mathbb{R}$;
- t_{delay} – задержка времени, $t_{\text{delay}} > 0$;
- K – количество интеграторов, $K \in \mathbb{N}$;
- $\omega_{z(m)}$ – частоты нулей передаточной функции $H(s)$ в количестве M , $\omega_{z(m)} \in \mathbb{R}$;
- $\omega_{p(n)}$ – частоты полюсов передаточной функции $H(s)$ в количестве N , $\omega_{p(n)} \in \mathbb{R}$.

Каждой комбинации соответствует 500 значений, отличающихся диапазонами частот и частотами полюсов/нулей. Параметры G , t_{delay} заданы константами для последующего изменения в ходе обучения. Общий размер тренировочного набора данных – $72 \times 500 = 36\,000$ примеров. Размеры валидационного и тестового наборов – 14 400 и 7 200 примеров, соответственно.

В тестовом наборе данных параметры G , t_{delay} сгенерированы случайным образом; частотные характеристики приближены к реальным данным путем введения шума с нормальным распределением.

Полное описание генератора набора данных приведено в репозитории [5].

3.2.2. Функция потерь

Обучение производилось путем минимизации комбинированной функции потерь

$$w^{\text{BCE}} \mathcal{L}^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}^{\text{Dice}},$$

где

- $\mathcal{L}^{\text{BCE}}$ – перекрестная энтропия,
- $\mathcal{L}^{\text{Dice}}$ – функция потерь Дайса,
- w^{BCE} , w^{Dice} – весовые коэффициенты.

Перекрестная энтропия:

$$\mathcal{L}^{\text{BCE}} = -\frac{1}{L} \sum_{i=1}^L \left[t_i \log(\sigma(d_i)) + (1 - t_i) \log(1 - \sigma(d_i)) \right],$$

где t_i – ожидаемое значение (0 или 1), d_i – логиты с выхода декодера (логит). Логиты преобразуются в непрерывный диапазон $[0; 1]$ функцией

$$\sigma(z) = \frac{1}{1 + e^{-z}}.$$

Функция потерь Дайса:

$$\mathcal{L}^{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^L d_i t_i}{\sum_{i=1}^L d_i + \sum_{i=1}^L t_i + \varepsilon}. \quad (3.1)$$

С целью более глубокого обучения полная функция ошибки формируется по каждому выходу n декодера:

$$\mathcal{L} = \frac{1}{w} \sum_{n=1}^N \left[w_n \left(w^{\text{BCE}} \mathcal{L}_n^{\text{BCE}} + w^{\text{Dice}} \mathcal{L}_n^{\text{Dice}} \right) \right],$$

w – сумма всех коэффициентов w_n .

3.2.3. Метрики

Оценка качества работы модели производилась по коэффициенту Дайса:

$$\text{Dice} = \frac{2 \sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i + \varepsilon}, \quad (3.2)$$

где p_i – значения бинарной маски на выходе модели,

$$p_i = \mathbb{I}(\sigma(d_i) > 0,5). \quad (3.3)$$

где $\mathbb{I}(\cdot)$ – индикаторная функция, принимающая значения «0» или «1».

В качестве вспомогательной метрики использовался коэффициент Жак-кара:

$$\text{IoU} = \frac{\sum_{i=1}^L p_i t_i}{\sum_{i=1}^L p_i + \sum_{i=1}^L t_i - \sum_{i=1}^L p_i t_i + \varepsilon} \quad (3.4)$$

3.3. Результаты

Обучение модели выполнялось по лучшему коэффициенту Дайса на валидации ???. Весовые коэффициенты функции ошибки: $w^{\text{BCE}} = 0.25$, $w^{\text{Dice}} = 0.75$.

Результаты инференса случайных примеров из тестового набора данных (??, ??).

Таблица 3.1. Метрики результирующие

		Dice	IoU	Комментарий
1	Train	0.9092	0.8580	Случайные аугментации: G , t_{delay} , шумы.
2	Val	0.9393	0.9030	Нет аугментаций.*
3	Test	0.9221	0.8774	Нет аугментаций.**

* Набор данных изначально сформирован с разными G , t_{delay} .

** Набор данных изначально сформирован с шумами и разными G , t_{delay} .




Рисунок 3.3. Результаты детекции полюсов/нулей




Рисунок 3.4. Результаты детекции полюсов/нулей

Проведен эксперимент на лабораторном стенде (приложение ??). Внутрисхемно измерена частотная характеристика цифрового звена

$$H(z) = \frac{\alpha}{1 - (1 - \alpha)z^{-1}},$$

где $\alpha = 0.12566$, частота тактирования 100 кГц, и выполнена детекция его полюсов и нулей (??).




Рисунок 3.5. Результат эксперимента

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Identity Mappings in Deep Residual Networks / К. He [и др.] // European Conference on Computer Vision (ECCV). — Springer, 2016. — С. 630—645. — DOI: [10.1007/978-3-319-46493-0_38](https://doi.org/10.1007/978-3-319-46493-0_38). — arXiv: [1603.05027](https://arxiv.org/abs/1603.05027) [cs.CV]. — URL: <https://arxiv.org/abs/1603.05027>.
2. On Layer Normalization in the Transformer Architecture / R. Xiong [и др.] // Proceedings of the 37th International Conference on Machine Learning (ICML). — PMLR, 2020. — С. 10524—10533. — URL: <https://arxiv.org/abs/2002.04745>.
3. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. Т. 30. — Curran Associates, Inc., 2017. — С. 5998—6008. — URL: <https://arxiv.org/abs/1706.03762>.
4. Attention U-Net: Learning Where to Look for the Pancreas / O. Oktay [и др.] // 1st Conference on Medical Imaging with Deep Learning (MIDL). — 2018. — URL: <https://arxiv.org/abs/1804.03999>.
5. *Gorbunov R.* zeros-poles-masks. — 2026. — GitHub repository; last accessed: 2026-05-04. <https://github.com/romangorbunov91/zeros-poles-masks>.

Приложение А. Лабораторный стенд

1. Макет источника питания 180 Вт – 1 шт.
2. Источник питания GW INSTEK GPC-3060D (2x30 В, 2x6 А) – 1 шт.
3. Нагрузка электронная АКИП 1380/1 (150 В, 30 А, 300 Вт) – 1 шт.
4. Измеритель частотных характеристик AP300 – 1 шт.
5. Осциллограф АКИП-4126/4А-Х – 1 шт.
6. Мультиметр FLUKE 17B+ – 1 шт.




Рисунок А.1. Лабораторный стенд

Приложение Б. Внедрение результатов работы